

Mémoire de stage de Master 2  
Informatique et Mathématiques Discrètes (IMD)  
Année universitaire 2025–2026

---

# Génération automatique et exhaustive de structures moléculaires bi-dimensionnelles par programmation par contraintes

---

Toky Nirina RAMAHERISOA

**Encadrants** Nicolas PRCOVIC et Cyril TERRIOUX  
*LIS, équipe COALA, Aix-Marseille Université*

**Partenaires** Yannick CARISSAN et Denis HAGEBAUM-REIGNIER  
*Institut des Sciences Moléculaires de Marseille (iSm2)*

## Table des matières

Table des figures

Liste des tableaux

Liste des algorithmes

# 1 Introduction

## 1.1 Contexte

Les *hydrocarbures aromatiques polycycliques* (HAP) sont des molécules constituées uniquement de carbone et d'hydrogène, dont les atomes de carbone forment des cycles fusionnés. Ils sont étudiés pour leurs propriétés électroniques et opto-électroniques. Parmi les HAP, les *benzénoïdes* forment la sous-famille composée exclusivement d'hexagones fusionnés par une arête. Cette famille a fait l'objet de nombreux travaux, et notamment de la thèse de A. Varet [?], qui a montré que la *programmation par contraintes* (PPC) est un outil particulièrement adapté à la génération exhaustive de benzénoïdes répondant à des propriétés données.

L'étude des HAP comportant des cycles à *cinq* ou *sept* atomes, dits *non-benzénoïdes*, est plus récente. L'azulène, formé d'un pentagone et d'un heptagone accolés (figure ??), en est l'exemple emblématique. L'introduction de tels cycles modifie en profondeur la chimie de la molécule : elle brise la régularité du pavage hexagonal, induit une courbure locale, et favorise l'apparition de sites radicalaires. Ces structures intéressent donc les chimistes, mais leur génération systématique reste largement inexplorée.




FIGURE 1 – Azulène (C<sub>10</sub>H<sub>8</sub>).

**Remarque 1.** Pour alléger la lecture, les figures suivantes ne représenteront plus explicitement les atomes d'hydrogène ni les liaisons C–H : ces derniers sont implicites sur tous les carbones de degré 2 du graphe carbone (les carbones de bord).

## 1.2 Objectif et problématique

L'objectif du stage est le suivant : étant donné un benzénoïde, énumérer de manière exhaustive toutes les substitutions admissibles dans lesquelles chaque hexagone est soit conservé, soit remplacé par un cycle à 5 ou 7 atomes. La difficulté est double, à la fois combinatoire et géométrique. Nous en donnons l'énoncé précis et l'analyse détaillée à la section ??, une fois introduit le vocabulaire nécessaire.

## 1.3 Positionnement et contributions

Ce stage se place dans la continuité directe de la thèse de Varet [?] : nous reprenons son cadre (modélisation PPC sur le *graphe dual* d'un benzénoïde, notions d'aromaticité) et nous l'étendons au cas, non traité jusqu'ici, des cycles à 5 et 7 atomes. Nos contributions sont les suivantes.

- Un **modèle PPC** qui énumère exhaustivement les substitutions 5/6/7 d'un benzénoïde, fondé sur une *table de voisinage* encodant les configurations locales chimiquement réalisables.

- Un **pipeline de validation physique** qui reconstruit en trois dimensions chaque solution du modèle, l’optimise par une méthode quantique semi-empirique (xTB), puis juge sa planéité.
- Une **étude expérimentale systématique** de contraintes additionnelles visant à augmenter la proportion de molécules planes produites. Ce point mérite une précision : la planéité d’une molécule est une propriété *globale* qui ne se laisse pas exprimer entièrement par des contraintes locales — c’est une difficulté intrinsèque au problème, et non un défaut de modélisation. Notre démarche consiste à identifier expérimentalement les contraintes qui, sans capturer la planéité au sens strict, en améliorent significativement le rendement.
- Une **extension de l’analyse électronique** (structures de Kekulé, couvertures de Clar, *Ring Bond Order*) aux cycles à 5 et 7 atomes, là où les outils existants se limitent aux hexagones.

Le mémoire est organisé comme suit. La section ?? introduit les deux corpus de notions nécessaires — la PPC et la chimie des HAP. La section ?? détaille le problème et ses difficultés. La section ?? présente notre modélisation. La section ?? décrit la réalisation (reconstruction, validation, analyse). La section ?? rapporte l’étude expérimentale, et la section ?? conclut.

## 2 Préliminaires et état de l’art

Notre travail se situe à l’interface de la chimie théorique et de l’informatique. Les notions nécessaires à la lecture du mémoire sont d’abord celles de la chimie des HAP, puis le formalisme de la programmation par contraintes.

### 2.1 Notions de chimie

Les termes de chimie employés dans la suite peuvent être lus aussi bien comme des définitions sur des graphes que comme le vocabulaire chimique usuel.

#### 2.1.1 Définitions préliminaires

Avant d’introduire les notions spécifiques aux HAP, nous rappelons brièvement le vocabulaire chimique de base utilisé dans le mémoire. Le lecteur familier peut sauter cette sous-section.

Atome et molécule : un atome est l’unité élémentaire de la matière chimique ; dans ce travail, seuls deux types interviennent : le carbone (C) et l’hydrogène (H). Une molécule est un assemblage stable d’atomes reliés par des liaisons covalentes.

Liaison covalente, simple et double : une liaison covalente résulte du partage d’une ou plusieurs paires d’électrons entre deux atomes. On parle de liaison *simple* lorsqu’une seule paire est partagée, de liaison *double* lorsque deux paires le sont.

Valence : la valence d’un atome est le nombre de liaisons qu’il peut former. Le carbone est tétravalent (quatre liaisons), l’hydrogène monovalent (une liaison).

Électrons  $\sigma$  et  $\pi$  : les électrons d’une liaison covalente se répartissent en deux types selon la géométrie du recouvrement orbitalaire. Une liaison simple est constituée d’une paire d’électrons formant une *liaison  $\sigma$* , qui appartient au squelette rigide de la molécule. Une liaison double comporte deux paires : la première forme également une liaison  $\sigma$ , la seconde une *liaison  $\pi$* , dont les électrons occupent des orbitales perpendiculaires au plan local et sont *plus faiblement localisés*. Ce sont ces électrons  $\pi$  qui portent les propriétés aromatiques et opto-électroniques des HAP.

### 2.1.2 HAP, benzénoïdes et graphe dual

Les **hydrocarbures aromatiques polycycliques** (HAP) sont des molécules formées exclusivement d'atomes de carbone et d'hydrogène, dont les carbones constituent un assemblage de cycles fusionnés.

**Définition 1** (Graphe carbone). À toute molécule HAP  $M$  on associe son **graphe carbone**  $G_C(M) = (V_C, E_C)$  : les sommets  $V_C$  sont les atomes de carbone, et les arêtes  $E_C$  représentent les liaisons covalentes carbone-carbone. Les hydrogènes périphériques, déduits des valences libres des carbones de bord, n'apparaissent pas dans ce graphe.




FIGURE 2 – Un benzénoïde non linéaire à six hexagones  $(v_0, \dots, v_5)$ .

Parmi les HAP, les **benzénoïdes** forment la sous-famille constituée exclusivement d'hexagones réguliers fusionnés par des arêtes du pavage hexagonal. Plus généralement, on s'intéressera également aux HAP comportant des cycles à 5, 6 ou 7 atomes. Pour tout HAP, on définit son **graphe dual**  $G_D$ , qui résume la combinatoire des cycles indépendamment de leur taille.

**Définition 2** (Graphe dual). Soit  $M$  un HAP formé de  $n$  cycles. Son graphe dual  $G_D(M) = (V_D, E_D)$  a pour sommets  $V_D = \{0, \dots, n-1\}$  (un sommet par cycle), et  $(u, v) \in E_D$  si et seulement si les cycles  $u$  et  $v$  partagent une arête carbone-carbone. Cette construction correspond au graphe dual intérieur de la littérature, c'est-à-dire le graphe dual classique privé de la face externe.

Pour un benzénoïde  $B$ , on note  $n_H(B)$  son nombre d'hexagones ; ainsi  $|V_D(B)| = n_H(B)$ . On appelle **bord** de  $G_D$  l'ensemble des cycles de degré strictement inférieur à 6, c'est-à-dire ceux qui ne sont pas entièrement entourés de voisins. La figure ?? illustre le graphe dual du benzénoïde de la figure ??.




FIGURE 3 – Graphe dual  $G_D$  du benzénoïde de la figure ??.

### 2.1.3 Structures de Kekulé

Une **structure de Kekulé** est un étiquetage des liaisons carbone-carbone en simples et doubles tel que chaque carbone porte exactement une double liaison. En termes de graphes, c'est un *couplage parfait* du graphe carbone. Une molécule HAP possède en général plusieurs structures de Kekulé, mais il est aussi possible qu'elle n'en possède aucune lorsque son graphe carbone n'admet pas de couplage parfait.




FIGURE 4 – Les trois structures de Kekulé du naphthalène.

#### 2.1.4 Sextets et couvertures de Clar

Un **sextet de Clar** (ou rond de Clar) est un hexagone dont les six électrons  $\pi$  forment un cycle aromatique autonome. Concrètement, on peut le visualiser comme trois liaisons doubles alternées sur le cycle, et on le représente conventionnellement par un cercle inscrit dans l'hexagone (voir figure ??). La règle de Hückel (voir annexe ??) impose qu'un sextet occupe exactement six atomes ( $4n + 2$  électrons  $\pi$ ,  $n = 1$ ) : seuls les *hexagones* peuvent porter un sextet, jamais un pentagone ni un heptagone.

La clé de la notion de sextet est la **délocalisation** : les six électrons  $\pi$  d'un sextet ne sont pas figés dans une configuration de liaisons doubles particulière, ils *circulent librement* autour du cycle. Autrement dit, la molécule ne possède pas une unique structure de Kekulé fixe : on ne peut pas prédire à l'avance dans quelle configuration elle se trouvera à un instant donné — elle oscille en permanence entre toutes ses structures de Kekulé équivalentes. C'est précisément cette mobilité qui explique qu'une même couverture de Clar puisse correspondre à plusieurs structures de Kekulé.

Une **couverture de Clar** place des sextets sur un ensemble d'hexagones deux à deux disjoints, et le **nombre de Clar** est le nombre maximal de sextets que l'on peut placer.




FIGURE 5 – Représentation d'un sextet de Clar.

Une même couverture de Clar peut correspondre à plusieurs structures de Kekulé : sur le naphthalène (figure ??), les Kekulé  $K_1$  et  $K_2$  ne diffèrent que par la rotation des liaisons doubles à l'intérieur de l'hexagone gauche et correspondent toutes deux à la couverture  $C_A$  (sextet sur l'hexagone gauche).  $K_3$  correspond à la couverture  $C_B$  (sextet sur l'hexagone droit). Le nombre de Clar du naphthalène vaut donc 1 : on ne peut placer qu'un seul sextet à la fois, les deux hexagones partageant une arête.

#### 2.1.5 Ring Bond Order (RBO)

Le *ring bond order* (RBO) est une mesure combinatoire de la délocalisation aromatique locale d'un hexagone au sein d'un benzénoïde. Il prolonge le concept de *bond order* introduit par Pauling [?] à partir de la théorie de la résonance, formalisé ensuite comme indicateur cyclique notamment par Randić [?]. Nous reprenons ici les notations de Varet [?].

Soit  $B = (V, E)$  le graphe carbone d'un benzénoïde :  $V$  désigne l'ensemble des atomes de carbone et  $E$  celui des liaisons covalentes entre atomes voisins. On note  $\mathcal{K}(B)$  l'ensemble de ses structures de Kekulé, c'est-à-dire des couplages parfaits du graphe. Lorsque  $\mathcal{K}(B) \neq \emptyset$ , on dit que  $B$  est *Kekuléen* ; dans le cas contraire ( $\mathcal{K}(B) = \emptyset$ ), la molécule est dite *non-Kekuléenne* et admet au moins un *site radicalaire* (voir figure ?? et section ??).

**Définition 3** (Bond order, [?]). Soient  $B = (V, E)$  un benzénoïde Kekuléen et  $e \in E$  une de ses




FIGURE 6 – Les deux couvertures de Clar du naphtalène

*liaisons*. Le bond order de  $e$  est le rapport entre le nombre de structures de Kekulé dans lesquelles  $e$  apparaît comme liaison double et le nombre total de structures de Kekulé de  $B$  :

$$\text{bo}(e) = \frac{|\{K \in \mathcal{K}(B) : e \in K\}|}{|\mathcal{K}(B)|}.$$

C'est une mesure de la délocalisation locale :  $\text{bo}(e) = 1$  signifie que  $e$  est double dans toutes les Kekulé (liaison localisée),  $\text{bo}(e) = 0$  qu'elle est toujours simple, et toute valeur intermédiaire traduit une délocalisation partielle.

**Définition 4** (Ring bond order, [?]). Soient  $B$  un benzénoïde Kekuléen et  $h$  un de ses hexagones. Le ring bond order de  $h$  est la somme des bond order associés aux six liaisons définissant  $h$  :

$$\text{RBO}(h) = \sum_{e \in E(h)} \text{bo}(e),$$

où  $E(h) \subset E$  désigne l'ensemble des six arêtes du cycle  $h$ .

**Remarque 2.** Pour tout hexagone  $h$  d'un benzénoïde Kekuléen, on a  $0 \leq \text{RBO}(h) \leq 3$ . La borne supérieure provient du fait que, dans toute structure de Kekulé  $K \in \mathcal{K}(B)$ , au plus trois arêtes de  $h$  peuvent être doubles dans  $K$  (un couplage parfait restreint aux six sommets de  $h$  comporte au plus trois arêtes). En sommant cette inégalité sur les structures et en divisant par  $|\mathcal{K}(B)|$ , on obtient  $\text{RBO}(h) \leq 3$ .

À titre d'exemple, le benzène admet exactement deux structures de Kekulé, échangées par rotation des liaisons doubles. Chaque arête  $y$  est double dans une seule des deux structures :  $\text{bo}(e) = 1/2$  pour les six arêtes, et l'unique hexagone vérifie  $\text{RBO}(h) = 6 \times 1/2 = 3$ , la valeur maximale. Le naphtalène, qui admet trois structures de Kekulé (figure ??), voit chacun de ses deux hexagones atteindre  $\text{RBO}(h) = 8/3 \approx 2,67$  : cette valeur strictement inférieure à 3 traduit la délocalisation partielle propre aux benzénoïdes polycycliques.

**Extension aux cycles de taille quelconque.** Les molécules considérées dans ce travail comportent non seulement des hexagones, mais aussi des cycles à cinq et sept atomes. Pour traiter ces cas, nous étendons la définition précédente. Soit  $C$  un cycle de taille  $n$  d'un graphe moléculaire Kekuléen, et  $E(C)$  l'ensemble de ses  $n$  arêtes. On définit le *cycle bond order*

$$\text{CBO}(C) = \sum_{e \in E(C)} \text{bo}(e).$$



Le même argument que ci-dessus donne l'encadrement

$$0 \leq \text{CBO}(C) \leq \lfloor n/2 \rfloor,$$

puisque un cycle de longueur  $n$  ne peut porter, dans une structure de Kekulé donnée, plus de  $\lfloor n/2 \rfloor$  arêtes doubles. Pour comparer la délocalisation entre cycles de tailles différentes, nous reportons systématiquement le ratio normalisé  $\text{CBO}(C)/\lfloor n/2 \rfloor \in [0, 1]$ , qui vaut 1 pour un cycle « parfaitement aromatique » au sens combinatoire. Dans le cas radicalaire où  $\mathcal{K}(B) = \emptyset$ , les quantités  $\text{bo}(e)$ ,  $\text{RBO}(h)$  et  $\text{CBO}(C)$  ne sont pas définies au sens classique.

### 2.1.6 Sites radicalaires

Lorsqu'une molécule n'admet aucun couplage parfait (par exemple à cause d'un nombre impair d'atomes ou d'une topologie particulière), certains carbones restent non couverts : ils portent un **électron  $\pi$  non apparié**, appelé aussi *électron célibataire*. La molécule devient dans ce cas un (mono)radical. La parité impaire des cycles à 5 et 7 atomes favorise précisément l'apparition de tels sites, ce qui rend les structures non-benzénoïdes intéressantes pour la chimie radicalaire.

L'exemple le plus simple est celui d'un pentagone accolé à un hexagone (figure ??) : le squelette compte  $5 + 6 - 2 = 9$  atomes de carbone, un nombre impair. Aucun couplage parfait ne peut donc exister, et au moins un carbone reste non couvert dans toute structure de Kekulé : un site radicalaire est *forcé* par la topologie.




FIGURE 7 – Un pentagone accolé à un hexagone

### 2.1.7 Aromaticité et délocalisation

L'**aromaticité** traduit la stabilité particulière de certains cycles conjugués. La *règle de Hückel* (annexe ??) en donne le critère classique : un cycle est dit aromatique s'il est plan, conjugué, et contient  $4n+2$  électrons  $\pi$  pour un entier  $n \geq 0$  — le benzène ( $n = 1$ , 6 électrons) en est l'exemple fondamental. Dans un tel cycle, les électrons  $\pi$  sont *délocalisés* et circulent autour du cycle. Plus une molécule admet de représentations équivalentes de ses liaisons doubles (au sens des structures de Kekulé introduites plus haut), plus la délocalisation est étendue, et plus la molécule est stable.

### 2.1.8 Planéité et courbure

À toute molécule on associe une fonction *énergie potentielle* qui dépend de la position de ses atomes ; cette énergie est minimale lorsque les longueurs et les angles de liaison correspondent aux préférences de chaque atome et que les répulsions stériques sont relâchées. Une configuration des atomes est dite à l'**équilibre énergétique** lorsqu'elle réalise un minimum local de cette énergie ; c'est dans cette configuration que la molécule existe effectivement. On dit alors qu'une molécule est **plane** si tous ses atomes se placent, à l'équilibre énergétique, dans un même plan.

Pour un pavage d'hexagones réguliers, la somme des angles autour de chaque sommet vaut  $360^\circ$  et la structure est plane. Un pentagone (angle interne  $108^\circ$ ) introduit localement un *défaut d'angle* par rapport à un hexagone et la tension de cycle est plus importante : la molécule tend à se refermer, comme dans un fullerène. À l'inverse, dans un heptagone ( $\approx 128,6^\circ$ ), les angles sont plus ouverts que ceux d'un hexagone et la molécule tend à être plus flexible, donc à onduler.

### 2.1.9 Validation quantique semi-empirique (xTB)

Pour juger si une molécule est réellement plane, on cherche sa géométrie d'équilibre : la disposition des atomes qui minimise l'énergie. Nous utilisons une méthode *semi-empirique*, GFN2-xTB [?], qui approxime l'énergie à un coût permettant de traiter de grandes séries de molécules et fournit une géométrie optimisée exploitable à grande échelle. C'est le sens de la « validation quantique semi-empirique » du titre.

## 2.2 Programmation par contraintes (PPC)

La *programmation par contraintes* est un paradigme déclaratif de résolution de problèmes combinatoires. Plutôt que de décrire *comment* résoudre un problème, on se contente d'en *décrire les solutions*, puis on confie la recherche à un solveur générique.

### 2.2.1 Réseau de contraintes

Une instance d'un problème de satisfaction de contraintes (CSP) est définie par un ensemble de *variables*, chacune dotée d'un *domaine* de valeurs possibles, et d'un ensemble de *contraintes* restreignant les combinaisons de valeurs autorisées. Formellement [?] :

**Définition 5** (Instance CSP). *Une instance d'un problème de satisfaction de contraintes est un triplet  $P = (X, D, C)$  où :*

- $X = \{x_1, x_2, \dots, x_n\}$  est un ensemble de  $n$  variables ;
- $D = \{d_{x_1}, d_{x_2}, \dots, d_{x_n}\}$  est un ensemble de domaines finis ; la variable  $x_i$  prend ses valeurs dans le domaine  $d_{x_i}$  ;
- $C = \{c_1, c_2, \dots, c_m\}$  est un ensemble de  $m$  contraintes. Chaque contrainte  $c$  est caractérisée par un couple  $(S(c), R(c))$  où
  1.  $S(c) = \{x_{i_1}, x_{i_2}, \dots, x_{i_q}\} \subseteq X$  est la portée de  $c$ , c'est-à-dire l'ensemble des variables sur lesquelles porte la contrainte ;
  2.  $R(c) \subseteq d_{x_{i_1}} \times d_{x_{i_2}} \times \dots \times d_{x_{i_q}}$  est sa relation de compatibilité, c'est-à-dire l'ensemble des combinaisons de valeurs autorisées par la contrainte.

Une contrainte portant sur une seule variable est dite *unaire*, sur deux variables *binaire*, sur  $q$  variables *q-aire*.

### 2.2.2 Un exemple : le Sudoku

Pour illustrer le formalisme, considérons le **Sudoku** : sur une grille  $9 \times 9$  partiellement remplie de chiffres de 1 à 9 (figure ??), on cherche à compléter les cases vides de telle sorte que chaque chiffre apparaisse exactement une fois sur chaque ligne, chaque colonne et chacun des neuf sous-blocs  $3 \times 3$ . Les chiffres initialement présents sont appelés *indices*.

Le problème se modélise comme un CSP  $P = (X, D, C)$  :

- $X = \{x_1, x_2, \dots, x_{81}\}$  : une variable par case de la grille, numérotées de gauche à droite et de haut en bas. La valeur de  $x_i$  représente le chiffre inscrit dans la  $i$ -ème case.
- $D = \{d_{x_1}, d_{x_2}, \dots, d_{x_{81}}\}$  : pour les cases vides,  $d_{x_i} = \{1, 2, \dots, 9\}$  ; pour les cases pré-remplies de valeur  $v$ ,  $d_{x_i} = \{v\}$ . Par exemple, sur la grille de la figure ??, on aurait  $d_{x_1} = \{2\}$ ,  $d_{x_2} = \{4\}$ ,  $d_{x_3} = \{1\}$ ,  $d_{x_4} = \{1, 2, \dots, 9\}$ , ...
- $C = \{c_{i,j}\}$  : pour chaque paire  $(x_i, x_j)$  de variables appartenant à une même ligne, une même colonne ou un même bloc  $3 \times 3$ , on définit une contrainte binaire  $c_{i,j}$  exprimant la différence des valeurs :

$$S(c_{i,j}) = \{x_i, x_j\}, \quad R(c_{i,j}) = \{(v_i, v_j) \in d_{x_i} \times d_{x_j} \mid v_i \neq v_j\}.$$

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 5 | 3 |   |   | 7 |   |   |   |   |
| 6 |   |   | 1 | 9 | 5 |   |   |   |
|   | 9 | 8 |   |   |   |   | 6 |   |
| 8 |   |   |   | 6 |   |   |   | 3 |
| 4 |   |   | 8 |   | 3 |   |   | 1 |
| 7 |   |   |   | 2 |   |   |   | 6 |
|   | 6 |   |   |   |   | 2 | 8 |   |
|   |   |   | 4 | 1 | 9 |   |   | 5 |
|   |   |   |   | 8 |   |   | 7 | 9 |

|  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |

FIGURE 8 – Un Sudoku partiellement rempli (à gauche). À droite, la valeur de la case  $x_{ij}$  doit différer de toutes les autres cases de sa ligne, de sa colonne et de son bloc  $3 \times 3$ .

**Remarque 3.** *Ces contraintes binaires seront avantageusement regroupées sous une contrainte globale plus compacte à la section ??, une fois introduite la notion de contrainte globale.*

### 2.2.3 Résolution : propagation et recherche arborescente

Décider si une instance CSP admet une solution est un problème **NP-complet** dans le cas général : aucun algorithme polynomial n'est connu pour le résoudre. Les solveurs CSP combinent en pratique deux mécanismes complémentaires que nous décrivons ci-dessous. Précisons d'abord la notion de solution.

**Définition 6** (Solution). *Une solution d'une instance CSP  $P = (X, D, C)$  est une affectation à chaque variable  $x_i$  d'une valeur de son domaine  $d_{x_i}$  telle que toutes les contraintes de  $C$  soient satisfaites. On parle d'affectation complète cohérente. Un problème est dit cohérent s'il possède au moins une solution, et incohérent sinon.*

**Propagation de contraintes (filtrage).** À chaque étape de la résolution, on retire des domaines les valeurs qui ne peuvent appartenir à aucune solution. Le critère le plus courant est la *cohérence d'arc* : pour toute contrainte  $c$  et toute variable  $x_i \in S(c)$ , on retire de  $d_{x_i}$  toute valeur  $v$  qui n'a aucun *support* dans les domaines des autres variables de  $c$  (c'est-à-dire telle qu'aucune affectation des autres variables ne satisfasse  $c$  avec  $v$ ). Sur le Sudoku, si une case d'une ligne contient 7, la propagation retire 7 du domaine de toutes les autres cases de la même ligne, de la même colonne et du même bloc.

**Recherche arborescente.** On affecte les variables une à une. À chaque nœud, le solveur choisit une variable et lui assigne une valeur de son domaine courant, puis propage. Si un domaine devient vide, le solveur *revient en arrière* (*backtrack*) sur le dernier choix et essaie une autre valeur. La recherche aboutit soit à une affectation complète cohérente (solution), soit à l'épuisement de toutes les branches (instance incohérente).

L'intérêt majeur du paradigme est qu'il n'est pas nécessaire d'écrire un algorithme spécifique à chaque problème : il suffit de formuler le modèle, puis d'invoquer un solveur traité comme une *boîte noire*. Dans ce travail, nous écrivons les modèles avec la bibliothèque Python PyCSP3 et nous les résolvons avec le solveur ACE (*Abstrcon Constraint Engine*) [?], qui sait énumérer l'ensemble des solutions d'une instance.

### 2.2.4 Contraintes en extension et contraintes globales

La possibilité de spécifier des contraintes de façon modulaire fait la force de la PPC. On distingue deux grandes familles particulièrement utiles dans la suite.

Une **contrainte en extension** (ou *de table*) liste explicitement les combinaisons de valeurs autorisées (ou interdites) pour sa portée : c’est exactement la relation  $R(c)$  donnée plus haut. C’est la forme naturelle pour encoder un catalogue de configurations admissibles, et c’est elle que nous utiliserons pour la *table de voisinage* chimique (section ??).

Une **contrainte globale** capture un motif récurrent sur un nombre arbitraire de variables, avec un *propagateur* spécialisé plus efficace que la décomposition en contraintes binaires. L’exemple typique est  $\text{allDifferent}(x_{i_1}, \dots, x_{i_q})$ , qui généralise les contraintes binaires de différence  $c_{i,j}$  de notre exemple du Sudoku (section ??) : sa portée est  $S(c) = \{x_{i_1}, \dots, x_{i_q}\}$  et sa relation

$$R(c) = \{ (v_{i_1}, \dots, v_{i_q}) \in d_{x_{i_1}} \times \dots \times d_{x_{i_q}} \mid v_{i_j} \neq v_{i_k} \text{ pour } j \neq k \}.$$

Cette contrainte est équivalente à  $\binom{q}{2}$  contraintes binaires de différence, mais son propagateur dédié élague l’espace de recherche de manière nettement plus efficace.

**Reformulation du Sudoku avec  $\text{allDifferent}$ .** Les contraintes binaires  $c_{i,j}$  du modèle précédent peuvent être factorisées par lignes, colonnes et blocs. Pour chaque ligne  $L_k$ , on remplace les  $\binom{9}{2} = 36$  contraintes binaires de différence par une seule contrainte globale  $\text{allDifferent}(x_i : x_i \in L_k)$ ; de même pour les colonnes et les blocs  $3 \times 3$ . On obtient ainsi un modèle équivalent avec 27 contraintes globales au lieu de plus de huit cents contraintes binaires, et la propagation est sensiblement plus efficace.

**Illustration de la résolution.** Reprenons la grille de Sudoku partiellement remplie de la figure ?. Au départ, la case  $x_1$  est connue :  $d_{x_1} = \{2\}$ . La propagation des contraintes  $\text{allDifferent}$  de la ligne  $L_1$ , de la colonne  $C_1$  et du bloc  $R_1$  contenant  $x_1$  retire alors 2 de tous les domaines des autres cases concernées. Si après propagation un domaine se réduit à un singleton, l’affectation correspondante est forcée et déclenche à son tour de nouvelles propagations. Lorsque la propagation seule ne suffit plus à compléter la grille, le solveur entre en recherche : il choisit une variable au domaine non encore singleton (par exemple  $x_4$  avec  $d_{x_4} = \{1, 5, 7\}$ ), affecte la première valeur ( $x_4 = 1$ ) et propage à nouveau. Si à un moment un domaine devient vide, la contradiction force un retour arrière et le solveur essaie la valeur suivante ( $x_4 = 5$ ). La recherche aboutit soit à une affectation complète et cohérente — une solution — soit à l’épuisement de toutes les branches, ce qui signifie que l’instance est incohérente.

La souplesse de la PPC, qui consiste à activer, désactiver ou ajouter une contrainte puis réénumérer rapidement les solutions, est un atout décisif pour un travail mené en dialogue continu avec les chimistes.

### 2.2.5 Isomorphisme de graphes

Comme une partie centrale de notre modélisation repose sur les automorphismes d’un graphe (rupture de symétrie en section ??), nous rappelons ici la notion d’*isomorphisme*, qui apparaît dans tout le mémoire.

**Définition 7** (Isomorphisme de graphes). *Deux graphes non orientés  $G = (V_G, E_G)$  et  $H = (V_H, E_H)$  sont dits **isomorphes** s’il existe une bijection  $f : V_G \rightarrow V_H$  qui préserve les arêtes, c’est-à-dire telle que*

$$\forall u, v \in V_G, \quad \{u, v\} \in E_G \iff \{f(u), f(v)\} \in E_H.$$

La bijection  $f$  est alors appelée un **isomorphisme** entre  $G$  et  $H$ . Si  $G = H$ , on parle d'**automorphisme** de  $G$  : c'est une permutation des sommets qui préserve les arêtes.

Intuitivement, deux graphes isomorphes sont « les mêmes » à un renommage des sommets près ; ils représentent la même structure abstraite. Pour notre problème, deux substitutions d'un benzénoïde qui diffèrent uniquement par un automorphisme du graphe dual correspondent à la même molécule, et seront comptées une seule fois. La rupture de symétrie (section ??) traite explicitement ce point.

### 3 Le problème

Maintenant que le vocabulaire est posé, nous pouvons énoncer précisément le problème et analyser ses deux sources de difficulté.

On part d'un benzénoïde  $B$  à  $n_H(B)$  hexagones, représenté par son graphe dual  $G_D$ . Une **substitution** affecte à chaque hexagone  $v$  une taille de cycle  $x_v \in \{5, 6, 7\}$  : conserver l'hexagone ( $x_v = 6$ ), le contracter en pentagone ( $x_v = 5$ ) ou le dilater en heptagone ( $x_v = 7$ ). La substitution doit satisfaire les deux contraintes suivantes :

- **conservation du graphe dual** : les arêtes partagées entre cycles voisins sont préservées, donc  $G_D$  reste identique avant et après transformation. C'est un point essentiel de la modélisation : elle garantit que chaque cycle de la solution correspond *exactement* à un hexagone du benzénoïde de départ, ce qui sera exploité pour exprimer simplement la conservation des atomes en section ?? ;
- **conservation du nombre total d'atomes de carbone**.

On cherche à **énumérer toutes les substitutions admissibles**, c'est-à-dire toutes celles qui correspondent à une molécule chimiquement et géométriquement réalisable, à *isomorphisme* près : deux substitutions identiques à une symétrie du benzénoïde de départ décrivent la même molécule et ne sont comptées qu'une seule fois (la notion d'isomorphisme est définie en section ??).

#### 3.1 La difficulté combinatoire

Avec trois valeurs possibles par hexagone, un benzénoïde à  $n_H(B)$  hexagones admet a priori  $3^{n_H(B)}$  substitutions. Ce nombre croît exponentiellement, et la grande majorité de ces affectations ne correspondent à *aucune* molécule valide : elles violent la conservation du carbone, ou décrivent des voisinages localement impossibles à reconstruire. Énumérer naïvement puis filtrer est donc hors de portée dès que  $n_H(B)$  dépasse quelques unités. C'est exactement le type de problème fortement combinatoire pour lequel la PPC est conçue : on encode les conditions d'admissibilité comme des contraintes, et le solveur n'explore que les affectations cohérentes.

#### 3.2 La difficulté géométrique et topologique

La seconde difficulté est de nature différente, et c'est la plus profonde. Dans un benzénoïde, tous les cycles sont des hexagones réguliers d'angle interne  $120^\circ$ , et le pavage est plan par construction. Dès que l'on introduit des pentagones (angle interne  $108^\circ$ ) et des heptagones (environ  $128,6^\circ$ ), plusieurs grandeurs cessent d'être fixées :

- les **angles** aux sommets ne se complètent plus à  $360^\circ$ , ce qui crée une courbure locale ;
- les **distances** inter-atomiques et les longueurs de liaison s'ajustent pour relâcher les tensions ;
- la **topologie** de fusion impose que les cycles voisins partagent exactement une arête, ce qui n'est pas toujours réalisable selon la disposition des voisins ;
- la **planéité** qui en résulte n'est pas garantie : la molécule peut se courber ou onduler pour minimiser son énergie.

Le point crucial est que la planéité est une propriété *globale* : elle dépend de l’agencement de tous les défauts à la fois, et ne se déduit pas seulement des voisinages locaux. On peut filtrer localement les configurations manifestement irréalisables, mais on ne peut pas, par des contraintes locales seules, garantir qu’une molécule entière sera plane. Cette limite est *intrinsèque au problème*. Elle motive l’architecture en deux temps de notre travail : un modèle PPC qui énumère les candidats en appliquant les conditions *exprimables* (section ??), suivi d’une validation physique qui tranche la planéité *réelle* de chaque candidat (section ??). Et elle motive l’étude expérimentale (section ??), qui cherche les contraintes améliorant au mieux le rendement de planéité.

## 4 Modélisation

Nous présentons à présent le modèle PPC qui énumère les substitutions admissibles. Il comporte une variable par hexagone et un ensemble de contraintes *structurelles*, toujours actives, que nous décrivons ici. Les contraintes *additionnelles*, qui font l’objet de l’étude expérimentale, sont introduites à la section ??.

### 4.1 Variables et domaines

À chaque hexagone  $v$  du graphe dual on associe une variable  $x_v$  donnant la taille du cycle substitué :

$$x_v \in \{5, 6, 7\}, \quad v \in V_D.$$

Toutes les variables ont initialement le même domaine  $\{5, 6, 7\}$ . Le prétraitement décrit en section ?? (contrainte C2) réduira ce domaine à  $\{6\}$  pour certains hexagones, dits *gelés*, en fonction de leur position dans le graphe dual.

### 4.2 Contraintes

Cette sous-section regroupe les contraintes du modèle. C1, C2.1, C3 et C4 sont actives par défaut. C2.2 et C5 sont optionnelles : leur effet est étudié expérimentalement à la section ??.

#### 4.2.1 C1 — Conservation du carbone

Le nombre total d’atomes de carbone doit être préservé par la substitution. Notons  $n_H = n_H(B)$  le nombre d’hexagones du benzénoïde  $B$  de départ, et  $n_5$ ,  $n_6$ ,  $n_7$  les nombres respectifs de pentagones, hexagones et heptagones dans la solution. Tout cycle de la solution remplace exactement un hexagone du benzénoïde de départ, donc

$$n_5 + n_6 + n_7 = n_H.$$

Pour exprimer la conservation du carbone, comptons explicitement les atomes de carbone de chaque côté. Soit  $a = |E_D|$  le nombre d’arêtes du graphe dual  $G_D$  du benzénoïde de départ (chaque arête correspond à deux hexagones partageant une arête carbone-carbone, et donc deux atomes communs). Le nombre total d’atomes de carbone du benzénoïde de départ vaut

$$N(B) = 6n_H - 2a,$$

puisque chaque hexagone contient 6 atomes et que chaque arête commune correspond à 2 atomes comptés en double.

Après substitution, la solution comporte  $n_5$  pentagones,  $n_6$  hexagones et  $n_7$  heptagones, soit  $5n_5 + 6n_6 + 7n_7$  atomes avant correction. La **conservation du graphe dual** (section ??) garantit que **le nombre d’arêtes communes reste  $a$** , donc le nombre total d’atomes de la solution vaut

$$N(\text{solution}) = 5n_5 + 6n_6 + 7n_7 - 2a.$$

Conserver le nombre d'atomes ( $N(\text{solution}) = N(B)$ ) donne donc

$$5n_5 + 6n_6 + 7n_7 - 2a = 6n_H - 2a,$$

et le terme  $-2a$  se simplifie de part et d'autre. On obtient ainsi directement

$$\boxed{\sum_{v \in V_D} x_v = 5n_5 + 6n_6 + 7n_7 = 6n_H,}$$

qui est l'expression effectivement déclarée au solveur : une simple contrainte de somme sur les variables entières.

Combinée à  $n_5 + n_6 + n_7 = n_H$ , cette équation équivaut à  $n_5 = n_7$ , qui s'interprète chimiquement : chaque pentagone retire un atome de carbone et doit être compensé par un heptagone qui en ajoute un.

#### 4.2.2 C2 — Hexagones gelés (réduction de domaine)

Avant même la résolution proprement dite, un *prétraitement* — c'est-à-dire une première passe de **filtrage** au sens de la section ?? — réduit le domaine de certaines variables à  $\{6\}$  en exploitant la structure locale du graphe dual. Pour chaque hexagone  $v$ , on définit son **motif d'occupation**  $\sigma(v) = (\sigma_0, \dots, \sigma_5) \in \{0, 1\}^6$ , où  $\sigma_i = 1$  si le  $i$ -ème côté de  $v$  est partagé avec un voisin, et 0 s'il est libre. On note  $b(v)$  le nombre de *blocs* de côtés libres consécutifs (sur le cycle des six côtés). La contrainte C2 se décompose en deux conditions de gel, l'une stricte et toujours active, l'autre optionnelle.

**C2.1 — hexagones de degré 6.** Si  $\deg_{G_D}(v) = 6$ , l'hexagone  $v$  est entouré de six voisins et n'a aucun côté libre. Il ne peut donc ni se contracter (aucun sommet à supprimer sans casser un côté partagé), ni se dilater (aucun bloc libre où insérer un sommet). On impose  $x_v = 6$ . Ce gel est une conséquence topologique stricte, sans alternative.

**C2.2 — blocs libres fragmentés.** Si  $b(v) \geq 2$ , les côtés libres de  $v$  sont répartis en plusieurs blocs disjoints sur le cycle. Notons que la simple connaissance du *nombre* d'arêtes périphériques d'un hexagone — au sens de l'étiquetage de Brinkmann repris par Varet [?] pour distinguer les benzénoïdes partageant le même graphe dual intérieur — ne suffit pas à caractériser cette situation : c'est la *disposition* des côtés libres (un bloc continu ou plusieurs blocs séparés) qui détermine la faisabilité d'une substitution.

La transformation n'est pas *impossible*, mais elle n'est plus unique : on doit choisir où placer l'arête périphérique supplémentaire introduite par le septième sommet, et chaque choix produit un benzénoïde distinct au sens de Brinkmann. La figure ?? illustre cet enjeu sur un motif tiré de la figure 2.14 de la thèse de Varet [?] : un anthracène dont l'hexagone central est étiqueté 2+2 (deux blocs périphériques de deux arêtes, en haut et en bas) admet deux substitutions distinctes par un heptagone, l'une ajoutant une arête périphérique en bas (étiquetage 2+3), l'autre en haut (3+2).

On impose donc  $x_v = 6$  *par défaut* pour ces hexagones, ce qui revient à interdire l'ambiguïté de transformation introduite par les blocs libres multiples. Cette restriction est désactivable lorsqu'on souhaite explorer des géométries où l'on accepte de modifier l'étiquetage des voisins, par exemple pour étudier l'effet de relâcher cette contrainte dans les expériences de la section ??.

Les hexagones qui ne sont gelés par aucune des deux règles sont dits *libres* et conservent le domaine  $\{5, 6, 7\}$ .

#### 4.2.3 C3 — Voisinage admissible et table de voisinage

C'est le cœur du filtrage chimique. Pour chaque hexagone libre  $v$ , on impose que la configuration locale formée par  $v$  et ses voisins soit *réalisable*. Cette condition est encodée par une




FIGURE 9 – Anthracène et transformation du cycle central en heptagone.

**contrainte en extension** : le tuple ordonné

$$\tau_v = (x_v, x_{u_1}, x_{u_2}, \dots, x_{u_k}),$$

où  $u_1, \dots, u_k$  sont les voisins de  $v$  dans  $G_D$  pris dans l'ordre cyclique, doit appartenir à une **table de voisinage**  $\mathcal{T}$  pré-calculée. Le degré  $k$  de  $v$  dans le graphe dual est compris entre 2 et 6 (un hexagone a au plus six côtés partagés), ce qui donne à  $\tau_v$  une longueur  $|\tau_v| = k + 1 \in \{3, 4, 5, 6, 7\}$ . Le cas  $k = 0$  (un hexagone isolé sans voisin) n'est pas considéré, et le cas  $k = 1$  est traité séparément ci-dessous.

Un point essentiel distingue notre table de celle des benzénoïdes purs : elle est *sensible à la disposition* des voisins. Deux configurations ayant les mêmes tailles de voisins mais disposées différemment autour du cycle central ne sont pas équivalentes, car elles ne se reconstruisent pas de la même manière en trois dimensions. La position des voisins est donc encodée explicitement dans les tuples de la table (un 0 marquant un côté libre).

La table est **construite hors-ligne** : on énumère les configurations locales candidates (un cycle central entouré de voisins de tailles données dans une disposition donnée), on reconstruit chacune en 3D, on l'optimise par xTB, et on ne retient que celles qui sont planes (au sens du critère décrit en section ??). Ce catalogue est *paramétrable* : il pourra être régénéré ou affiné lorsque de nouvelles études chimiques préciseront les critères d'admissibilité. La version utilisée dans ce travail comporte **721** entrées au total, réparties selon la taille du cycle central :

|                  | $\mathcal{T}(5)$ | $\mathcal{T}(6)$ | $\mathcal{T}(7)$ |
|------------------|------------------|------------------|------------------|
| Nombre d'entrées | 63               | 291              | 367              |

**Remarque 4.** Un hexagone de degré 1 (un seul voisin) n'a pas besoin de contrainte de table : un cycle accolé à un unique voisin par une arête est toujours réalisable, quelle que soit sa taille.

#### 4.2.4 C4 — Rupture de symétrie

Deux substitutions qui ne diffèrent que par une symétrie du benzénoïde décrivent la *même* molécule. Pour ne les compter qu'une fois, on exploite le groupe des automorphismes du graphe



dual,  $\text{Aut}(G_D)$  (les permutations des sommets qui préservent les arêtes), dont on calcule un ensemble générateur  $\{\pi_1, \dots, \pi_m\}$ . Pour chaque générateur  $\pi$ , on impose une contrainte *lex-leader*

$$(x_0, x_1, \dots, x_{h-1}) \leq_{\text{lex}} (x_{\pi(0)}, x_{\pi(1)}, \dots, x_{\pi(h-1)}),$$

qui ne retient, dans chaque orbite de solutions équivalentes, que le représentant minimal pour l'ordre lexicographique. Cette technique élimine les doublons et réduit fortement l'espace de recherche. Sa validité repose sur l'unicité du plongement planaire des graphes considérés (théorème de Whitney [?] et 2-connexité des benzénoïdes).

#### 4.2.5 C5 — Adjacence 5–7 (motif azulène)

Cette contrainte est une piste d'amélioration explorée à la section ??; elle n'est pas active par défaut. L'idée chimique sous-jacente est la suivante : remplacer un motif 6–6 (deux hexagones accolés, comme dans le naphthalène) par un motif 5–7 (un pentagone et un heptagone accolés, comme dans l'azulène, voir figure ??) *préserve* le compte d'atomes de carbone ( $5 + 7 = 6 + 6 = 12$ , moins 2 pour l'arête partagée, donc 10 dans les deux cas) et conserve le nombre total d'électrons  $\pi$  (10 électrons, soit  $4n + 2$  avec  $n = 2$ , dans les deux motifs : la règle de Hückel reste satisfaite). Le motif 5–7 apparaît donc comme un *substitut isoélectronique* naturel du motif 6–6, et il est connu en chimie pour préserver la planéité localement, là où un pentagone ou un heptagone isolé introduit une courbure.




FIGURE 10 – Motif 5–7 fusionné (azulène).

Pour chaque sommet  $v$  du graphe dual, notons

$$\mathcal{N}(v) = \{u \in V_D \mid (u, v) \in E_D\}$$

l'ensemble des voisins de  $v$  dans  $G_D$ . La contrainte C5 traduit alors l'idée chimique dans le modèle PPC sous la forme *tout pentagone a au moins un heptagone parmi ses voisins, et tout heptagone a au moins un pentagone parmi les siens* :

$$\forall v \in V_D, \quad (x_v = 5 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 7) \wedge (x_v = 7 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 5).$$

Cette contrainte est purement *locale*, mais sa motivation est globale : en imposant que tout défaut 5 ou 7 soit immédiatement compensé par un défaut opposé, on espère préserver la planéité d'ensemble. Son efficacité réelle est mesurée expérimentalement.

### 4.3 Résolution

Le modèle est écrit en PYCSP3, puis compilé au format standard XCSP3. Selon les options choisies par l'utilisateur, il inclut les contraintes suivantes :

- **actives par défaut** : C1 (conservation du carbone), C2.1 (gel des hexagones de degré 6), C3 (voisinage admissible) et C4 (rupture de symétrie) ;
- **optionnelles** : C2.2 (gel des hexagones à blocs libres fragmentés, activée par défaut mais désactivable) et C5 (adjacence 5–7, désactivée par défaut, étudiée à la section ??).

Le solveur ACE est ensuite invoqué pour **énumérer toutes les solutions** de l'instance ainsi configurée. Chaque solution est un vecteur de tailles  $(x_0, \dots, x_{h-1})$  qui sera, à l'étape suivante, reconstruit en une molécule tridimensionnelle puis validé.

## 5 Réalisation : des solutions du modèle aux molécules validées et analysées

Le modèle de la section ?? produit des *vecteurs de tailles*  $(x_0, \dots, x_{h-1})$  : des objets abstraits. Cette section décrit comment on en fait des molécules réelles, comment on décide de leur planéité, et comment on analyse leurs propriétés électroniques. Elle regroupe l'essentiel du travail d'implémentation.

### 5.1 Reconstruction 3D, validation et test de planéité

Cette sous-section décrit, en trois temps, comment on passe d'un vecteur de tailles abstrait à une molécule physiquement validée : la reconstruction 3D produit une géométrie initiale, la validation xTB la fait converger vers son équilibre énergétique, et un test géométrique sur la géométrie optimisée tranche la planéité.

#### 5.1.1 Reconstruction 3D des solutions

Chaque solution du modèle est un vecteur de tailles  $(x_0, \dots, x_{h-1})$  indiquant la taille assignée à chaque hexagone. Pour en faire une molécule tridimensionnelle exploitable, on procède en trois phases : modification topologique du graphe carbone, placement géométrique des sommets, puis assemblage en molécule (liaisons doubles et hydrogènes).

**Modifications topologiques du graphe carbone.** En partant du graphe carbone (défini en section ??) du benzénoïde d'entrée, lorsque la solution affecte une taille  $x_v \neq 6$  à un hexagone  $v$ , il faut transformer ce cycle en un pentagone ou un heptagone *sans* perturber les arêtes partagées avec ses voisins.

**Repérage des côtés libres.** Rappelons que le motif d'occupation  $\sigma(v) \in \{0, 1\}^6$  indique pour chacun des six côtés du cycle s'il est partagé avec un voisin ( $\sigma_i = 1$ ) ou *libre* ( $\sigma_i = 0$ ). Les modifications topologiques opèrent exclusivement sur les sommets adjacents à des côtés libres ; les sommets attenants à au moins un côté partagé sont *gelés*, sans quoi la modification briserait la fusion avec un voisin.

**Contraction en pentagone** ( $x_v = 5$ ). On supprime un sommet du cycle parmi les sommets libres, en privilégiant celui qui se trouve au milieu d'un bloc de côtés libres consécutifs ; ses deux voisins dans le cycle sont alors reliés directement, réduisant le cycle de six à cinq sommets. Le choix du sommet à supprimer est unique lorsque l'hexagone possède un seul bloc libre (cas garanti par la condition  $b(v) \leq 1$  pour les hexagones non gelés, section ??).

**Dilatation en heptagone** ( $x_v = 7$ ). On insère un nouveau sommet entre deux sommets libres consécutifs (au milieu du bloc libre), ce qui ajoute une arête au cycle et le porte à sept sommets.

**Effet sur les voisins.** Une fois le cycle modifié, sa nouvelle séquence ordonnée de sommets est conservée dans la structure de données du graphe carbone afin que les cycles voisins continuent à le référencer correctement via leurs sommets partagés.

**Placement géométrique.** Une fois la topologie fixée (chaque cycle connaît sa liste ordonnée de sommets), il reste à attribuer à chaque sommet une position dans le plan. L'idée est de poser chaque cycle comme un *polygone régulier* de longueur de côté  $\ell = 1,4 \text{ \AA}$  (longueur typique d'une liaison carbone-carbone), en respectant les contraintes de partage d'arête entre cycles adjacents.

**Rayon des cycles.** Le rayon  $r_n$  du cercle circonscrit à un polygone régulier de  $n$  côtés de longueur  $\ell$  vaut

$$r_n = \frac{\ell}{2 \sin(\pi/n)}.$$

Pour  $\ell = 1,4 \text{ \AA}$  (longueur typique d'une liaison carbone-carbone dans un benzénoïde), on obtient  $r_5 \approx 1,19 \text{ \AA}$ ,  $r_6 \approx 1,40 \text{ \AA}$ ,  $r_7 \approx 1,61 \text{ \AA}$ .

**Parcours en largeur du graphe dual.** Le placement s'effectue par un parcours en largeur (*BFS*) du graphe dual  $G_D$  à partir d'un cycle **ancre** — choisi de plus haut degré, ce qui maximise les contraintes immédiates de partage et stabilise la géométrie. Le cycle ancre est dessiné centré à l'origine, dans une orientation canonique. Chaque cycle suivant est placé *relativement à un parent déjà placé*, via l'arête  $e = \{a, b\}$  qu'ils partagent.

**Positionnement d'un cycle enfant.** Soit  $c$  un cycle à placer, parent  $p$ , arête partagée  $\{a, b\}$  déjà positionnée aux coordonnées  $\mathbf{x}_a, \mathbf{x}_b$ . Le placement s'effectue alors en quatre étapes décrites par l'algorithme ??.

---

**Algorithme 1** Positionnement d'un cycle enfant relativement à son parent.

---

**Entrée :** cycle  $c$  de taille  $n_c$ , parent  $p$  déjà placé, arête  $\{a, b\}$  partagée

**Sortie :** positions des sommets de  $c$  dans le plan

```

m ← (x_a + x_b) / 2                                ; milieu de l'arête partagée
a_{n_c} ← r_{n_c} · cos(π / n_c)                    ; apothème du polygone régulier
n ← vecteur unitaire ⊥ {a, b}, opposé au parent p
centre_c ← m + a_{n_c} · n
// répartir les n_c-2 sommets restants sur le cercle
pour i de 1 à n_c - 2 :
    θ_i ← angle du i-ème sommet (depuis a vers b, hors parent)
    x_i ← centre_c + r_{n_c} · (cos θ_i, sin θ_i)

```

---

Le choix de l'orientation de la normale par rapport au parent (étape 3 de l'algorithme) garantit que la structure ne se replie pas sur elle-même : chaque cycle enfant est posé du *bon côté* de son arête de fusion. Lorsqu'un cycle a plusieurs parents déjà placés (cas de cycles internes au benzénoïde), seul le premier rencontré dans le BFS est utilisé pour le placer, et les positions imposées par les autres parents sont vérifiées *a posteriori* pour cohérence ; la topologie en amont garantit qu'elles coïncident dans la limite des polygones réguliers.

**Algorithme global.** L'algorithme complet de placement, qui orchestre le parcours en largeur du graphe dual et appelle l'algorithme ?? sur chaque cycle non encore placé, est donné par l'algorithme ??.

**Assemblage moléculaire.** Une fois tous les sommets placés en 2D (avec  $z = 0$ ), il reste à transformer la géométrie en une véritable molécule. On effectue trois opérations successives.

**Liaisons doubles.** On calcule un *couplage de cardinalité maximale* sur le graphe carbone par l'algorithme de Blossom [?], et chaque arête du couplage est marquée comme liaison double. Les carbones non couverts par le couplage sont les sites radicalaires.

---

**Algorithme 2** Placement géométrique global par parcours en largeur du graphe dual.

---

placer le cycle ancre à l'origine, orienté canoniquement

file  $\leftarrow$  [ancre]

tant que file non vide :

    c  $\leftarrow$  file.popleft()

    pour chaque voisin v de c dans GD, non encore placé :

        {a, b}  $\leftarrow$  arête partagée entre c et v

        positionner v par l'algorithme ?? (parent = c)

        file.append(v)

---

**Ajout des hydrogènes.** Tout carbone du bord, c'est-à-dire de degré 2 dans le graphe carbone, possède une valence libre : on lui attache un atome d'hydrogène, placé radialement vers l'extérieur du cycle auquel il appartient, à une distance de 1,088 Å (longueur typique de la liaison C–H).

**Export.** La géométrie complète (carbones et hydrogènes, avec coordonnées) est exportée au format XYZ (un format parmi d'autres de représentation de molécule), lisible par xTB.

La géométrie ainsi produite est *plane par construction* : tous les atomes sont dans le plan  $z = 0$ . C'est l'étape de validation xTB (section suivante) qui révélera si la molécule est réellement plane à l'équilibre, ou si l'optimisation la fait quitter le plan.

### 5.1.2 Validation par xTB : protocole d'optimisation déterministe

L'optimisation xTB procède par descente de gradient. Si la géométrie initiale est parfaitement plane, l'optimiseur reste piégé dans un **minimum plat parasite**. Pour briser cette symétrie de façon reproductible, nous appliquons une **perturbation analytique déterministe** aux coordonnées  $z$  avant toute optimisation : la perturbation est une fonction pure des indices atomiques, sans tirage aléatoire, ce qui rend l'ensemble du pipeline *byte-déterministe*. La formule, la commande `xtb -opt tight` et tous les détails techniques sont donnés en annexe ??.

### 5.1.3 Test de planéité

Une fois la géométrie optimisée par xTB, il reste à décider si la molécule est plane. Nous utilisons deux métriques complémentaires, dont seule la seconde sert au verdict final.

**Métrique géométrique globale (ACP).** La première métrique, implémentée dès les premières versions du pipeline, applique une **analyse en composantes principales** aux positions des carbones, calcule la normale du plan moyen, et pour chaque cycle l'angle de gauchissement entre la normale locale du cycle et la normale globale. La quantité retenue, `max_angle_deg`, est le maximum de ces angles sur tous les cycles. Cette métrique donne une image globale de la courbure : une molécule en cuvette ou en selle produit un `max_angle_deg` élevé. Les détails techniques (diagonalisation de la covariance, formules) sont en annexe ??.

**Métrique chimique locale (angles dièdres).** En discussion avec les chimistes (Denis Hagebaum-Reignier, Yannick Carissan), nous avons constaté que la métrique précédente capturait bien la *courbure d'ensemble* mais surestimait l'écart à la planéité du système  $\pi$ , qui n'est sensible qu'à des déformations *localisées entre liaisons voisines*. Nous calculons donc, pour chaque suite de quatre atomes de carbone  $A-B-C-D$  tous connectés par des liaisons covalentes consécutives (trois liaisons en chaîne), l'angle dièdre signé  $\varphi(A, B, C, D) \in (-180^\circ, 180^\circ]$ . Pour une molécule strictement plane, chaque dièdre vaut  $0^\circ$  ou  $\pm 180^\circ$  : l'écart au plan est donc  $\delta(\varphi) = \min(|\varphi|, 180^\circ - |\varphi|) \in [0, 90^\circ]$ . La métrique retenue est le maximum :

$$\text{max\_dihedral\_deg} = \max_{A-B-C-D} \delta(\varphi(A, B, C, D)).$$

**Critère de décision (verdict final).** Sur recommandation des chimistes, la classification adopte *trois niveaux* plutôt qu'un seuil binaire, le seuil exact étant difficile à fixer dans l'absolu et dépendant de chaque système :

|                                                      |                           |
|------------------------------------------------------|---------------------------|
| $\text{max\_dihedral\_deg} < 10^\circ$               | $\Rightarrow$ très plan,  |
| $10^\circ \leq \text{max\_dihedral\_deg} < 25^\circ$ | $\Rightarrow$ acceptable, |
| $\text{max\_dihedral\_deg} \geq 25^\circ$            | $\Rightarrow$ non plan.   |

Chaque solution reçoit ainsi un verdict parmi TRÈS PLAN, ACCEPTABLE, NON PLAN ou ÉCHEC xTB. La plage intermédiaire « acceptable » reflète l'avis chimique : même avec un dièdre maximal de  $20^\circ$ , le composé reste raisonnable chimiquement (encore conjugué, encore stable). Les statistiques aux deux seuils  $10^\circ$  et  $25^\circ$  sont reportées séparément à la section ??, comme suggéré par les chimistes pour distinguer les molécules *légèrement* déformées (entre  $10^\circ$  et  $25^\circ$ ) de celles *fortement* déformées ( $\geq 25^\circ$ ).

## 5.2 Analyse électronique des structures

Une fois les structures planes obtenues, nous avons développé un outil pour en étudier les propriétés électroniques. Ces analyses sont *statiques* : elles opèrent directement sur le graphe carbone (sans nouveau calcul quantique) et sont donc quasi instantanées.

**Modèle CSP  $\mathcal{M}_K$  pour les structures de Kekulé.** On associe une variable booléenne  $x_e \in \{0,1\}$  à chaque liaison  $e \in E$  du graphe carbone ( $x_e = 1$  signifie liaison double). La contrainte unique est :

$$\sum_{e \in \delta(v)} x_e = 1, \quad \forall v \in V. \quad (\text{C-Kek})$$

L'énumération de toutes les solutions de  $\mathcal{M}_K$  produit l'intégralité des structures de Kekulé. Pour les molécules sans couplage parfait (graphe carbone à nombre impair de sommets ou topologie radicalaire — cas fréquent avec des cycles à 5 ou 7), on relaxe l'égalité en inégalité et l'on maximise  $\sum x_e$  ; les atomes non couverts à l'optimum sont les *sites radicalaires*.

[Capture du visualiseur en mode Kekulé — à insérer]

FIGURE 11 – Visualiseur des structures de Kekulé.

**Modèle CSP  $\mathcal{M}_C$  pour les couvertures de Clar.** On étend  $\mathcal{M}_K$  avec une variable booléenne  $y_h \in \{0,1\}$  par hexagone ( $y_h = 1$  signifie que  $h$  porte un sextet de Clar). La contrainte unifiée par atome est :

$$\sum_{e \in \delta(v)} x_e + \sum_{h \in \mathcal{H} : v \in V(h)} y_h = 1, \quad \forall v \in V, \quad (\text{C-Clar})$$

et l'on maximise  $Z = \sum_{h \in \mathcal{H}} y_h$ . Cette contrainte capture simultanément la vertex-disjonction des sextets (deux sextets partageant un atome violeraient l'égalité à 1) et le couplage parfait du résidu (tout atome hors sextet doit être couvert par exactement une double liaison). En posant  $y_h = 0$  pour tout  $h$ , on retrouve  $\mathcal{M}_K$  comme cas particulier. Pour les structures radicalaires, on relaxe (C-Clar) en inégalité et l'on utilise un objectif lexicographique : minimiser d'abord le nombre de radicaux, puis maximiser  $Z$ .




FIGURE 12 – Visualiseur en mode Clar.

**Extension du RBO aux cycles 5 et 7.** La définition de Pauling–Randić [?], reprise par Varet, ne concerne que les hexagones. Notre contribution est de conserver la formule  $\text{CBO}(C) = \sum_{e \in C} \text{bo}(e)$  *sommée sur tout cycle quelle que soit sa taille*, en affichant le ratio  $\text{CBO}/\text{cbo}_{\max}$  pour rester fidèle au contexte. Le cas radicalaire (aucune Kekulé stricte) n'est pas défini au sens de Pauling–Randić.




FIGURE 13 – Visualiseur en mode RBO.

**Remarque 5** (Alignement avec la littérature). *Ce modèle coïncide avec celui de **pah-tools** et de BenzAI [?] pour les benzénoïdes. Notre apport est l'extension aux cycles impairs (5 et 7) via la relaxation radicalaire de (C-Clar) et le CBO normalisé : les outils existants imposent  $\mathcal{H} = \text{hexagones}$  uniquement et ne définissent pas le cas sans couplage parfait.*

### 5.3 Le designer : interface et pipeline intégré

L'ensemble des étapes décrites jusqu'ici — modèle PPC, reconstruction 3D, validation xTB, test de planéité, analyse électronique — est intégré dans une application web unique, le *designer*, qui sert à la fois d'interface d'utilisation et d'infrastructure de campagne expérimentale. Cette sous-section en donne un aperçu fonctionnel et détaille l'environnement technique (versions, machines, garanties de reproductibilité).

### 5.3.1 Saisie de l'instance

Un canevas hexagonal en SVG permet à l'utilisateur de *dessiner* un benzénoïde de départ : on clique sur les hexagones du pavage pour les sélectionner, et le graphe dual sous-jacent est construit à la volée. La saisie peut aussi se faire par *importation* : un benzénoïde déjà enregistré dans la base BenzDB (ou venant d'un fichier au format texte adapté) peut être chargé directement, ce qui est utile pour rejouer une campagne sur un corpus déjà fixé.




FIGURE 14 – Designer en mode saisie : canevas hexagonal pour dessiner un benzénoïde ou choisir un benzenoïde importé depuis BenzDB.

### 5.3.2 Configuration des contraintes et exécution

Une fois l'instance posée, l'utilisateur configure le solveur depuis un panneau organisé en deux onglets. L'onglet **Préréglage** propose quatre configurations canoniques, sélectionnables d'un clic, qui correspondent exactement aux configurations étudiées expérimentalement (section ??) :

- **C1 — Baseline** : contraintes structurelles uniquement (C1+C2.1+C3+C4).
- **C2 — Pb1 + adj\_57** : C1 plus pentagones plafonnés au bord et appariement Stone–Wales obligatoire.
- **C3 — Pb1 + adj\_57 + pas de 7–7 adjacents** : durcissement local de la courbure (Gauss–Bonnet locale à zéro dans un rayon de 2 dans  $G_D$ ).
- **Ctopo — Topologie complète** : C3 plus une blacklist de motifs de rayon 2 du graphe dual et un pré-filtre exigeant un squelette compact (au moins 4 atomes péri-condensés). Recommandé pour les grands squelettes ( $h_9$ ).

L'onglet **Avancé** expose individuellement chaque flag (Pb1, adj\_57, tau\_gb, ctopo\_filter, etc.) pour les expérimentations fines.

Un second panneau gère la **validation xTB**. Le mode par défaut est *skip xTB* : le pipeline s'arrête après la reconstruction 3D et produit directement les géométries planes (non optimisées), ce qui est très rapide et suffit pour visualiser les sorties du CSP. Pour valider la planéité physique, l'utilisateur bascule sur *det-opt* (le protocole déterministe décrit section ??), ou plus rarement sur les modes *md* et *multi-runs* conservés pour comparaison historique. Une option permet aussi de comparer la planéité des solutions à celle du benzénoïde d'entrée pur (tout-hexagones).

Le lancement d'une génération orchestre, derrière l'interface, l'ensemble du pipeline : compilation du modèle en XCSP3, appel à ACE, reconstruction 3D des solutions, validation xTB (si demandée), test de planéité par ACP et calcul des métriques électroniques. Les résultats — solutions, géométries XYZ compressées, statistiques par campagne — sont persistés dans une base SQLite, ce qui rend chaque campagne facilement rejouable et comparable. Les exécutions sur le grand corpus ( $h \geq 7$ , jusqu'à plusieurs milliers de squelettes) sont distribuées sur le cluster décrit ci-dessous.


### 5.3.3 Exploration des solutions et visualiseur intégré

Une fois une campagne terminée, le designer présente l'ensemble des solutions produites sous forme d'une **liste paginée** (figure ??). Chaque ligne récapitule les caractéristiques d'une solution : identifiant, composition ( $n_5, n_6, n_7$ ), verdict de planéité, angle maximal hors-plan, et distances quadratique / extrême au plan moyen.

Plusieurs leviers facilitent l'exploration :

- **Tri** sur n'importe quelle colonne (angle croissant ou décroissant, identifiant, etc.) ;
- **Filtrage** par verdict de planéité (PLAN, NON-PLAN, géométrie infaisable, échec xTB), par sous-chaîne de la composition, ou par squelette de départ ;
- navigation directe vers le **visualiseur 3D** d'une solution donnée pour inspecter sa géométrie en relief, lire ses structures de Kekulé, ses couvertures de Clar et ses RBO/CBO (section ??).

Le visualiseur, intégré à la même application web, est aussi accessible indépendamment du designer pour explorer la base de résultats du run final ( $\sim 1,5$  M de solutions sur  $h_3$ – $h_9$ ). Il sert à la fois d'outil d'exploration pour les chimistes et de banc de débogage pour le développement (vérifier en 3D qu'une géométrie produite par le pipeline ressemble à ce que l'on attend).



[Capture de la liste des solutions dans le designer — à insérer]

FIGURE 15 – Liste des solutions avec tri et filtrage.

## 6 Étude expérimentale : quelles contraintes améliorent la planéité ?

Comme établi en section ??, la planéité est une propriété globale qu'aucun jeu de contraintes locales ne capture exactement. La question pratique devient alors : *quelles contraintes additionnelles augmentent le plus la proportion de molécules planes parmi celles que le modèle génère ?* Nous y répondons par une étude comparative de quatre configurations **C**<sub>1</sub>, **C**<sub>2</sub>, **C**<sub>3</sub> et **C**<sub>topo</sub>, des plus simples aux plus contraintes, qui isolent successivement chaque levier identifié.

### 6.1 Protocole et banc d'essai

Le banc d'essai utilise les squelettes benzénoïdes canoniques de la base *BenzDB*, de  $h_3$  à  $h_9$  hexagones (tableau ??). La métrique principale est la **distribution des verdicts dièdres** définis section ?? : pour chaque configuration, on reporte la proportion de solutions **très planes** (**TP**, dièdre maximal  $< 10^\circ$ ) et **plan acceptable** (**A**, dièdre maximal  $< 25^\circ$ , *cumulatif* : la colonne A inclut toutes les solutions très planes), complétée par le *nombre absolu*  $N$  de solutions générées (souvent plus parlant pour l'aval, qui s'intéresse au nombre de candidats exploitables). Le complément à 100 % de la colonne A donne la proportion de solutions NON PLANES (dièdre  $\geq 25^\circ$ ). La distinction **TP** *vs.* **A** suit la recommandation des chimistes (Denis Hagebaum-Reignier) : un



dièdre maximal entre 10 et 25° correspond à une molécule *légèrement* déformée qui reste chimiquement raisonnable, à distinguer d’une planéité quasi parfaite. Les campagnes sont reproductibles (validation *det-opt*, section ??), agrégées en base SQLite, et chaque configuration de contraintes est comparée terme à terme aux autres sur le même corpus.

| $h$                  | $h_3$ | $h_4$ | $h_5$ | $h_6$ | $h_7$ | $h_8$ | $h_9$ |
|----------------------|-------|-------|-------|-------|-------|-------|-------|
| nombre de squelettes | 3     | 6     | 16    | 44    | 126   | 376   | 2 418 |

TABLE 1 – Nombre de squelettes benzénoïdes du corpus par taille  $h$ , issue de BenzDB.

## 6.2 Environnement logiciel et reproductibilité

La reproductibilité des expériences est une garantie centrale du pipeline : un même fichier d’entrée et une même configuration de contraintes doivent produire le *même* résultat, indépendamment de la machine ou de la date d’exécution.

**Stack logicielle.** Le pipeline est écrit en **Python 3.14.4**, aligné entre le poste de développement (Windows 11) et l’environnement **conda** du cluster. Les bibliothèques utilisées et leurs versions (extraits de **requirements.txt**) sont récapitulées dans le tableau ??.

| Bibliothèque | Version | Rôle                                            |
|--------------|---------|-------------------------------------------------|
| Python       | 3.14.4  | langage hôte du pipeline                        |
| PyCSP3       | 2.5.1   | modélisation des contraintes (génération XCSP3) |
| ACE          | —       | solveur CSP Java invoqué par PyCSP3             |
| NetworkX     | 3.6.1   | graphes (dual, carbone, couplage de Blossom)    |
| NumPy        | 2.4.6   | algèbre linéaire (ACP, reconstruction 3D)       |
| Flask        | 3.1.3   | backend web du designer                         |
| Werkzeug     | 3.1.8   | dépendance Flask (WSGI)                         |
| Jinja2       | 3.1.6   | dépendance Flask (templates)                    |
| 3Dmol.js     | —       | bibliothèque JS du visualiseur 3D (via CDN)     |

TABLE 2 – Stack logicielle du pipeline et du designer.

**Cluster de calcul.** Les campagnes de grande taille tournent sur le cluster **COALA** du LIS (Aix-Marseille Université), composé de **16 nœuds** (lames **lis-cluster-coala-49** à **-64**), chacun équipé de **2 processeurs Intel Xeon Gold 5218R** (20 cœurs physiques) et **187 GiB de RAM**. Au total, jusqu’à **320 instances xTB en parallèle**. Les artefacts (solutions, géométries XYZ, verdicts) sont persistés dans une base **SQLite** (mode **WAL**). Les détails du protocole (variables d’environnement, **PYTHONHASHSEED**, orchestration cluster) sont en annexe ??.

## 6.3 C<sub>1</sub> — Baseline (contraintes structurales seules)

La première configuration mesure la référence : avec les seules contraintes structurales (section ??) — conservation du carbone C1, gel des hexagones de degré 6 (C2.1), table de voisinage (C3) et rupture de symétrie (C4) —, quelle proportion des solutions est réellement plane après validation xTB ?

Le tableau ?? récapitule les résultats sur le corpus  $h_3$ – $h_9$ .

| $h$   | $N$     | $N_{\text{TP}}$ | %TP     | $N_A$   | %A      |
|-------|---------|-----------------|---------|---------|---------|
| $h_3$ | 7       | 7               | 100,0 % | 7       | 100,0 % |
| $h_4$ | 44      | 42              | 95,5 %  | 42      | 95,5 %  |
| $h_5$ | 278     | 245             | 88,1 %  | 252     | 90,6 %  |
| $h_6$ | 2 146   | 1 691           | 78,8 %  | 1 834   | 85,5 %  |
| $h_7$ | 15 004  | 9 909           | 66,0 %  | 11 381  | 75,8 %  |
| $h_8$ | 112 800 | 64 677          | 57,3 %  | 78 793  | 69,9 %  |
| $h_9$ | 646 319 | 241 577         | 37,4 %  | 351 343 | 54,4 %  |

TABLE 3 – Résultats de la configuration  $C_1$  (baseline).  $N_{\text{TP}}$  : nombre de solutions très planes (dièdre  $< 10^\circ$ ).  $N_A$  : nombre cumulé de solutions planes ou acceptables (dièdre  $< 25^\circ$ ), incluant  $N_{\text{TP}}$ .

## 6.4 $C_2$ — Pb1 + adjacence 5–7 (motif Stone–Wales)

$C_2$  ajoute à  $C_1$  deux contraintes complémentaires, identifiées comme les plus efficaces parmi les variantes locales explorées :

- **Pb1** ( $K_{\text{pb}}=1$ ) :  $\sum_{v \in \partial G_D} \mathbf{1}[x_v = 5] \leq 1$ , c’est-à-dire *au plus un pentagone au bord* du squelette. Cette contrainte traduit l’observation empirique que les pentagones de bord, qui introduisent une courbure locale non compensée par un voisin opposé, sont particulièrement déstabilisants ; la limiter améliore fortement le taux de planéité.
- **adj\_57** (contrainte C5, section ??) : appariement Stone–Wales obligatoire (tout pentagone a un heptagone voisin, et réciproquement). Localement, la paire 5–7 compense exactement la courbure de Gauss–Bonnet ( $+\pi/3 - \pi/3 = 0$ ).

Une troisième contrainte testée parallèlement,  $|n_5 - n_7| \leq K_{\text{sym}}$  (notée C-SYM), s’est révélée *sans effet mesurable* : l’équilibre  $n_5 = n_7$  est déjà imposé par  $C_1$ , et le filtrage par la table produit naturellement des compositions équilibrées.

Le tableau ?? récapitule les résultats sur le corpus.

| $h$   | $N$    | $N_{\text{TP}}$ | %TP     | $N_A$  | %A      |
|-------|--------|-----------------|---------|--------|---------|
| $h_3$ | 5      | 5               | 100,0 % | 5      | 100,0 % |
| $h_4$ | 16     | 16              | 100,0 % | 16     | 100,0 % |
| $h_5$ | 62     | 55              | 88,7 %  | 55     | 88,7 %  |
| $h_6$ | 254    | 224             | 88,2 %  | 233    | 91,7 %  |
| $h_7$ | 900    | 749             | 83,2 %  | 802    | 89,1 %  |
| $h_8$ | 3 292  | 2 669           | 81,1 %  | 2 925  | 88,8 %  |
| $h_9$ | 21 127 | 10 170          | 48,1 %  | 15 623 | 73,9 %  |

TABLE 4 – Résultats de la configuration  $C_2$  (Pb1 + adj\_57). Colonnes : voir tableau ??.

## 6.5 $C_3$ — Interdire les paires 7–7 adjacentes

$C_3$  durcit  $C_2$  en interdisant la concentration locale de courbure négative. Concrètement, on impose une **contrainte de Gauss–Bonnet locale** de paramètre  $\tau_{\text{gb}} = 0$  et rayon 2 dans le graphe dual :

$$\forall v \in V_D, \quad \left| |\{u : x_u = 5, d_{G_D}(u, v) \leq 2\}| - |\{u : x_u = 7, d_{G_D}(u, v) \leq 2\}| \right| \leq 0.$$

En pratique, cela revient à interdire que deux heptagones soient à distance  $\leq 2$  dans le dual sans être compensés par autant de pentagones dans le même voisinage, ce qui exclut notamment les paires 7–7 adjacentes.

Le tableau ?? récapitule les résultats sur le corpus.

| $h$   | $N$   | $N_{\text{TP}}$ | %TP     | $N_{\text{A}}$ | %A      |
|-------|-------|-----------------|---------|----------------|---------|
| $h_3$ | 5     | 5               | 100,0 % | 5              | 100,0 % |
| $h_4$ | 12    | 12              | 100,0 % | 12             | 100,0 % |
| $h_5$ | 28    | 24              | 85,7 %  | 24             | 85,7 %  |
| $h_6$ | 75    | 70              | 93,3 %  | 71             | 94,7 %  |
| $h_7$ | 178   | 170             | 95,5 %  | 171            | 96,1 %  |
| $h_8$ | 512   | 498             | 97,3 %  | 500            | 97,7 %  |
| $h_9$ | 2 845 | 1 696           | 59,6 %  | 2 292          | 80,5 %  |

TABLE 5 – Résultats de la configuration  $C_3$  (Gauss–Bonnet local, rayon 2). Colonnes : voir tableau ??.

## 6.6 $C_{\text{topo}}$ — Topologie complète

Pour traiter  $h_9$ , nous avons cherché des contraintes *non redondantes* avec Pb1 et qui capturent un mécanisme d’échec différent. Une analyse *a posteriori* des solutions  $C_1$  non planes a fait émerger deux **descripteurs topologiques** complémentaires, qui forment ensemble la configuration  $C_{\text{topo}}$ . On appelle ici *descripteur topologique* toute quantité calculée sur le graphe dual d’une solution qui résume une propriété structurelle et dont on observe la corrélation avec la planéité.

**Descripteur 1 — motifs de rayon 2 dans le graphe dual.** Pour chaque cycle  $v$  d’une solution, on définit son *motif de rayon 2* comme le couple  $(x_v, \mathcal{M}(x_u : u \in \mathcal{N}_{G_D}(v)))$ , où  $\mathcal{M}(\cdot)$  désigne un **multiset** (ou *multi-ensemble*), c’est-à-dire un ensemble autorisant les répétitions :  $\mathcal{M}(6, 7, 7) \neq \mathcal{M}(6, 7)$ , les deux voisins de taille 7 étant comptés séparément. Par exemple, le motif  $7 \mid [6, 7, 7]$  désigne un heptagone entouré d’un hexagone et de deux heptagones. L’analyse statistique sur le corpus  $h_7, h_8, h_9$  a identifié une *blacklist* d’une dizaine de motifs fortement corrélés à la non-planéité, indépendamment de la taille du benzénoïde : par exemple  $7 \mid [6, 7, 7]$  ne produit que 9,2 % de solutions planes sur  $h_8$ , contre une moyenne de  $\sim 60\%$ . La contrainte  $C_{\text{topo}}$  interdit explicitement tous ces motifs ; elle est implémentée par une famille de contraintes négatives sur les tuples  $(x_v, x_{u_1}, \dots, x_{u_k})$ , intégrées dans le modèle PPC.

**Descripteur 2 — topologie du squelette.** Le second descripteur est calculé *avant* l’assignement des tailles : le nombre  $n_{\text{péri}}$  d’atomes péri-condensés du squelette, c’est-à-dire partagés par au moins trois cycles. Empiriquement, les squelettes  $n_{\text{péri}} \geq 4$  (péri-condensés, type coronène) résistent beaucoup mieux à la déformation que les squelettes étalés, où les défauts peuvent se replier sans coût énergétique majeur. La contrainte impose donc  $n_{\text{péri}} \geq 4$ , ce qui est un *pré-filtre sur le squelette d’entrée* : si le benzénoïde fourni ne le satisfait pas,  $C_{\text{topo}}$  ne génère aucune solution.

**Résultats.** Le tableau ?? récapitule les résultats sur le corpus.

| $h$   | $N$    | $N_{\text{TP}}$ | %TP     | $N_{\text{A}}$ | %A      |
|-------|--------|-----------------|---------|----------------|---------|
| $h_6$ | 90     | 90              | 100,0 % | 90             | 100,0 % |
| $h_7$ | 1 035  | 980             | 94,7 %  | 998            | 96,4 %  |
| $h_8$ | 9 340  | 7 989           | 85,5 %  | 8 512          | 91,1 %  |
| $h_9$ | 43 057 | 29 954          | 69,6 %  | 35 440         | 82,3 %  |

TABLE 6 – Résultats de la configuration  $C_{\text{topo}}$  (topologie complète, applicable à partir de  $h_6$ ). Colonnes : voir tableau ??.

## 6.7 Bilan expérimental

L'étude désigne trois régimes selon la taille du squelette d'entrée.

- **Pour  $h_3$ – $h_5$**  : les volumes restent faibles ( $\leq 280$  solutions par configuration sur tout le corpus), le taux de très planes de  $C_1$  seul est déjà élevé (88–100 %), et  $C_2$  ou  $C_3$  atteignent typiquement 100 % très planes. À cette échelle, le filtrage par contraintes additionnelles est essentiellement superflu, et la configuration  $C_{\text{topo}}$  n'est pas applicable (le pré-filtre  $n_{\text{péri}} \geq 4$  exclut tous les squelettes,  $n_{\text{péri}}$  ne dépassant pas 3 avant  $h_6$ ) ;
- **Pour  $h_6$ – $h_8$**  :  $C_3$  reste la plus pure (93–**97,3** % très planes), au prix d'un volume réduit ; à utiliser lorsqu'on cherche très peu de candidats mais très fiables.  $C_{\text{topo}}$  atteint la même couverture cumulée %A en élargissant le volume d'un facteur  $\sim 10$  ;
- **Pour  $h_9$  et au-delà** :  $C_{\text{topo}}$  est nettement supérieure (69,6 % de très planes contre 59,6 % pour  $C_3$ , **82,3** % cumulé acceptable contre 80,5 %), et produit dix-huit fois plus de très planes en absolu (29 954 contre 1 696). C'est la configuration par défaut recommandée pour les grandes tailles.

**Lecture chimique de la zone « acceptable ».** La métrique cumulée A (dièdre  $< 25^\circ$ ) montre que la grande majorité des solutions de  $C_1$  non strictement planes restent dans une plage modérément déformée, en particulier sur  $h_9$  : 54,4 % contre 37,4 % pour le strict  $< 10^\circ$ , soit un écart de +17 points. Sur les configurations contraintes, l'écart est plus modeste (+1 à +13 points) car les solutions sont déjà majoritairement très planes. Cela suggère, comme Denis Hagebaum-Reignier l'indique, que les molécules issues du modèle qui « se déforment » le font *modérément* (entre 10 et  $25^\circ$ ) plutôt que franchement. Une analyse statistique sur des non-benzénoïdes synthétisés permettrait de raffiner ce seuil ; ce travail dépasse le cadre du stage.

L'effet  $C_{\text{topo}}$  illustre une difficulté méthodologique identifiée à la section ?? : la planéité est une propriété *globale*, et les leviers les plus efficaces ne s'expriment pas comme contraintes locales « naturelles » sur les tailles 5/6/7. Ils nécessitent d'une part une exploration statistique du corpus  $C_1$  pour identifier des motifs déstabilisants (descripteur 1, *a posteriori*), et d'autre part une caractérisation du squelette *avant assignment* (descripteur 2, indépendant de la solution). Cette démarche — générer un corpus, analyser ses échecs, en extraire des contraintes, ré-énumérer — préfigure une boucle d'apprentissage que nous discutons en perspective (section ??).

## 7 Conclusion et perspectives

### 7.1 Conclusion

Ce stage a étendu aux non-benzénoïdes le cadre de génération exhaustive par programmation par contraintes proposé par Varet [?]. Nous avons proposé un modèle PPC qui assigne à chaque hexagone d'un benzénoïde d'entrée une taille dans  $\{5, 6, 7\}$ , articulé autour d'une *table de voisinage* extensionnelle de 721 entrées sensible à la disposition des voisins, et d'une rupture de symétrie par lex-leader sur le groupe d'automorphismes du graphe dual. Chaque solution du modèle est reconstruite en géométrie 3D, puis validée par un pipeline xTB+ACP, dont le protocole d'optimisation déterministe (perturbation analytique en  $\sin(2\pi i/N + \varphi)$  suivie de `xTB -opt` en mono-thread) garantit la reproductibilité byte-pour-byte, contrairement à la dynamique moléculaire initialement employée. L'ensemble est intégré dans une application web — le *designer* et son visualiseur 3D — qui étend également aux cycles à 5 et 7 atomes l'analyse électronique (structures de Kekulé, couvertures de Clar, ring bond order), restreinte jusqu'ici aux hexagones.

L'étude expérimentale sur les squelettes  $h_3$ – $h_9$  de BenzDB a comparé quatre configurations, du modèle de base  $C_1$  à la configuration  $C_{\text{topo}}$  combinant une blacklist de motifs de rayon 2 et un pré-filtre sur le squelette ( $n_{\text{péri}} \geq 4$ ). Suivant la recommandation des chimistes, l'évaluation

utilise la métrique *angle dièdre maximal entre liaisons connectées*, plus fidèle à la planéité du système conjugué que la métrique ACP globale, avec deux seuils : très plan ( $< 10^\circ$ ) et acceptable ( $< 25^\circ$ ). Les configurations purement locales  $C_2$  et  $C_3$  atteignent une pureté élevée sur les tailles intermédiaires (jusqu'à **97,3** % de très planes sur  $h_8$ ) mais s'effondrent sur  $h_9$  (59,6 % très planes pour  $C_3$ ). Sur cette grande taille,  $C_{\text{topo}}$  s'impose nettement : 69,6 % de très planes et **82,3** % une fois la zone acceptable incluse, soit *dix-huit fois plus* de très planes en absolu que  $C_3$  (29 954 contre 1 696). Ce résultat confirme expérimentalement ce que nous avons identifié théoriquement : la planéité est une propriété globale qui ne se capture pas, sur les grands squelettes, par des contraintes purement locales sur les tailles 5/6/7. Les leviers les plus efficaces nécessitent soit une analyse statistique *a posteriori* du corpus généré (descripteurs de rayon 2), soit un pré-filtre sur le squelette d'entrée indépendant de l'assignment ( $n_{\text{péri}}$ ) — difficulté qui motive directement les perspectives ci-après.

## 7.2 Perspectives

La démarche suivie pendant ce stage présente une forme caractéristique : on génère un corpus de candidats par un modèle PPC, on les valide par xTB, on observe les résultats, on interprète les régularités (les pentagones de bord nuisent à la planéité, les paires 5–7 se compensent), on les transforme en hypothèses, on les exprime sous forme de nouvelles contraintes, puis on ré-énumère pour mesurer leur effet. Au sens méthodologique, c'est une boucle d'*apprentissage* aujourd'hui tenue par l'humain ; demain, elle pourrait être tenue partiellement par une machine. C'est précisément l'enjeu de la **combinaison IA symbolique (PPC) + IA d'apprentissage**, qui fait l'objet d'une recherche active actuellement [?, ?]. La PPC apporte la garantie d'exhaustivité et l'explicabilité (chaque solution satisfait des règles écrites explicitement) ; l'apprentissage apporte la capacité à inférer des motifs dans des espaces de grande dimension où l'humain ne saurait les formuler à la main. Pour notre problème, cela ouvre plusieurs voies : apprendre des contraintes à partir du corpus déjà généré, guider la recherche du solveur par une heuristique entraînée, ou encore prédire la planéité par un réseau de neurones sur graphe pour éviter les appels xTB les moins informatifs. Cette direction, qui maintient le moteur symbolique au cœur mais l'enrichit d'heuristiques apprises, semble particulièrement adaptée à un problème comme le nôtre, où la connaissance chimique est encore en construction et progresse au rythme des expériences elles-mêmes.

## A Annexe

### A.1 Définitions formelles de cohérence

Les définitions suivantes sont adaptées de Mackworth [?] et reprises dans la thèse de Varet [?] (Déf. 1.4.1).

**Définition 8** (Arc-cohérence). Soit  $P = (X, D, C)$  un CSP. Une valeur  $v \in D_x$  est arc-cohérente par rapport à une contrainte  $c \in C$  de portée  $S(c) \ni x$  si, pour chaque autre variable  $y \in S(c)$ , il existe une valeur  $w \in D_y$  telle que le tuple partiellement défini par  $t[\{x\}] = v$ ,  $t[\{y\}] = w$  est compatible avec  $R(c)$ .

Un CSP est dit arc-cohérent si chaque valeur de chaque domaine est arc-cohérente par rapport à toutes les contraintes qui la concernent.

**Définition 9** (Propagation de contraintes). La propagation de contraintes (ou filtrage) est le processus itératif consistant à supprimer des domaines toute valeur non arc-cohérente. Le processus se répète jusqu'à l'obtention d'un point fixe : un état où aucune suppression supplémentaire n'est possible. Chaque suppression peut déclencher de nouvelles suppressions en cascade (effet "boule de neige").

**Remarque 6.** L'arc-cohérence ne garantit pas à elle seule la satisfiabilité du CSP : un problème peut être arc-cohérent et ne posséder aucune solution (les domaines restent non vides, mais aucune combinaison complète n'est consistante). Elle réduit cependant l'espace de recherche et est systématiquement appliquée avant et pendant le backtracking.

### A.2 Règle de Hückel

La règle suivante est établie par Hückel en 1931 [?] dans le cadre de la théorie des orbitales moléculaires au niveau *tight-binding*.

**Définition 10** (Règle de Hückel, [?]). Un cycle conjugué plan est aromatique si et seulement s'il possède  $4n + 2$  électrons  $\pi$  pour un entier  $n \geq 0$ .

Les premiers cas sont :  $n = 0$  (2 électrons, cyclopropényle cation),  $n = 1$  (6 électrons, benzène),  $n = 2$  (10 électrons, azulène et naphthalène). Les cycles à  $4n$  électrons (cyclobutadiène : 4, cyclo-octatetraène : 8) sont dits *antiaromatiques* et sont déstabilisés.

**Remarque 7.** Dans notre contexte, seuls les hexagones satisfont la règle avec  $n = 1$  (6 atomes de carbone  $\Rightarrow$  6 électrons  $\pi$  délocalisés). Les pentagones et heptagones n'ont pas le bon décompte et ne peuvent donc pas porter de sextet de Clar. C'est pourquoi la variable  $y_h$  du modèle  $\mathcal{M}_C$  (section ??) n'est définie que sur les hexagones  $h \in \mathcal{H}$ .

### A.3 Protocole de validation xTB (détails)

**Historique : abandon de la dynamique moléculaire.** Une première version du pipeline utilisait une *dynamique moléculaire* courte (`xTB -md` à 298 K pendant 1 ps) pour briser la symétrie planaire parasite avant l'optimisation. Cette approche s'est révélée **non reproductible** : xTB initialise les vitesses MD à partir de l'horloge système et n'expose aucune graine accessible (confirmé par l'issue GitHub #730 du dépôt `grimme-lab/xTB`, ouverte depuis 2022 et sans réponse). Sur des structures tendues ( $h_8-h_9$ ), deux exécutions identiques pouvaient basculer entre les verdicts PLAN et NON-PLAN, ce qui invalidait toute campagne expérimentale.

**Protocole déterministe retenu.** La perturbation  $z'_i = z_i + A \sin(2\pi i/N + \varphi)$  ( $A = 0,05$  Å,  $\varphi = 0,5$  rad) est appliquée aux  $N$  atomes ordonnés canoniquement avant l'appel à `xtb -opt tight` (GFN2-xTB 6.7.1). Les variables d'environnement suivantes sont imposées avant chaque appel :

```
OMP_NUM_THREADS=1    MKL_NUM_THREADS=1
OPENBLAS_NUM_THREADS=1    NUMEXPR_NUM_THREADS=1
PYTHONHASHSEED=0
```

De plus, l'ordre canonique `sorted(...)` est appliqué partout où des collections non ordonnées (ensembles d'atomes, de liaisons) seraient itérées. L'ensemble du pipeline est ainsi *byte-déterministe*.

**Filtre anti-fragmentation.** Un filtre rejette les optimisations où un atome s'éjecte au-delà de 30 Å du barycentre (liaison rompue). La solution reçoit alors le verdict `ÉCHEC xTB`.

**Persistence.** La géométrie finale est conservée dans `md_final_opt.xyz` sous chaque solution. L'orchestration sur le cluster COALA utilise un dispatcher basé sur un *manifest JSONL* partagé sur NFS et des verrous atomiques (`O_CREAT|O_EXCL`) garantissant qu'un job n'est pris que par un seul worker.

## A.4 Test de planéité par ACP (détails)

**Calcul du plan moyen.** Soit  $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathbb{R}^3$  les coordonnées des carbones après optimisation xTB. On centre le nuage ( $\bar{\mathbf{x}} = \frac{1}{N} \sum_i \mathbf{x}_i$ ) et on forme la matrice de covariance  $3 \times 3$

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

La diagonalisation de  $\Sigma$  fournit trois vecteurs propres orthonormés  $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$  avec valeurs propres  $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$ . Le plan moyen est engendré par  $\mathbf{v}_1, \mathbf{v}_2$ ;  $\mathbf{v}_3$  est sa **normale globale**.

**Métriques globales.**

- *rmsd plan* :  $\sqrt{\frac{1}{N} \sum_i (\mathbf{v}_3^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2}$  — épaisseur quadratique moyenne ;
- *hauteur* :  $\max_i - \min_i$  des projections sur  $\mathbf{v}_3$  — épaisseur extrême ;
- angle entre  $\mathbf{v}_3$  et l'axe  $Z$  global — valeur diagnostique (inclinaison d'ensemble sans déformation).

**Métrique `max_angle_deg`.** Pour chaque cycle  $C$ , la même ACP sur ses seuls sommets donne une normale locale  $\mathbf{n}_C$ . La valeur maximale de l'angle de gauchissement est

$$\text{max\_angle\_deg} = \max_C \arccos(|\mathbf{n}_C \cdot \mathbf{v}_3|).$$

Cette quantité, utilisée historiquement comme critère de planéité (`max_angle_deg`  $\leq 10^\circ$ ), est conservée dans la base de résultats pour comparaison. Pour le verdict final, elle est remplacée par `max_dihedral_deg` (voir ci-dessous), plus fidèle à l'évaluation chimique de la planéité.

## A.5 Calcul de la métrique dièdre `max_dihedral_deg`

**Énumération des chemins.** Soit  $G_C = (V_C, E_C)$  le graphe carbone après optimisation xTB (les hydrogènes sont écartés). Pour chaque arête  $\{B, C\} \in E_C$  prise dans l'ordre  $B < C$ , et pour chaque paire de voisins  $A \in \mathcal{N}_{G_C}(B)$ ,  $D \in \mathcal{N}_{G_C}(C)$  vérifiant  $A \neq C$ ,  $D \neq B$  et  $A \neq D$ , le quadruplet  $(A, B, C, D)$  forme une chaîne de trois liaisons consécutives.

**Angle dièdre.** Pour chaque quadruplet, posons  $\mathbf{b}_1 = \mathbf{x}_B - \mathbf{x}_A$ ,  $\mathbf{b}_2 = \mathbf{x}_C - \mathbf{x}_B$ ,  $\mathbf{b}_3 = \mathbf{x}_D - \mathbf{x}_C$ . L'angle dièdre signé entre les plans  $(A, B, C)$  et  $(B, C, D)$  est

$$\varphi(A, B, C, D) = \text{atan2}(\|\mathbf{b}_2\| \cdot (\mathbf{b}_1 \cdot (\mathbf{b}_2 \times \mathbf{b}_3)), (\mathbf{b}_1 \times \mathbf{b}_2) \cdot (\mathbf{b}_2 \times \mathbf{b}_3)) \in (-180^\circ, 180^\circ].$$

**Écart au plan.** Pour une molécule plane, chaque  $\varphi$  vaut exactement  $0^\circ$  (configuration *cis*) ou  $\pm 180^\circ$  (configuration *trans*). L'écart au plan est donc

$$\delta(\varphi) = \min(|\varphi|, 180^\circ - |\varphi|) \in [0, 90^\circ],$$

et la métrique retenue est le maximum sur tous les quadruplets connectés. Une molécule parfaitement plane vérifie `max_dihedral_deg` =  $0^\circ$ ; une molécule fortement courbée s'approche de  $90^\circ$ .

**Coût.** Implémentation vectorielle en NumPy :  $\sim 0,4$  ms par molécule. Le calcul sur l'intégralité de la base finale ( $\sim 805\,000$  géométries optimisées) prend environ 5 minutes en mono-thread, sans nouvelle invocation de xTB.



## Références et bibliographie

- [1] A. Varet, *Programmation par contraintes et chimie théorique : utilisation du formalisme CSP pour résoudre des problématiques liées aux benzénoides*, thèse de doctorat, Aix-Marseille Université, 2022.
- [2] F. Rossi, P. van Beek, T. Walsh (éds.), *Handbook of Constraint Programming*, Elsevier, 2006.
- [3] C. Lecoutre, *Constraint Networks : Techniques and Algorithms*, ISTE/Wiley, 2009.
- [4] C. Lecoutre, N. Szczepanski, *PyCSP3 : modélisation en programmation par contraintes et le solveur ACE (Abscon Constraint Engine)*. [pycsp.org](http://pycsp.org).
- [5] A. Varet, N. Prcovic, C. Terrioux et al., *BenzAI : A Program to Design Benzenoids with Defined Properties Using Constraint Programming*, Journal of Chemical Information and Modeling, 2022. DOI : 10.1021/acs.jcim.2c00353.
- [6] J. Edmonds, *Paths, trees, and flowers*, Canadian Journal of Mathematics, 17 :449–467, 1965.
- [7] H. Whitney, *Congruent graphs and the connectivity of graphs*, American Journal of Mathematics, 54(1) :150–168, 1932.
- [8] E. Clar, *The Aromatic Sextet*, John Wiley & Sons, Londres, 1972.
- [9] E. Hückel, *Quantentheoretische Beiträge zum Benzolproblem*, Zeitschrift für Physik, 70 :204–286, 1931 (règle des  $4n + 2$  électrons  $\pi$ ).
- [10] A. K. Mackworth, *Consistency in Networks of Relations*, Artificial Intelligence, 8(1) :99–118, 1977.
- [11] L. Pauling, *The Nature of the Chemical Bond*, Cornell University Press, 3<sup>e</sup> édition, 1960.
- [12] M. Randić, *Aromaticity and conjugation*, Journal of the American Chemical Society, 99(2) :444–450, 1977 (ordres de liaison et circuits conjugués).
- [13] F. J. Rispoli, *Counting Perfect Matchings in Hexagonal Systems Associated with Benzenoids*, Mathematics Magazine, 14 :194–200, 2001.
- [14] P. W. Kasteleyn, *Graph theory and crystal physics*, in *Graph Theory and Theoretical Physics*, Academic Press, p. 43–110, 1967.
- [15] A. J. Stone, D. J. Wales, *Theoretical studies of icosahedral  $C_{60}$  and some related species*, Chemical Physics Letters, 128(5–6) :501–503, 1986.
- [16] C. Bannwarth, S. Ehlert, S. Grimme, *GFN2- $xTB$  — An Accurate and Broadly Parametrized Self-Consistent Tight-Binding Quantum Chemical Method*, Journal of Chemical Theory and Computation, 15(3) :1652–1671, 2019.
- [17] Q. Cappart, D. Chételat, E. Khalil, A. Lodi, C. Morris, P. Veličković, *Combinatorial Optimization and Reasoning with Graph Neural Networks*, Journal of Machine Learning Research, 24(130) :1–61, 2023.
- [18] Y. Bengio, A. Lodi, A. Prouvost, *Machine learning for combinatorial optimization : a methodological tour d’horizon*, European Journal of Operational Research, 290(2) :405–421, 2021.