

Mémoire de stage de Master 2
Informatique et Mathématiques Discrètes (IMD)
Année universitaire 2025–2026

Génération automatique et exhaustive de structures moléculaires bi-dimensionnelles par programmation par contraintes

focus sur les non-benzénoïdes à cycles 5, 6 et 7 atomes
et validation quantique semi-empirique

Toky Nirina RAMAHERISOA

Encadrants Nicolas PROCOVIC et Cyril TERRIOUX
LIS, équipe COALA, Aix-Marseille Université

Partenaires Yannick CARISSAN et Denis HAGEBAUM-REIGNIER
Institut des Sciences Moléculaires de Marseille (iSm2)

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	Objectif et problématique	2
1.3	Positionnement et contributions	2
2	Préliminaires et état de l’art	3
2.1	Programmation par contraintes (PPC)	3
2.2	Notions de chimie	3
2.2.1	HAP, benzénoïdes et graphe dual	3
2.2.2	Aromaticité et délocalisation	4
2.2.3	Structures de Kekulé	4
2.2.4	Sextets et couvertures de Clar	4
2.2.5	Ring Bond Order (RBO)	4
2.2.6	Sites radicalaires	5
2.2.7	Planéité et courbure	5
2.2.8	Validation quantique semi-empirique (xTB)	5
3	Le problème	6
3.1	Énoncé : substitutions 5/6/7 d’un benzénoïde	6
3.2	La difficulté combinatoire	6
3.3	La difficulté géométrique et topologique	6
4	Modélisation	6
4.1	Variables et domaines	7
4.2	Contrainte C1 — Conservation du carbone	7
4.3	Contrainte C3 — Voisinage admissible et table de voisinage	8
4.4	Rupture de symétrie	8
4.5	Résolution	8
5	Réalisation : des solutions du modèle aux molécules validées et analysées	8
5.1	Reconstruction 3D des solutions	9
5.1.1	Modifications topologiques du graphe carbone	9
5.1.2	Placement géométrique	9
5.1.3	Assemblage moléculaire	10
5.2	Validation par xTB : protocole de dynamique moléculaire	10
5.3	Test de planéité par analyse en composantes principales	11
5.4	Analyse électronique des structures	12
5.5	Mise en œuvre logicielle	12
6	Étude expérimentale : quelles contraintes améliorent la planéité ?	13
6.1	Protocole et banc d’essai	13
6.2	v1 — Modèle de base	13
6.3	v2 — Contraintes globales : pentagones en bord	13
6.4	v3 — Contraintes locales : appariement 5–7 (Stone–Wales)	13
6.5	Bilan expérimental	14
7	Conclusion et perspectives	14

1 Introduction

1.1 Contexte

Les *hydrocarbures aromatiques polycycliques* (HAP) sont des molécules constituées uniquement de carbone et d'hydrogène, dont les atomes de carbone forment des cycles fusionnés. Ils sont étudiés pour leurs propriétés électroniques et opto-électroniques. Parmi les HAP, les *benzénoïdes* forment la sous-famille composée exclusivement d'hexagones fusionnés par une arête. Cette famille a fait l'objet de nombreux travaux, et notamment de la thèse de A. Varet [1], qui a montré que la *programmation par contraintes* (PPC) est un outil particulièrement adapté à la génération exhaustive de benzénoïdes répondant à des propriétés données.

L'étude des HAP comportant des cycles à *cinq* ou *sept* atomes, dits *non-benzénoïdes*, est plus récente. L'azulène, formé d'un pentagone et d'un heptagone accolés, en est l'exemple emblématique. L'introduction de tels cycles modifie en profondeur la chimie de la molécule : elle brise la régularité du pavage hexagonal, induit une courbure locale, et favorise l'apparition de sites radicalaires. Ces structures intéressent donc les chimistes, mais leur génération systématique reste largement inexplorée.

1.2 Objectif et problématique

L'objectif du stage est le suivant : *étant donné un benzénoïde, énumérer de manière exhaustive toutes les substitutions admissibles dans lesquelles chaque hexagone est soit conservé, soit remplacé par un cycle à 5 ou 7 atomes*. La difficulté est double, à la fois combinatoire et géométrique. Nous en donnons l'énoncé précis et l'analyse détaillée à la section 3, une fois introduit le vocabulaire nécessaire.

1.3 Positionnement et contributions

Ce stage se place dans la continuité directe de la thèse de Varet [1] : nous reprenons son cadre (modélisation PPC sur le *graphe dual* d'un benzénoïde, notions d'aromaticité) et nous l'étendons au cas, non traité jusqu'ici, des cycles à 5 et 7 atomes. Nos contributions sont les suivantes.

- Un **modèle PPC** qui énumère exhaustivement les substitutions 5/6/7 d'un benzénoïde, fondé sur une *table de voisinage* encodant les configurations locales chimiquement réalisables.
- Un **pipeline de validation physique** qui reconstruit en trois dimensions chaque solution du modèle, l'optimise par une méthode quantique semi-empirique (XTB), puis juge sa planéité.
- Une **étude expérimentale systématique** de contraintes additionnelles visant à augmenter la proportion de molécules planes produites. Ce point mérite une précision : la planéité d'une molécule est une propriété *globale* qui ne se laisse pas exprimer entièrement par des contraintes locales — c'est une difficulté intrinsèque au problème, et non un défaut de modélisation. Notre démarche consiste à identifier expérimentalement les contraintes qui, sans capturer la planéité au sens strict, en améliorent significativement le rendement.
- Une **extension de l'analyse électronique** (structures de Kekulé, couvertures de Clar, *Ring Bond Order*) aux cycles à 5 et 7 atomes, là où les outils existants se limitent aux hexagones.

Le mémoire est organisé comme suit. La section 2 introduit les deux corpus de notions nécessaires — la PPC et la chimie des HAP. La section 3 détaille le problème et ses difficultés. La section 4 présente notre modélisation. La section 5 décrit la réalisation (reconstruction, validation, analyse). La section 6 rapporte l'étude expérimentale, et la section 7 conclut.

2 Préliminaires et état de l’art

Notre travail se situe à l’interface de l’informatique et de la chimie théorique. Les notions nécessaires à la lecture du mémoire sont d’abord celles de la programmation par contraintes, puis le vocabulaire de chimie utilisé dans la suite.

2.1 Programmation par contraintes (PPC)

La *programmation par contraintes* est un paradigme déclaratif de résolution de problèmes combinatoires. Plutôt que de décrire *comment* résoudre un problème, on se contente d’en *décrire les solutions*, puis on confie la recherche à un solveur générique.

Définition 1 (Réseau de contraintes / CSP). *Un problème de satisfaction de contraintes est un triplet (X, D, C) où $X = \{x_1, \dots, x_n\}$ est un ensemble de variables, $D = \{D_1, \dots, D_n\}$ associe à chaque variable x_i un domaine fini D_i de valeurs possibles, et C est un ensemble de contraintes. Chaque contrainte porte sur un sous-ensemble de variables et restreint les combinaisons de valeurs qu’elles peuvent prendre simultanément. Une solution est une affectation de chaque variable à une valeur de son domaine satisfaisant toutes les contraintes.*

La résolution combine une *recherche arborescente* (on affecte les variables une à une, en revenant en arrière en cas d’échec) et de la *propagation de contraintes* (à chaque étape, on retire des domaines les valeurs qui ne peuvent appartenir à aucune solution, par exemple par *cohérence d’arc*). L’intérêt majeur du paradigme est qu’il n’est pas nécessaire d’écrire un algorithme spécifique à chaque problème : il suffit de formuler le modèle, puis d’invoquer un solveur traité comme une *boîte noire*. Dans ce travail, nous écrivons les modèles avec la bibliothèque Python PYCSP3 et nous les résolvons avec le solveur ACE (*Abscon Constraint Engine*) [4], qui sait énumérer l’ensemble des solutions d’une instance.

Deux familles de contraintes nous seront utiles. Une **contrainte extensionnelle** (ou *de table*) liste explicitement les combinaisons de valeurs autorisées pour un groupe de variables ; c’est la forme naturelle pour encoder un catalogue de configurations admissibles. Une **contrainte globale** capture un motif récurrent sur un nombre arbitraire de variables : par exemple *Sum* (une somme bornée) ou *LexIncreasing* (un ordre lexicographique entre deux vecteurs de variables), que nous emploierons pour la *rupture de symétrie*. Enfin, la souplesse de la PPC — activer, désactiver ou ajouter une contrainte, puis ré-énumérer rapidement les solutions — est un atout décisif pour un travail mené en dialogue continu avec les chimistes.

2.2 Notions de chimie

Les termes de chimie employés dans la suite peuvent être lus aussi bien comme des définitions sur des graphes que comme le vocabulaire chimique usuel.

2.2.1 HAP, benzénoïdes et graphe dual

Un **benzénoïde** est un assemblage d’hexagones réguliers du pavage hexagonal, fusionnés par des arêtes. On peut le voir de deux façons. Le *graphe carbone* a pour sommets les atomes de carbone et pour arêtes les liaisons carbone-carbone. Le *graphe dual* G_D , central dans tout ce travail, résume la combinatoire des hexagones.

Définition 2 (Graphe dual). *Soit B un benzénoïde à h hexagones. Son graphe dual $G_D = (V_D, E_D)$ a pour sommets $V_D = \{0, \dots, h - 1\}$ (un sommet par hexagone), et $(u, v) \in E_D$ si et seulement si les hexagones u et v partagent une arête carbone-carbone. Cette construction correspond au graphe dual intérieur de la littérature, c’est-à-dire le graphe dual classique privé de la face externe.*

On appelle **bord** de G_D l'ensemble des hexagones de degré strictement inférieur à 6, c'est-à-dire ceux qui ne sont pas entièrement entourés de voisins. La figure 1 illustre cette construction sur un benzénoïde linéaire à trois hexagones.




FIGURE 1 – Un benzénoïde linéaire à trois hexagones (gauche) et son graphe dual G_D (droite) : un chemin à trois sommets.

2.2.2 Aromaticité et délocalisation

L'**aromaticité** traduit la stabilité particulière de certains cycles conjugués. La *règle de Hückel* en donne le critère classique : un cycle est dit aromatique s'il est plan, conjugué (chaque atome du cycle porte un électron π), et contient $4n + 2$ électrons π , où n est un entier positif ou nul. Le benzène ($n = 1$, soit 6 électrons π) en est l'exemple fondamental. Dans un tel cycle, les électrons π ne sont pas localisés sur une liaison précise : ils sont *délocalisés* et circulent autour du cycle. Plus une molécule admet de représentations équivalentes de ses liaisons doubles, plus la délocalisation est étendue, et plus la molécule est stable.

2.2.3 Structures de Kekulé

Une **structure de Kekulé** est un étiquetage des liaisons carbone-carbone en simples et doubles tel que chaque carbone porte exactement une double liaison. En termes de graphes, c'est un *couplage parfait* du graphe carbone. Une molécule HAP possède en général plusieurs structures de Kekulé, mais il est aussi possible qu'elle n'en possède aucune lorsque son graphe carbone n'admet pas de couplage parfait.




FIGURE 2 – Les trois structures de Kekulé du naphthalène. Chaque trait intérieur représente une liaison double ; chaque atome de carbone est l'extrémité d'exactly une double.

2.2.4 Sextets et couvertures de Clar

Un **sextet de Clar** (ou rond de Clar) est un hexagone dont les six électrons π forment un cycle aromatique autonome. Une **couverture de Clar** place des sextets sur un ensemble d'hexagones deux à deux disjoints, et le **nombre de Clar** est le nombre maximal de sextets que l'on peut placer. La règle de Hückel ($4n + 2$ électrons π , soit 6 pour $n = 1$) impose qu'un sextet occupe exactement six atomes : seuls les *hexagones* peuvent porter un sextet, jamais un pentagone ni un heptagone.

2.2.5 Ring Bond Order (RBO)

L'**ordre de liaison** d'une arête est la fraction des structures de Kekulé dans lesquelles cette arête est double ; c'est une mesure de la délocalisation locale. Le **Ring Bond Order** d'un cycle est la somme des ordres de liaison de ses arêtes. Il quantifie à quel point un cycle « ressemble » à un cycle aromatique sur l'ensemble des Kekulé.




FIGURE 3 – Les deux couvertures de Clar du naphthalène. Le cercle représente un sextet aromatique de six électrons π ; les deux liaisons doubles restantes sont placées dans l’autre hexagone. Le *nombre de Clar* du naphthalène vaut donc 1 : on ne peut placer qu’un seul sextet à la fois (les deux hexagones partagent une arête).

2.2.6 Sites radicalaires

Lorsqu’une molécule n’admet aucun couplage parfait (par exemple à cause d’un nombre impair d’atomes ou d’une topologie particulière), certains carbones restent non couverts : ils portent un **électron π non apparié**, appelé aussi *électron radicalaire* ou *électron célibataire*. La parité impaire des cycles à 5 et 7 atomes favorise précisément l’apparition de tels sites, ce qui rend les structures non-benzénoïdes intéressantes pour la chimie radicalaire.

L’exemple le plus simple est celui d’un pentagone accolé à un hexagone (figure 4) : le squelette compte $5 + 6 - 2 = 9$ atomes de carbone, un nombre impair. Aucun couplage parfait ne peut donc exister, et au moins un carbone reste non couvert dans toute structure de Kekulé : un site radicalaire est *forcé* par la topologie.




FIGURE 4 – Un pentagone accolé à un hexagone : 9 carbones (impair), donc tout couplage laisse au moins un atome non couvert. Le carbone marqué d’un point porte un électron π non apparié : c’est un site radicalaire imposé par la topologie du squelette.

2.2.7 Planéité et courbure

À toute molécule on associe une fonction *énergie potentielle* qui dépend de la position de ses atomes ; cette énergie est minimale lorsque les longueurs et les angles de liaison correspondent aux préférences de chaque atome et que les répulsions stériques sont relâchées. Une configuration des atomes est dite à l’**équilibre énergétique** lorsqu’elle réalise un minimum local de cette énergie ; c’est dans cette configuration que la molécule existe effectivement. On dit alors qu’une molécule est **plane** si tous ses atomes se placent, à l’équilibre énergétique, dans un même plan.

Pour un pavage d’hexagones réguliers, la somme des angles autour de chaque sommet vaut 360° et la structure est plane. Un pentagone (angle interne 108°) introduit localement un *défaut d’angle* positif et la matière tend à se refermer, comme dans un fullerène ; un heptagone ($\approx 128,6^\circ$) introduit un défaut négatif et la matière tend à onduler.

2.2.8 Validation quantique semi-empirique (xTB)

Pour juger si une molécule est réellement plane, on cherche sa géométrie d’équilibre : la disposition des atomes qui minimise l’énergie. Nous utilisons une méthode *semi-empirique*, GFN2-xTB [15], qui approxime l’énergie à un coût permettant de traiter de grandes séries de molécules et fournit une géométrie optimisée exploitable à grande échelle. C’est le sens de la « validation quantique semi-empirique » du titre.

3 Le problème

Maintenant que le vocabulaire est posé, nous pouvons énoncer précisément le problème et analyser ses deux sources de difficulté.

3.1 Énoncé : substitutions 5/6/7 d'un benzénoïde

On part d'un benzénoïde B à h hexagones, représenté par son graphe dual G_D . Une **substitution** affecte à chaque hexagone v une taille de cycle $x_v \in \{5, 6, 7\}$: conserver l'hexagone ($x_v = 6$), le contracter en pentagone ($x_v = 5$) ou le dilater en heptagone ($x_v = 7$). La substitution doit respecter la *topologie* de B (les arêtes partagées entre cycles voisins sont préservées) et conserver le nombre total d'atomes de carbone. On cherche à **énumérer toutes les substitutions admissibles**, c'est-à-dire toutes celles qui correspondent à une molécule chimiquement et géométriquement réalisable, sans doublon (deux substitutions identiques à une symétrie près ne comptent que pour une).

3.2 La difficulté combinatoire

Avec trois valeurs possibles par hexagone, un benzénoïde à h hexagones admet a priori 3^h substitutions. Ce nombre croît exponentiellement, et la grande majorité de ces affectations ne correspondent à *aucune* molécule valide : elles violent la conservation du carbone, ou décrivent des voisinages localement impossibles à reconstruire. Énumérer naïvement puis filtrer est donc hors de portée dès que h dépasse quelques unités. C'est exactement le type de problème fortement combinatoire pour lequel la PPC est conçue : on encode les conditions d'admissibilité comme des contraintes, et le solveur n'explore que les affectations cohérentes.

3.3 La difficulté géométrique et topologique

La seconde difficulté est de nature différente, et c'est la plus profonde. Dans un benzénoïde, tous les cycles sont des hexagones réguliers d'angle interne 120° , et le pavage est plan par construction. Dès que l'on introduit des pentagones (angle interne 108°) et des heptagones (environ $128,6^\circ$), plusieurs grandeurs cessent d'être fixées :

- les **angles** aux sommets ne se complètent plus à 360° , ce qui crée une courbure locale ;
- les **distances** inter-atomiques et les longueurs de liaison s'ajustent pour relâcher les tensions ;
- la **topologie** de fusion impose que les cycles voisins partagent exactement une arête, ce qui n'est pas toujours réalisable selon la disposition des voisins ;
- la **planéité** qui en résulte n'est pas garantie : la molécule peut se courber ou onduler pour minimiser son énergie.

Le point crucial est que la planéité est une propriété *globale* : elle dépend de l'agencement de tous les défauts à la fois, et ne se déduit pas seulement des voisinages locaux. On peut filtrer localement les configurations manifestement irréalisables, mais on ne peut pas, par des contraintes locales seules, garantir qu'une molécule entière sera plane. Cette limite est *intrinsèque au problème*. Elle motive l'architecture en deux temps de notre travail : un modèle PPC qui énumère les candidats en appliquant les conditions *exprimables* (section 4), suivi d'une validation physique qui tranche la planéité *réelle* de chaque candidat (section 5). Et elle motive l'étude expérimentale (section 6), qui cherche les contraintes améliorant au mieux le rendement de planéité.

4 Modélisation

Nous présentons à présent le modèle PPC qui énumère les substitutions admissibles. Il comporte une variable par hexagone et un ensemble de contraintes *structurelles*, toujours actives, que

nous décrivons ici. Les contraintes *additionnelles*, qui font l'objet de l'étude expérimentale, sont introduites à la section 6.

4.1 Variables et domaines

À chaque hexagone v du graphe dual on associe une variable x_v donnant la taille du cycle substitué :

$$x_v \in \{5, 6, 7\}, \quad v \in V_D.$$

Avant la résolution, un *prétraitement* réduit le domaine de certaines variables en exploitant la structure de G_D . Pour chaque hexagone v , on définit son **motif d'occupation** $\sigma(v) = (\sigma_0, \dots, \sigma_5) \in \{0, 1\}^6$, où $\sigma_i = 1$ si le i -ème côté de v est partagé avec un voisin, et 0 s'il est libre. On note $b(v)$ le nombre de *blocs* de côtés libres consécutifs (sur le cycle des six côtés).

Un hexagone est dit **gelé** — forcé à rester un hexagone, domaine réduit à $\{6\}$ — dans deux cas :

- $\deg_{G_D}(v) = 6$: l'hexagone est entouré de six voisins, n'a aucun côté libre, et ne peut donc ni se contracter ni se dilater ;
- $b(v) \geq 2$: ses côtés libres sont fragmentés en plusieurs blocs ; transformer le cycle reviendrait à étirer ou contracter l'un des blocs sans toucher aux autres, et ferait donc perdre au nouveau cycle sa forme régulière de polygone. Cette restriction est appliquée par défaut, mais peut être désactivée si l'on souhaite explorer des géométries plus irrégulières.

Les autres hexagones, dits *libres*, conservent le domaine $\{5, 6, 7\}$.

4.2 Contrainte C1 — Conservation du carbone

Le nombre total d'atomes de carbone doit être préservé par la substitution. Notons h le nombre d'hexagones du benzénoïde de départ, et n_5, n_6, n_7 les nombres respectifs de pentagones, hexagones et heptagones dans la solution. Tout cycle de la solution remplace exactement un hexagone du benzénoïde de départ, donc

$$n_5 + n_6 + n_7 = h.$$

Pour exprimer la conservation des atomes, raisonnons *relativement à un hexagone*. Substituer un hexagone par un pentagone retire un atome de carbone, le substituer par un heptagone en ajoute un, et le conserver ne change rien. Le bilan total des carbones, par rapport à la molécule de départ, est donc $n_7 - n_5$, et la conservation impose

$$\boxed{n_5 = n_7.}$$

Remarque sur le nombre absolu de carbones. Un benzénoïde à h hexagones ne contient pas $6h$ atomes de carbone, car les hexagones adjacents partagent leurs sommets : le naphthalène ($h = 2$) a 10 carbones, l'anthracène ($h = 3$) en a 14, etc. La formule $\sum_v x_v = 6h$ ci-dessous n'est donc pas un comptage d'atomes ; c'est une réécriture algébrique de la condition $n_5 = n_7$.

Pour traduire $n_5 = n_7$ sur les variables x_v du modèle, on observe que

$$\sum_{v \in V_D} x_v = 5n_5 + 6n_6 + 7n_7 = 6(n_5 + n_6 + n_7) + (n_7 - n_5) = 6h + (n_7 - n_5).$$

Imposer $n_5 = n_7$ équivaut donc à imposer

$$\sum_{v \in V_D} x_v = 6h,$$

qui est l'expression effectivement déclarée au solveur (une simple contrainte de somme sur les variables entières).

4.3 Contrainte C3 — Voisinage admissible et table de voisinage

C’est le cœur du filtrage chimique. Pour chaque hexagone libre v , on impose que la configuration locale formée par v et ses voisins soit *réalisable*. Cette condition est encodée par une **contrainte extensionnelle** : le tuple ordonné

$$\tau_v = (x_v, x_{u_1}, x_{u_2}, \dots, x_{u_k}),$$

où $u_1, \dots, u_k$ sont les voisins de v dans G_D pris dans l’ordre cyclique, doit appartenir à une **table de voisinage** $\mathcal{T}$ pré-calculée.

Un point essentiel distingue notre table de celle des benzénoïdes purs : elle est *sensible à la disposition* des voisins. Deux configurations ayant les mêmes tailles de voisins mais disposées différemment autour du cycle central ne sont pas équivalentes, car elles ne se reconstruisent pas de la même manière en trois dimensions. La position des voisins est donc encodée explicitement dans les tuples de la table (un 0 marquant un côté libre).

La table est **construite hors-ligne** : on énumère les configurations locales candidates (un cycle central entouré de voisins de tailles données dans une disposition donnée), on reconstruit chacune en 3D, on l’optimise par xTB, et on ne retient que celles qui sont planes (au sens du critère décrit en section 5). Ce catalogue est *paramétrable* : il pourra être régénéré ou affiné lorsque de nouvelles études chimiques préciseront les critères d’admissibilité. La version utilisée dans ce travail comporte **721** entrées, réparties selon la taille du cycle central :

$$|\mathcal{T}(5)| = 63, \quad |\mathcal{T}(6)| = 291, \quad |\mathcal{T}(7)| = 367.$$

Remarque 1. *Un hexagone de degré 1 (un seul voisin) n’a pas besoin de contrainte de table : un cycle accolé à un unique voisin par une arête est toujours réalisable, quelle que soit sa taille.*

4.4 Rupture de symétrie

Deux substitutions qui ne diffèrent que par une symétrie du benzénoïde décrivent la *même* molécule. Pour ne les compter qu’une fois, on exploite le groupe des automorphismes du graphe dual, $\text{Aut}(G_D)$ (les permutations des sommets qui préservent les arêtes), dont on calcule un ensemble générateur $\{\pi_1, \dots, \pi_m\}$. Pour chaque générateur π , on impose une contrainte *lex-leader*

$$(x_0, x_1, \dots, x_{h-1}) \leq_{\text{lex}} (x_{\pi(0)}, x_{\pi(1)}, \dots, x_{\pi(h-1)}),$$

qui ne retient, dans chaque orbite de solutions équivalentes, que le représentant minimal pour l’ordre lexicographique. Cette technique élimine les doublons et réduit fortement l’espace de recherche. Sa validité repose sur l’unicité du plongement planaire des graphes considérés (théorème de Whitney [7] et 2-connexité des benzénoïdes).

4.5 Résolution

Le modèle (variables, domaines, contraintes C1, C3 et lex-leader) est écrit en PyCSP3, puis compilé au format standard XCSP3. Le solveur ACE est ensuite invoqué pour **énumérer toutes les solutions** de l’instance. Chaque solution est un vecteur de tailles $(x_0, \dots, x_{h-1})$ qui sera, à l’étape suivante, reconstruit en une molécule tridimensionnelle puis validé.

5 Réalisation : des solutions du modèle aux molécules validées et analysées

Le modèle de la section 4 produit des *vecteurs de tailles* $(x_0, \dots, x_{h-1})$: des objets abstraits. Cette section décrit comment on en fait des molécules réelles, comment on tranche leur planéité, et comment on analyse leurs propriétés électroniques. Elle regroupe l’essentiel du travail d’implémentation.

5.1 Reconstruction 3D des solutions

Chaque solution du modèle est un vecteur de tailles $(x_0, \dots, x_{h-1})$ indiquant la taille assignée à chaque hexagone. Pour en faire une molécule tridimensionnelle exploitable, on procède en trois phases : modification topologique du graphe carbone, placement géométrique des sommets, puis assemblage en molécule (liaisons doubles et hydrogènes).

5.1.1 Modifications topologiques du graphe carbone

Le graphe carbone initial est celui du benzénoïde de départ : chaque hexagone est un cycle à six sommets, et deux hexagones adjacents partagent une arête (donc deux sommets). Lorsque la solution affecte une taille $x_v \neq 6$ à un hexagone v , il faut transformer ce cycle en un pentagone ou un heptagone *sans* perturber les arêtes partagées avec ses voisins.

Repérage des côtés libres. Rappelons que le motif d’occupation $\sigma(v) \in \{0, 1\}^6$ indique pour chacun des six côtés du cycle s’il est partagé avec un voisin ($\sigma_i = 1$) ou *libre* ($\sigma_i = 0$). Les modifications topologiques opèrent exclusivement sur les sommets adjacents à des côtés libres ; les sommets attenants à au moins un côté partagé sont *gelés*, sans quoi la modification briserait la fusion avec un voisin.

Contraction en pentagone ($x_v = 5$). On supprime un sommet du cycle parmi les sommets libres, en privilégiant celui qui se trouve au milieu d’un bloc de côtés libres consécutifs ; ses deux voisins dans le cycle sont alors reliés directement, réduisant le cycle de six à cinq sommets. Le choix du sommet à supprimer est unique lorsque l’hexagone possède un seul bloc libre (cas garanti par la condition $b(v) \leq 1$ pour les hexagones non gelés, section 4).

Dilatation en heptagone ($x_v = 7$). On insère un nouveau sommet entre deux sommets libres consécutifs (au milieu du bloc libre), ce qui ajoute une arête au cycle et le porte à sept sommets.

Effet sur les voisins. Une fois le cycle modifié, sa nouvelle séquence ordonnée de sommets est conservée dans la structure de données du graphe carbone afin que les cycles voisins continuent à le référencer correctement via leurs sommets partagés.

5.1.2 Placement géométrique

Une fois la topologie fixée (chaque cycle connaît sa liste ordonnée de sommets), il reste à attribuer à chaque sommet une position dans le plan. L’idée est de poser chaque cycle comme un *polygone régulier* de longueur de côté $\ell = 1,4$ Å (longueur typique d’une liaison carbone-carbone), en respectant les contraintes de partage d’arête entre cycles adjacents.

Rayon des cycles. Le rayon r_n du cercle circonscrit à un polygone régulier de n côtés de longueur ℓ vaut

$$r_n = \frac{\ell}{2 \sin(\pi/n)}.$$

Numériquement, $r_5 \approx 1,19$, $r_6 \approx 1,40$, $r_7 \approx 1,61$ (en angströms).

Parcours en largeur du graphe dual. Le placement s’effectue par un parcours en largeur (*BFS*) du graphe dual G_D à partir d’un cycle **ancre** — choisi de plus haut degré, ce qui maximise les contraintes immédiates de partage et stabilise la géométrie. Le cycle ancre est dessiné centré à l’origine, dans une orientation canonique. Chaque cycle suivant est placé *relativement à un parent déjà placé*, via l’arête $e = \{a, b\}$ qu’ils partagent.

Positionnement d'un cycle enfant. Soit c un cycle à placer, parent p , arête partagée $\{a, b\}$ déjà positionnée aux coordonnées $\mathbf{x}_a, \mathbf{x}_b$. On calcule :

- (i) le *milieu* de l'arête $\mathbf{m} = (\mathbf{x}_a + \mathbf{x}_b)/2$;
- (ii) la *distance apothème* du cycle enfant $a_{n_c} = r_{n_c} \cos(\pi/n_c)$, où n_c est la taille de c ;
- (iii) la *normale unitaire* $\mathbf{n}$ à l'arête $\{a, b\}$, orientée *vers le demi-plan opposé au parent* (le centre de p est d'un côté de la droite (ab) , on prend l'autre) ;
- (iv) le centre du cycle enfant $\mathbf{c} = \mathbf{m} + a_{n_c} \mathbf{n}$.

Les $n_c - 2$ sommets restants du cycle enfant sont alors disposés sur le cercle de centre $\mathbf{c}$ et de rayon r_{n_c} , dans l'ordre cyclique donné par la topologie, en partant de a et en allant vers b par le côté opposé au parent.

Le choix de l'orientation par rapport au parent (étape (iii)) garantit que la structure ne se replie pas sur elle-même : chaque cycle enfant est posé du *bon côté* de son arête de fusion. Lorsqu'un cycle a plusieurs parents déjà placés (cas de cycles internes au benzénoïde), seul le premier rencontré dans le BFS est utilisé pour le placer, et les positions imposées par les autres parents sont vérifiées *a posteriori* pour cohérence ; la topologie en amont garantit qu'elles coïncident dans la limite des polygones réguliers.

Algorithme. Pseudo-code synthétique :

```

placer le cycle ancre à l'origine, oriente canoniquement
file = [ancre]
tant que file non vide :
    c = file.popleft()
    pour chaque voisin v de c dans GD non encore placé :
        {a, b} = arête partagée entre c et v
        placer le centre de v à  $\mathbf{m} + a_{n_v} \cdot \mathbf{n}$ 
        placer les sommets libres de v sur le cercle de rayon  $r_{n_v}$ 
        file.append(v)

```

5.1.3 Assemblage moléculaire

Une fois tous les sommets placés en 2D (avec $z = 0$), il reste à transformer la géométrie en une véritable molécule. On effectue trois opérations :

- **Liaisons doubles.** On calcule un *couplage de cardinalité maximale* sur le graphe carbone par l'algorithme de Blossom [6], et chaque arête du couplage est marquée comme liaison double. Les carbones non couverts par le couplage sont les sites radicalaires.
- **Ajout des hydrogènes.** Tout carbone du bord, c'est-à-dire de degré 2 dans le graphe carbone, possède une valence libre : on lui attache un atome d'hydrogène, placé radialement vers l'extérieur du cycle auquel il appartient, à une distance de 1,088 Å (longueur typique de la liaison C-H).
- **Export.** La géométrie complète (carbones et hydrogènes, avec coordonnées) est exportée au format XYZ, lisible par xTB.

La géométrie ainsi produite est *plane par construction* : tous les atomes sont dans le plan $z = 0$. C'est l'étape de validation xTB (section suivante) qui révélera si la molécule est réellement plane à l'équilibre, ou si l'optimisation la fait quitter le plan.

5.2 Validation par xTB : protocole de dynamique moléculaire

L'optimisation xTB procède par descente de gradient. Or si la géométrie initiale est *parfaitement* plane, les forces perpendiculaires au plan sont nulles par symétrie : l'optimiseur reste alors piégé dans un **minimum plat parasite** et conclut à tort que la molécule est plane. Nous l'avons

constaté en comparant deux géométries initiales planes du même benzénoïde, qui convergeaient l’une vers une forme plane, l’autre vers une forme courbée à 58,6°.

Le protocole retenu contourne ce piège par une **dynamique moléculaire** courte (GFN2-xTB, ~ 300 K) qui « secoue » la molécule pour la sortir du faux équilibre, suivie d’une optimisation (`-opt tight`) depuis la dernière configuration, qui fournit la géométrie d’équilibre. Un filtre anti-fragmentation rejette les trajectoires où un atome s’éjecte. C’est l’équivalent numérique de la procédure suggérée par le chimiste : *déplacer un atome et vérifier s’il revient à sa place*. Deux variantes ont été testées : **multi-runs** (plusieurs optimisations indépendantes avec une légère perturbation aléatoire en z , la molécule étant déclarée plane si *au moins une* converge plane) et **z-perturb** (perturbation déterministe, calculée par hachage du fichier, donc reproductible). Le protocole MD est la stratégie par défaut.

5.3 Test de planéité par analyse en composantes principales

Une fois la géométrie optimisée par xTB, on doit décider si la molécule est plane. La géométrie est donnée par un nuage de N points dans $\mathbb{R}^3$ (les positions des N carbones), et la question revient à mesurer dans quelle mesure ce nuage est contenu dans un même plan.

Calcul du plan moyen par ACP. On utilise une **analyse en composantes principales** (ACP). Soit $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathbb{R}^3$ les coordonnées des carbones. On centre le nuage en soustrayant le barycentre $\bar{\mathbf{x}} = \frac{1}{N} \sum_i \mathbf{x}_i$, puis on forme la matrice de covariance 3×3

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

La diagonalisation de Σ fournit trois vecteurs propres orthonormés $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ associés aux valeurs propres $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$. Les deux premiers vecteurs engendrent le *plan moyen* du nuage (celui qui minimise la somme des carrés des distances des atomes au plan) et $\mathbf{v}_3$ est sa **normale**. La plus petite valeur propre λ_3 mesure l’épaisseur quadratique moyenne du nuage par rapport à ce plan ; elle est nulle si et seulement si tous les atomes sont parfaitement coplanaires.

Métriques globales. À partir de cette décomposition, on calcule plusieurs grandeurs globales :

- le *rmsd plan* : la racine de la moyenne des carrés des distances des atomes au plan moyen, $\sqrt{\frac{1}{N} \sum_i (\mathbf{n}^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2}$, qui mesure l’épaisseur typique du nuage ;
- la *hauteur* : l’amplitude (max – min) des projections des atomes sur la normale, qui mesure l’épaisseur *extrême* du nuage ;
- l’angle entre $\mathbf{v}_3$ et l’axe Z global, qui n’a qu’une valeur diagnostique (vérifier que la molécule ne s’est pas *simplement* inclinée sans se déformer).

La métrique décisive : max_angle_deg. Aucune de ces métriques globales ne suffit. Une molécule peut être très peu épaisse globalement mais comporter un *bombement local* significatif sur quelques cycles seulement ; à l’inverse, une légère inclinaison d’ensemble gonfle artificiellement le rmsd. La métrique réellement décisive, validée par le chimiste, mesure l’angle de chaque cycle par rapport au plan moyen.

Pour chaque cycle C de la molécule (pentagone, hexagone ou heptagone), on applique la même ACP à ses seuls sommets : on obtient une normale locale $\mathbf{n}_C$. L’angle entre cette normale locale et la normale globale $\mathbf{v}_3$ mesure le « gauchissement » du cycle. La métrique **max_angle_deg** est la valeur maximale de cet angle sur l’ensemble des cycles :

$$\text{max_angle_deg} = \max_{C \in \text{cycles}} \arccos(|\mathbf{n}_C \cdot \mathbf{v}_3|),$$

exprimée en degrés (la valeur absolue $|\cdot|$ règle l’ambiguïté de signe de la normale). Le maximum garantit qu’aucun cycle n’est trop incliné par rapport à l’ensemble.

Critère de décision. Le critère retenu, fixé par le chimiste après examen de cas-tests, est

$$\boxed{\text{molécule plane} \iff \text{max_angle_deg} \leq 10^\circ.}$$

Le seuil de 10° tolère les déformations légères dues aux contraintes stériques inévitables (les hydrogènes peuvent dévier le plan localement) sans accepter de molécules visiblement courbées. En combinant le statut du protocole MD (terminé ou échoué, voir section précédente) et ce test, chaque solution reçoit un verdict final : PLAN, NON-PLAN, ou ÉCHEC MD.

5.4 Analyse électronique des structures

Une fois les structures planes obtenues, nous avons développé un outil pour en étudier les propriétés électroniques. Ces analyses sont *statiques* : elles opèrent directement sur le graphe carbone (sans nouveau calcul quantique) et sont donc quasi instantanées.

- **Kekulé et radicaux.** On calcule un couplage de cardinalité maximale (Blossom) ; les Kekulé sont énumérés par retour arrière (avec un plafond). Les carbones non couverts sont les sites radicalaires.
- **Couvertures de Clar.** On énumère les sous-ensembles d’hexagones deux à deux disjoints (au plus $2^{n_{\text{hex}}}$, trivial pour $n_{\text{hex}} \leq 9$) et l’on couple le résidu ; seuls les hexagones portent un sextet (règle de Hückel).
- **Extension du RBO aux cycles 5 et 7.** La définition de Pauling–Randić [11], reprise par Varet, ne concerne que les hexagones. Notre contribution est de conserver la formule $\text{CBO}(C) = \sum_{e \in C} \text{bo}(e)$ *sommée sur tout cycle quelle que soit sa taille*, en affichant le ratio $\text{CBO}/\text{cbo}_{\text{max}}$ pour rester fidèle au contexte. Le cas radicalaire (aucune Kekulé stricte) n’est pas défini au sens de Pauling–Randić.

Remarque 2 (Pourquoi l’énumération directe plutôt qu’une méthode polynomiale). *Le comptage rapide des Kekulé des benzénoïdes (méthode de Rispoli [12]) repose sur le caractère biparti du graphe carbone. Les cycles impairs (5 ou 7) brisent cette bipartition ; la généralisation passe par le théorème de Kasteleyn [13] (orientation et Pfaffien), d’un coût d’implémentation jugé hors du périmètre du stage. Nous nous en tenons à l’énumération directe, suffisante car les cycles 5/7 contraignent fortement les couplages.*

À ce stade, cet outillage est *opérationnel* mais l’exploration reste préliminaire : nous avons par exemple cherché un lien entre planéité et nombre de radicaux sans dégager de corrélation exploitable. Nous le présentons comme un moyen d’analyse des structures produites et une piste à approfondir.

5.5 Mise en œuvre logicielle

Le stage relevant de l’IMD et non du génie logiciel, nous décrivons ce volet brièvement. L’ensemble du pipeline est intégré dans une application web (le *designer*) : un canevas hexagonal permet de dessiner ou d’importer un benzénoïde et de choisir la configuration de contraintes, puis de lancer la génération. Les résultats (solutions, géométries XYZ compressées, agrégats) sont persistés dans une base SQLite, et les campagnes sur le grand corpus sont distribuées sur un cluster. Un visualiseur 3D propose quatre modes d’affichage (défaut, Kekulé, Clar, RBO). Ce travail d’industrialisation garantit surtout la *reproductibilité* des expériences décrites ci-dessous.

6 Étude expérimentale : quelles contraintes améliorent la planéité ?

Comme établi en section 3, la planéité est une propriété globale qu’aucun jeu de contraintes locales ne capture exactement. La question pratique devient alors : *quelles contraintes additionnelles augmentent le plus la proportion de molécules planes parmi celles que le modèle génère ?* Nous y répondons par une démarche expérimentale en trois temps.

Remarque 3. Les valeurs chiffrées de cette section sont laissées en attente (*−?−*, **[À COMPLÉTER :]**) : le corpus de résultats doit être régénéré sur la version définitive de la table de voisinage avant intégration au mémoire.

6.1 Protocole et banc d’essai

Le banc d’essai utilise les squelettes benzénoïdes canoniques de la base *BenzaiDB*, de h_3 à h_9 hexagones (tableau 1). La métrique principale est le **taux de planéité** : la proportion de solutions jugées planes par le pipeline xTB+ACP, complétée par le *nombre absolu* de molécules planes produites. Les campagnes sont reproductibles, agrégées en base SQLite, et chaque configuration de contraintes est comparée terme à terme aux autres sur le même corpus.

h	h_3	h_4	h_5	h_6	h_7	h_8	h_9
nombre de squelettes	<i>−?−</i>	<i>−?−</i>	<i>−?−</i>	44	126	376	2 418

TABLE 1 – Nombre de squelettes benzénoïdes de *BenzaiDB* par taille h .

6.2 v1 — Modèle de base

La première campagne mesure la référence : avec les seules contraintes structurales (section 4), quelle proportion des solutions est réellement plane après xTB ? Le constat est que ce taux est médiocre et *décroît fortement* quand h augmente (*−?−*). Au-delà de la mesure, v1 a surtout servi à mettre au point et stabiliser le pipeline complet (reconstruction $\rightarrow$ MD $\rightarrow$ optimisation $\rightarrow$ ACP).

6.3 v2 — Contraintes globales : pentagones en bord

L’idée de v2 est de traduire en contraintes *a priori* deux régularités empiriques observées sur les premières données : un équilibre entre pentagones et heptagones, et la localisation des pentagones sur le bord. On introduit donc deux contraintes optionnelles paramétrées :

$$(\text{C-SYM}) \quad |n_5 - n_7| \leq K_{\text{sym}}, \quad (\text{C-PB}) \quad \sum_{v \in \partial G_D} \mathbf{1}[x_v = 5] \leq K_{\text{pb}}.$$

Les résultats sont nets. La contrainte de symétrie **C-SYM** est **sans effet** mesurable : l’équilibre $n_5 = n_7$ est déjà imposé par C1, et le filtrage par la table produit des compositions équilibrées. En revanche, **plafonner les pentagones de bord est le levier dominant** : avec $K_{\text{pb}} = 1$ (préréglage pb1), le taux de planéité gagne **[À COMPLÉTER : +X à +Y points]** sur l’ensemble des tailles, tandis que $K_{\text{pb}} = 0$ rend le problème insatisfiable. Le préréglage pb1 génère beaucoup moins de solutions, mais une proportion bien plus élevée d’entre elles est plane (compromis volume / qualité favorable à l’aval).

6.4 v3 — Contraintes locales : appariement 5–7 (Stone–Wales)

v3 explore deux raffinements *locaux*. Le premier borne la courbure de Gauss–Bonnet dans un disque de rayon R autour de chaque hexagone ($|n_5 - n_7| \leq \tau$ localement, contrainte C-LC) ; il s’avère **redondant** avec pb1. Le second impose l’**adjacence** 5–7 (contrainte C5) : tout pentagone

passage à l'échelle au-delà de h_9 et la poursuite du dialogue avec les chimistes — pour affiner les critères d'admissibilité et explorer la chimie radicalaire que les structures 5/7 produisent naturellement — prolongeraient naturellement ce travail.

Références

- [1] A. Varet, *Programmation par contraintes et chimie théorique : utilisation du formalisme CSP pour résoudre des problématiques liées aux benzénoïdes*, thèse de doctorat, Aix-Marseille Université, 2022.
- [2] F. Rossi, P. van Beek, T. Walsh (éds.), *Handbook of Constraint Programming*, Elsevier, 2006.
- [3] C. Lecoutre, *Constraint Networks : Techniques and Algorithms*, ISTE/Wiley, 2009.
- [4] C. Lecoutre, N. Szczepanski, *PyCSP3 : modélisation en programmation par contraintes* et le solveur *ACE* (Abscon Constraint Engine). pyscp.org.
- [5] Y. Carissan, D. Hagebaum-Reignier, N. Prkovic, C. Terrioux, A. Varet, *BenzAI : un logiciel pour la conception et l'étude des benzénoïdes*. **[À COMPLÉTER : référence exacte à compléter]**
- [6] J. Edmonds, *Paths, trees, and flowers*, Canadian Journal of Mathematics, 17 :449–467, 1965.
- [7] H. Whitney, *Congruent graphs and the connectivity of graphs*, American Journal of Mathematics, 54(1) :150–168, 1932.
- [8] E. Clar, *The Aromatic Sextet*, John Wiley & Sons, Londres, 1972.
- [9] E. Hückel, *Quantentheoretische Beiträge zum Benzolproblem*, Zeitschrift für Physik, 70 :204–286, 1931 (règle des $4n + 2$ électrons π).
- [10] L. Pauling, *The Nature of the Chemical Bond*, Cornell University Press, 3^e édition, 1960.
- [11] M. Randić, *Aromaticity and conjugation*, Journal of the American Chemical Society, 99(2) :444–450, 1977 (ordres de liaison et circuits conjugués).
- [12] E. Rispoli, comptage des structures de Kekulé d'un benzénoïde par le déterminant de la matrice de biadjacence, 2001. **[À COMPLÉTER : référence exacte à compléter]**
- [13] P. W. Kasteleyn, *Graph theory and crystal physics*, in *Graph Theory and Theoretical Physics*, Academic Press, p. 43–110, 1967.
- [14] A. J. Stone, D. J. Wales, *Theoretical studies of icosahedral C_{60} and some related species*, Chemical Physics Letters, 128(5–6) :501–503, 1986.
- [15] C. Bannwarth, S. Ehlert, S. Grimme, *GFN2- xTB — An Accurate and Broadly Parametrized Self-Consistent Tight-Binding Quantum Chemical Method*, Journal of Chemical Theory and Computation, 15(3) :1652–1671, 2019.