

Mémoire de stage de Master 2  
Informatique et Mathématiques Discrètes (IMD)  
Année universitaire 2025–2026

---

# Génération automatique et exhaustive de structures moléculaires bi-dimensionnelles par programmation par contraintes

---

Toky Nirina RAMAHERISOA

**Encadrants** Nicolas PROCOVIC et Cyril TERRIOUX  
*LIS, équipe COALA, Aix-Marseille Université*

**Partenaires** Yannick CARISSAN et Denis HAGEBAUM-REIGNIER  
*Institut des Sciences Moléculaires de Marseille (iSm2)*

# Table des matières

|          |                                                                                  |           |
|----------|----------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                                              | <b>4</b>  |
| 1.1      | Contexte . . . . .                                                               | 4         |
| 1.2      | Objectif et problématique . . . . .                                              | 4         |
| 1.3      | Positionnement et contributions . . . . .                                        | 4         |
| <b>2</b> | <b>Préliminaires et état de l’art</b>                                            | <b>5</b>  |
| 2.1      | Notions de chimie . . . . .                                                      | 5         |
| 2.1.1    | Définitions préliminaires . . . . .                                              | 5         |
| 2.1.2    | HAP, benzénoïdes et graphe dual . . . . .                                        | 5         |
| 2.1.3    | Aromaticité et délocalisation . . . . .                                          | 6         |
| 2.1.4    | Structures de Kekulé . . . . .                                                   | 7         |
| 2.1.5    | Sextets et couvertures de Clar . . . . .                                         | 7         |
| 2.1.6    | Ring Bond Order (RBO) . . . . .                                                  | 8         |
| 2.1.7    | Sites radicalaires . . . . .                                                     | 9         |
| 2.1.8    | Planéité et courbure . . . . .                                                   | 10        |
| 2.1.9    | Validation quantique semi-empirique (xTB) . . . . .                              | 10        |
| 2.2      | Programmation par contraintes (PPC) . . . . .                                    | 10        |
| 2.2.1    | Réseau de contraintes . . . . .                                                  | 10        |
| 2.2.2    | Un exemple : le Sudoku . . . . .                                                 | 11        |
| 2.2.3    | Résolution : propagation et recherche arborescente . . . . .                     | 11        |
| 2.2.4    | Contraintes en extension et contraintes globales . . . . .                       | 12        |
| 2.2.5    | Isomorphisme de graphes . . . . .                                                | 13        |
| <b>3</b> | <b>Le problème</b>                                                               | <b>13</b> |
| 3.1      | La difficulté combinatoire . . . . .                                             | 14        |
| 3.2      | La difficulté géométrique et topologique . . . . .                               | 14        |
| <b>4</b> | <b>Modélisation</b>                                                              | <b>15</b> |
| 4.1      | Variables et domaines . . . . .                                                  | 15        |
| 4.2      | Préalable : motif d’occupation $\sigma(v)$ et blocs libres . . . . .             | 15        |
| 4.3      | Contraintes . . . . .                                                            | 16        |
| 4.3.1    | Contraintes structurelles (C1–C3) . . . . .                                      | 16        |
| 4.4      | Résolution . . . . .                                                             | 20        |
| <b>5</b> | <b>Réalisation : des solutions du modèle aux molécules validées et analysées</b> | <b>20</b> |
| 5.1      | Reconstruction 3D, validation et test de planéité . . . . .                      | 20        |
| 5.1.1    | Reconstruction 3D des solutions . . . . .                                        | 21        |
| 5.1.2    | Validation par xTB : protocole d’optimisation déterministe . . . . .             | 22        |
| 5.1.3    | Test de planéité . . . . .                                                       | 22        |
| 5.2      | Analyse électronique des structures . . . . .                                    | 23        |
| 5.3      | Le designer : interface et pipeline intégré . . . . .                            | 24        |
| <b>6</b> | <b>Étude expérimentale</b>                                                       | <b>25</b> |

|          |                                                                        |           |
|----------|------------------------------------------------------------------------|-----------|
| 6.1      | Protocole et banc d'essai . . . . .                                    | 25        |
| 6.2      | Environnement logiciel et reproductibilité . . . . .                   | 25        |
| 6.3      | Comparaison du solveur ACE vs Choco . . . . .                          | 26        |
| 6.4      | <b>Cf<sub>1</sub></b> : Baseline (contraintes structurelles) . . . . . | 27        |
| 6.5      | <b>Cf<sub>2</sub></b> : Pb1 + adjacence 5–7 (motif azulène) . . . . .  | 27        |
| 6.6      | <b>Cf<sub>3</sub></b> : Interdire les paires 7–7 adjacentes . . . . .  | 28        |
| 6.7      | <b>C<sub>topo</sub></b> : Topologie complète . . . . .                 | 28        |
| 6.8      | Bilan expérimental . . . . .                                           | 29        |
| <b>7</b> | <b>Conclusion et perspectives</b>                                      | <b>30</b> |
| 7.1      | Conclusion . . . . .                                                   | 30        |
| 7.2      | Perspectives . . . . .                                                 | 30        |
| <b>A</b> | <b>Annexe</b>                                                          | <b>31</b> |
| A.1      | Définitions formelles de cohérence . . . . .                           | 31        |
| A.2      | Règle de Hückel . . . . .                                              | 31        |
| A.3      | Protocole de validation xTB (détails) . . . . .                        | 31        |
| A.4      | Calcul de la métrique dièdre <code>max_dihedral_deg</code> . . . . .   | 32        |
| A.5      | Interface du designer (détails) . . . . .                              | 32        |
| A.6      | Détails de l'assemblage moléculaire . . . . .                          | 34        |

## Table des figures

|    |                                                                                                                                                                                              |    |
|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1  | Deux exemples de HAP avec leurs hydrogènes explicites : l'azulène ( $C_{10}H_8$ ) (à gauche), et un benzénoïde à six hexagones (à droite) . . . . .                                          | 4  |
| 2  | Graphe de carbone de l'azulène (à gauche, cycles indexés 0 et 1) et d'un benzénoïde non linéaire à six hexagones (à droite, $v_0, \dots, v_5$ ) . . . . .                                    | 6  |
| 3  | Graphe dual de l'azulène et du benzénoïde de la figure 2 . . . . .                                                                                                                           | 6  |
| 4  | Les trois structures de Kekulé du naphthalène. . . . .                                                                                                                                       | 7  |
| 5  | Représentation d'un sextet de Clar. . . . .                                                                                                                                                  | 8  |
| 6  | Les deux couvertures de Clar du naphthalène . . . . .                                                                                                                                        | 8  |
| 7  | Un pentagone accolé à un hexagone . . . . .                                                                                                                                                  | 10 |
| 8  | Un Sudoku partiellement rempli (à gauche). À droite, la valeur de la case $x_{ij}$ doit différer de toutes les autres cases de sa ligne, de sa colonne et de son bloc $3 \times 3$ . . . . . | 11 |
| 9  | Mise en évidence des carbones et des arêtes partagés . . . . .                                                                                                                               | 14 |
| 10 | Motif d'occupation $\sigma(v_1)$ pour le sommet central du benzénoïde de la figure 2. . . . .                                                                                                | 16 |
| 11 | Anthracène et transformation du cycle central en heptagone. . . . .                                                                                                                          | 19 |
| 12 | Visualiseur des structures de Kekulé. . . . .                                                                                                                                                | 23 |
| 13 | Visualiseur en mode Clar. . . . .                                                                                                                                                            | 24 |
| 14 | Visualiseur en mode RBO. . . . .                                                                                                                                                             | 24 |
| 15 | Pipeline intégré du designer, de la saisie au résultat exploré. . . . .                                                                                                                      | 25 |
| 16 | Distribution des temps d'exécution : ACE vs Choco par le corpus $h_3 - h_9$ . . . . .                                                                                                        | 26 |
| 17 | Temps moyen d'exécution par configuration (barres d'erreur = $\pm 1$ écart-type) . . . . .                                                                                                   | 27 |
| 18 | Designer en mode saisie : canevas hexagonal pour dessiner un benzénoïde ou choisir un benzenoïde importé depuis BenzDB. . . . .                                                              | 33 |
| 19 | Liste des solutions avec tri et filtrage. . . . .                                                                                                                                            | 34 |

## Liste des tableaux

|   |                                                                                                                                                                                                               |    |
|---|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1 | Nombre de squelettes benzénoïdes <b>plans</b> du corpus par taille $h$ , issus de BenzDB. . . . .                                                                                                             | 25 |
| 2 | Stack logicielle du pipeline et du designer. . . . .                                                                                                                                                          | 26 |
| 3 | Résultats de la configuration $Cf_1$ (baseline). $N_A$ : nombre cumulé de solutions planes ou acceptables (dièdre $< 25^\circ$ ), incluant les solutions très planes. %A : proportion correspondante. . . . . | 27 |
| 4 | Résultats de la configuration $Cf_2$ (Pb1 + adj_57). . . . .                                                                                                                                                  | 28 |
| 5 | Résultats de la configuration $Cf_3$ (Gauss-Bonnet local, rayon 2). . . . .                                                                                                                                   | 28 |
| 6 | Résultats de la configuration $C_{\text{topo}}$ (topologie complète, applicable à partir de $h_6$ ). . . . .                                                                                                  | 29 |

## Liste des algorithmes

|   |                                                                              |    |
|---|------------------------------------------------------------------------------|----|
| 1 | Positionnement d'un cycle enfant relativement à son parent. . . . .          | 21 |
| 2 | Placement géométrique global par parcours en largeur du graphe dual. . . . . | 22 |

# 1 Introduction

## 1.1 Contexte

Les *hydrocarbures aromatiques polycycliques* (HAP) sont des molécules constituées uniquement de carbone et d'hydrogène, dont les atomes de carbone forment des cycles fusionnés. Ils sont étudiés pour leurs propriétés électroniques et opto-électroniques. Parmi les HAP, les *benzénoïdes* forment la sous-famille composée exclusivement d'hexagones fusionnés par une arête. Cette famille a fait l'objet de nombreux travaux, et notamment de la thèse de A. Varet [1], qui a montré que la *programmation par contraintes* (PPC) est un outil particulièrement adapté à la génération exhaustive de benzénoïdes répondant à des propriétés données.

L'étude des HAP comportant des cycles à *cinq* ou *sept* atomes de carbone, dits *non-benzénoïdes*, est plus récente. L'azulène, formé d'un pentagone et d'un heptagone accolés (figure 1), en est l'exemple emblématique. L'introduction de tels cycles modifie en profondeur la chimie de la molécule : elle brise la régularité du pavage hexagonal, induit une courbure locale, et favorise l'apparition de sites radicalaires. Ces structures intéressent donc les chimistes, mais leur génération systématique reste largement inexplorée.




FIGURE 1 – Deux exemples de HAP avec leurs hydrogènes explicites : l'azulène ( $C_{10}H_8$ ) (à gauche), et un benzénoïde à six hexagones (à droite)

**Remarque 1.** Pour alléger la lecture, les figures suivantes ne représenteront plus explicitement les atomes d'hydrogène ni les liaisons C-H.

## 1.2 Objectif et problématique

L'objectif du stage est le suivant : *étant donné un benzénoïde, énumérer de manière exhaustive toutes les substitutions admissibles dans lesquelles chaque hexagone est soit conservé, soit remplacé par un cycle à 5 ou 7 atomes*. La difficulté est double, à la fois combinatoire et géométrique. Nous en donnons l'énoncé précis et l'analyse détaillée à la section 3, une fois introduit le vocabulaire nécessaire.

## 1.3 Positionnement et contributions

Ce stage se place dans la continuité directe de la thèse de Varet [1] : nous reprenons son cadre (modélisation PPC sur le *graphe dual* d'un benzénoïde, notions d'aromaticité) et nous l'étendons au cas, non traité jusqu'ici, des cycles à 5 et 7 atomes. Nos contributions sont les suivantes.

- Un **modèle PPC** qui énumère exhaustivement les substitutions 5/6/7 d'un benzénoïde, fondé sur une *table de voisinage* encodant les configurations locales chimiquement réalisables.
- Un **pipeline de validation physique** qui reconstruit en trois dimensions chaque solution du modèle, l'optimise par une méthode quantique semi-empirique (xTB), puis juge sa planéité.

- Une **étude expérimentale systématique** de contraintes additionnelles visant à augmenter la proportion de molécules planes produites. Ce point mérite une précision : la planéité d'une molécule est une propriété *globale* qui ne se laisse pas exprimer entièrement par des contraintes locales — c'est une difficulté intrinsèque au problème, et non un défaut de modélisation. Notre démarche consiste à identifier expérimentalement les contraintes qui, sans capturer la planéité au sens strict, en améliorent significativement le rendement.
- Une **extension de l'analyse électronique** (structures de Kekulé, couvertures de Clar, *Ring Bond Order*) aux cycles à 5 et 7 atomes, là où les outils existants se limitent aux hexagones.

Le mémoire est organisé comme suit. La section 2 introduit les deux corpus de notions nécessaires. La section 3 détaille le problème et ses difficultés. La section 4 présente notre modélisation. La section 5 décrit la réalisation (reconstruction, validation, analyse). La section 6 rapporte l'étude expérimentale, et la section 7 conclut.

## 2 Préliminaires et état de l'art

Notre travail se situe à l'interface de la chimie théorique et de l'informatique. Les notions nécessaires à la lecture du mémoire sont d'abord celles de la chimie des HAP, puis le formalisme de la programmation par contraintes.

### 2.1 Notions de chimie

Les termes de chimie employés dans la suite peuvent être lus aussi bien comme des définitions sur des graphes que comme le vocabulaire chimique usuel.

#### 2.1.1 Définitions préliminaires

Avant d'introduire les notions spécifiques aux HAP, nous rappelons brièvement le vocabulaire chimique de base utilisé dans le mémoire.

Atome et molécule : un atome est l'unité élémentaire de la matière chimique ; dans ce travail, seuls deux types interviennent : le carbone (C) et l'hydrogène (H). Une molécule est un assemblage stable d'atomes reliés par des liaisons covalentes.

Liaison covalente, simple et double : une liaison covalente résulte du partage d'une ou plusieurs paires d'électrons entre deux atomes. On parle de liaison *simple* lorsqu'une seule paire est partagée, de liaison *double* lorsque deux paires le sont.

Valence : la valence d'un atome est le nombre de liaisons qu'il peut former. Le carbone est tétravalent (quatre liaisons), l'hydrogène monovalent (une liaison).

Électrons  $\sigma$  et  $\pi$  : les électrons d'une liaison covalente se répartissent en deux types selon la géométrie du recouvrement orbitalaire. Une liaison simple est constituée d'une paire d'électrons formant une *liaison  $\sigma$* , qui appartient au squelette rigide de la molécule. Une liaison double comporte deux paires : la première forme également une liaison  $\sigma$ , la seconde une *liaison  $\pi$* , dont les électrons occupent des orbitales perpendiculaires au plan local et sont *plus faiblement localisés*.

#### 2.1.2 HAP, benzénoïdes et graphe dual

Les **hydrocarbures aromatiques polycycliques** (HAP) sont des molécules formées exclusivement d'atomes de carbone et d'hydrogène, dont les carbones constituent un assemblage de cycles fusionnés. Lorsque ces cycles sont exclusivement des hexagones, on parle de **benzénoïde** — le naphthalène ou le pyrène en sont des exemples typiques. Mais certains HAP comportent aussi des cycles à cinq ou sept atomes : on les appelle **non-benzénoïdes**, comme l'azulène (figure 1). Ce sont

précisément ces structures qui nous intéressent dans ce travail, en raison de leurs propriétés électroniques particulières : les électrons  $\pi$  introduits à la section 2.1.1 s'y répartissent et se délocalisent différemment que dans un pavage hexagonal régulier.

**Définition 1** (Graphe de carbone). *À toute molécule HAP  $M$  on associe son **graphe de carbone**  $G_C(M) = (V_C, E_C)$  : les sommets  $V_C$  sont les atomes de carbone, et les arêtes  $E_C$  représentent les liaisons covalentes carbone-carbone.*

Les hydrogènes périphériques, déduits des valences libres des carbones de bord, n'apparaissent pas dans ce graphe. L'intérêt de cette représentation est de pouvoir raisonner directement sur les **interactions entre atomes de carbone**, indépendamment des hydrogènes périphériques qui n'apportent pas d'information structurale.




FIGURE 2 – Graphe de carbone de l'azulène (à gauche, cycles indexés 0 et 1) et d'un benzénoïde non linéaire à six hexagones (à droite,  $v_0, \dots, v_5$ )

Pour tout HAP, on définit son **graphe dual**  $G_D$ , qui résume les interactions entre les cycles.

**Définition 2** (Graphe dual). *Soit  $M$  un HAP formé de  $n$  cycles. Son graphe dual  $G_D(M) = (V_D, E_D)$  a pour sommets  $V_D = \{0, \dots, n-1\}$  (un sommet par cycle), et  $(u, v) \in E_D$  si et seulement si les cycles  $u$  et  $v$  partagent une arête carbone-carbone.*

Cette construction correspond au *graphe dual intérieur* de la littérature, c'est-à-dire le graphe dual classique privé de la face externe. L'intérêt de cette représentation est de pouvoir raisonner directement sur les **interactions entre cycles** (partage d'arêtes), sans se soucier du détail atomique interne à chaque cycle.

Pour un benzénoïde  $B$ , on note  $n_H(B)$  son nombre d'hexagones ; ainsi  $|V_D(B)| = n_H(B)$ . On appelle **bord** de  $G_D$  l'ensemble des cycles de degré strictement inférieur à 6, c'est-à-dire ceux qui ne sont pas entièrement entourés de voisins. La figure 3 illustre le graphe dual du benzénoïde de la figure 2.




FIGURE 3 – Graphe dual de l'azulène et du benzénoïde de la figure 2

### 2.1.3 Aromaticité et délocalisation

L'**aromaticité** traduit la stabilité particulière de certains cycles conjugués. La *règle de Hückel* (annexe A.2) en donne le critère classique : un cycle est dit aromatique s'il est plan, conjugué, et contient  $4n + 2$  électrons  $\pi$  pour un entier  $n \geq 0$  — le benzène ( $n = 1$ , 6 électrons) en est l'exemple fondamental. Dans un tel cycle, les électrons  $\pi$  sont *délocalisés* et circulent autour du cycle. Plus

une molécule admet de représentations équivalentes de ses liaisons doubles (au sens des structures de Kekulé introduites plus haut), plus la délocalisation est étendue, et plus la molécule est stable.

L'aromaticité « réelle » d'une molécule se calcule en toute rigueur par un calcul quantique *ab initio*, prohibitif sur de grandes séries de molécules. Les structures de Kekulé, le nombre de Clar et le RBO introduits dans cette section en sont autant d'**estimations combinatoires**, calculables instantanément sur le graphe de carbone seul : c'est cette approche, déjà adoptée par Varet [1] pour les benzénoïdes, que nous étendons dans ce travail aux cycles à 5 et 7 atomes.

#### 2.1.4 Structures de Kekulé

Une **structure de Kekulé** est un étiquetage des liaisons carbone-carbone en simples et doubles tel que chaque carbone porte exactement une double liaison. En termes de graphes, c'est un *couplage parfait* du graphe carbone. Une molécule HAP possède en général plusieurs structures de Kekulé, mais il est aussi possible qu'elle n'en possède aucune lorsque son graphe carbone n'admet pas de couplage parfait.

L'intérêt de connaître l'ensemble  $\mathcal{K}(B)$  des structures de Kekulé d'une molécule est de pouvoir, par la suite, estimer sa stabilité et son aromaticité par des moyens purement combinatoires (section 2.1.6), et de détecter ses sites radicalaires lorsque  $\mathcal{K}(B) = \emptyset$ . Mais surtout, une molécule réelle n'adopte pas une structure de Kekulé unique et figée : à un instant donné, on ne peut pas prédire laquelle de ses structures décrit effectivement la molécule, les liaisons doubles se redistribuant en permanence entre les configurations équivalentes (délocalisation, détaillée en section 2.1.3). C'est précisément pour cette raison qu'il est nécessaire d'énumérer *toutes* les structures de Kekulé d'une molécule.




FIGURE 4 – Les trois structures de Kekulé du naphthalène.

#### 2.1.5 Sextets et couvertures de Clar

Un **sextet de Clar** (ou rond de Clar) est un hexagone dont les six électrons  $\pi$  forment un cycle aromatique autonome. Concrètement, on peut le visualiser comme trois liaisons doubles alternées sur le cycle, et on le représente conventionnellement par un cercle inscrit dans l'hexagone (voir figure 5). La règle de Hückel (voir annexe A.2) impose qu'un sextet occupe exactement six atomes ( $4n + 2$  électrons  $\pi$ ,  $n = 1$ ) : seuls les *hexagones* peuvent porter un sextet, jamais un pentagone ni un heptagone.

La clé de la notion de sextet est la **délocalisation** : les six électrons  $\pi$  d'un sextet ne sont pas figés dans une configuration de liaisons doubles particulière, ils *circulent librement* autour du cycle. Autrement dit, la molécule ne possède pas une unique structure de Kekulé fixe : on ne peut pas prédire à l'avance dans quelle configuration elle se trouvera à un instant donné — elle oscille en permanence entre toutes ses structures de Kekulé équivalentes. C'est précisément cette mobilité qui explique qu'une même couverture de Clar puisse correspondre à plusieurs structures de Kekulé.

Une **couverture de Clar** est un choix d'hexagones, disjoints deux à deux, sur lesquels on place un sextet. Le **nombre de Clar** est le plus grand nombre de sextets que l'on peut ainsi placer simultanément.

L'intérêt du nombre de Clar est qu'il fournit une **estimation combinatoire de l'aromaticité** : la couverture qui maximise le nombre de sextets correspond empiriquement à la structure



de résonance la plus stable, qui permette d'éviter un calcul quantique très coûteux. C'est cet avantage — remplacer un calcul quantique par un dénombrement sur le graphe — que nous exploitons systématiquement dans ce travail, à l'instar de Varet [1].




FIGURE 5 – Représentation d'un sextet de Clar.

Une même couverture de Clar peut correspondre à plusieurs structures de Kekulé : sur le naphthalène (figure 6), les Kekulé  $K_1$  et  $K_2$  ne diffèrent que par la rotation des liaisons doubles à l'intérieur de l'hexagone gauche et correspondent toutes deux à la couverture  $C_A$  (sextet sur l'hexagone gauche).  $K_3$  correspond à la couverture  $C_B$  (sextet sur l'hexagone droit). Le nombre de Clar du naphthalène vaut donc 1 : on ne peut placer qu'un seul sextet à la fois, les deux hexagones partageant une arête.




FIGURE 6 – Les deux couvertures de Clar du naphthalène

### 2.1.6 Ring Bond Order (RBO)

Le *ring bond order* (RBO) est une mesure combinatoire de la délocalisation aromatique locale d'un hexagone au sein d'un benzénoïde. Il prolonge le concept de *bond order* introduit par Pauling [12] à partir de la théorie de la résonance, formalisé ensuite comme indicateur cyclique notamment par Randić [13]. Nous reprenons ici les notations de Varet [1].

Comme le nombre de Clar, le RBO permet d'estimer la délocalisation aromatique sans calcul quantique coûteux, mais à une granularité plus fine : il quantifie la délocalisation *par cycle*, et non plus de façon binaire (sextet ou non) à l'échelle de la molécule entière. C'est cette finesse qui nous permettra de comparer des cycles de tailles différentes (pentagones, hexagones, heptagones).

Soit  $B = (V, E)$  le graphe de carbone d'un benzénoïde :  $V$  désigne l'ensemble des atomes de carbone et  $E$  celui des liaisons covalentes entre atomes voisins. On note  $\mathcal{K}(B)$  l'ensemble de ses structures de Kekulé, c'est-à-dire des couplages parfaits du graphe. Lorsque  $\mathcal{K}(B) \neq \emptyset$ , on dit que  $B$  est *Kekuléen* ; dans le cas contraire ( $\mathcal{K}(B) = \emptyset$ ), la molécule est dite *non-Kekuléenne* et admet au moins un *site radicalaire* (voir figure 7 et section 2.1.7).

**Définition 3** (Bond order, [1]). Soient  $B = (V, E)$  un benzénoïde Kekuléen et  $e \in E$  une de ses liaisons. Le bond order de  $e$  est le rapport entre le nombre de structures de Kekulé dans lesquelles  $e$  apparaît comme liaison double et le nombre total de structures de Kekulé de  $B$  :

$$\text{bo}(e) = \frac{|\{K \in \mathcal{K}(B) : e \in K\}|}{|\mathcal{K}(B)|}.$$

C'est une mesure de la délocalisation locale :  $\text{bo}(e) = 1$  signifie que  $e$  est double dans toutes les Kekulé (liaison localisée),  $\text{bo}(e) = 0$  qu'elle est toujours simple, et toute valeur intermédiaire traduit une délocalisation partielle.

**Définition 4** (Ring bond order, [1]). Soient  $B$  un benzénoïde Kekuléen et  $h$  un de ses hexagones. Le ring bond order de  $h$  est la somme des bond order associés aux six liaisons définissant  $h$  :

$$\text{RBO}(h) = \sum_{e \in E(h)} \text{bo}(e),$$

où  $E(h) \subset E$  désigne l'ensemble des six arêtes du cycle  $h$ .

**Remarque 2.** Pour tout hexagone  $h$  d'un benzénoïde Kekuléen, on a  $0 \leq \text{RBO}(h) \leq 3$ . La borne supérieure provient du fait que, dans toute structure de Kekulé  $K \in \mathcal{K}(B)$ , au plus trois arêtes de  $h$  peuvent être doubles dans  $K$  (un couplage parfait restreint aux six sommets de  $h$  comporte au plus trois arêtes). En sommant cette inégalité sur les structures et en divisant par  $|\mathcal{K}(B)|$ , on obtient  $\text{RBO}(h) \leq 3$ .

À titre d'exemple, le benzène admet exactement deux structures de Kekulé, échangées par rotation des liaisons doubles. Chaque arête y est double dans une seule des deux structures :  $\text{bo}(e) = 1/2$  pour les six arêtes, et l'unique hexagone vérifie  $\text{RBO}(h) = 6 \times 1/2 = 3$ , la valeur maximale. Le naphthalène, qui admet trois structures de Kekulé (figure 4), voit chacun de ses deux hexagones atteindre  $\text{RBO}(h) = 8/3 \approx 2,67$  : cette valeur strictement inférieure à 3 traduit la délocalisation partielle propre aux benzénoïdes polycycliques.

**Extension aux cycles de taille quelconque.** La définition précédente du RBO ne concerne que les hexagones d'un benzénoïde, alors que les molécules qui nous intéressent comportent aussi des cycles à cinq et sept atomes. Nous proposons donc d'étendre cette définition à *tout* HAP, quelle que soit la taille de ses cycles, de la manière suivante. Soit  $C$  un cycle de taille  $n$  d'un graphe moléculaire Kekuléen, et  $E(C)$  l'ensemble de ses  $n$  arêtes. On définit le *cycle bond order*

$$\text{CBO}(C) = \sum_{e \in E(C)} \text{bo}(e).$$

Le même argument que ci-dessus donne l'encadrement

$$0 \leq \text{CBO}(C) \leq \lfloor n/2 \rfloor,$$

puisque un cycle de longueur  $n$  ne peut porter, dans une structure de Kekulé donnée, plus de  $\lfloor n/2 \rfloor$  arêtes doubles. Pour comparer la délocalisation entre cycles de tailles différentes, nous reportons systématiquement le ratio normalisé  $\text{CBO}(C)/\lfloor n/2 \rfloor \in [0, 1]$ , qui vaut 1 pour un cycle « parfaitement aromatique » au sens combinatoire. Dans le cas radicalaire où  $\mathcal{K}(B) = \emptyset$ , les quantités  $\text{bo}(e)$ ,  $\text{RBO}(h)$  et  $\text{CBO}(C)$  ne sont pas définies au sens classique.

### 2.1.7 Sites radicalaires

Lorsqu'une molécule n'admet aucun couplage parfait (par exemple à cause d'un nombre impair d'atomes ou d'une topologie particulière), certains carbones restent non couverts : ils portent un **électron  $\pi$  non apparié**, appelé aussi *électron célibataire*. La molécule devient dans ce cas un (mono)radical. La parité impaire des cycles à 5 et 7 atomes favorise précisément l'apparition de tels sites, ce qui rend les structures non-benzénoïdes intéressantes pour la chimie radicalaire.

L'exemple le plus simple est celui d'un pentagone accolé à un hexagone (figure 7) : le squelette compte  $5 + 6 - 2 = 9$  atomes de carbone, un nombre impair. Aucun couplage parfait ne peut donc exister, et au moins un carbone reste non couvert dans toute structure de Kekulé : un site radicalaire est *forcé* par la topologie.




FIGURE 7 – Un pentagone accolé à un hexagone

### 2.1.8 Planéité et courbure

À toute molécule on associe une fonction *énergie potentielle* qui dépend de la position de ses atomes ; cette énergie est minimale lorsque les longueurs et les angles de liaison correspondent aux préférences de chaque atome et que les répulsions stériques sont relâchées. Une configuration des atomes est dite à l'**équilibre énergétique** lorsqu'elle réalise un minimum local de cette énergie ; c'est dans cette configuration que la molécule existe effectivement. On dit alors qu'une molécule est **plane** si tous ses atomes se placent, à l'équilibre énergétique, dans un même plan.

Pour un pavage d'hexagones réguliers, la somme des angles autour de chaque sommet vaut  $360^\circ$  et la structure est plane. Un pentagone (angle interne  $108^\circ$ ) introduit localement un *défaut d'angle* par rapport à un hexagone et la tension de cycle est plus importante : la molécule tend à se refermer, comme dans un fullerène. À l'inverse, dans un heptagone ( $\approx 128,6^\circ$ ), les angles sont plus ouverts que ceux d'un hexagone et la molécule tend à être plus flexible, donc à onduler.

### 2.1.9 Validation quantique semi-empirique (xTB)

Pour juger si une molécule est réellement plane, on cherche sa géométrie d'équilibre : la disposition des atomes qui minimise l'énergie. Nous utilisons une méthode *semi-empirique*, GFN2-xTB [16], qui approxime l'énergie à un coût permettant de traiter de grandes séries de molécules et fournit une géométrie optimisée exploitable à grande échelle. C'est le sens de la « validation quantique semi-empirique » du titre.

## 2.2 Programmation par contraintes (PPC)

La *programmation par contraintes* est un paradigme déclaratif de résolution de problèmes combinatoires. Plutôt que de décrire *comment* résoudre un problème, on se contente d'en *décrire les solutions*, puis on confie la recherche à un solveur générique.

### 2.2.1 Réseau de contraintes

Une instance d'un problème de satisfaction de contraintes (CSP) est définie par un ensemble de *variables*, chacune dotée d'un *domaine* de valeurs possibles, et d'un ensemble de *contraintes* restreignant les combinaisons de valeurs autorisées. Formellement [1] :

**Définition 5** (Instance CSP). *Une instance d'un problème de satisfaction de contraintes est un triplet  $P = (X, D, C)$  où :*

- $X = \{x_1, x_2, \dots, x_n\}$  est un ensemble de  $n$  variables ;
- $D = \{d_{x_1}, d_{x_2}, \dots, d_{x_n}\}$  est un ensemble de domaines finis ; la variable  $x_i$  prend ses valeurs dans le domaine  $d_{x_i}$  ;
- $C = \{c_1, c_2, \dots, c_m\}$  est un ensemble de  $m$  contraintes. Chaque contrainte  $c$  est caractérisée par un couple  $(S(c), R(c))$  où
  1.  $S(c) = \{x_{i_1}, x_{i_2}, \dots, x_{i_q}\} \subseteq X$  est la portée de  $c$ , c'est-à-dire l'ensemble des variables sur lesquelles porte la contrainte ;
  2.  $R(c) \subseteq \prod_{k=1}^q d_{x_{i_k}}$  est sa relation de compatibilité, c'est-à-dire l'ensemble des combinaisons de valeurs autorisées par la contrainte.

Une contrainte portant sur une seule variable est dite *unaire*, sur deux variables *binaire*, sur  $q$  variables *q-aire*.

### 2.2.2 Un exemple : le Sudoku

Pour illustrer le formalisme, considérons le **Sudoku** : sur une grille  $9 \times 9$  partiellement remplie de chiffres de 1 à 9 (figure 8), on cherche à compléter les cases vides de telle sorte que chaque chiffre apparaisse exactement une fois sur chaque ligne, chaque colonne et chacun des neuf sous-blocs  $3 \times 3$ . Les chiffres initialement présents sont appelés *indices*.

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 5 | 3 |   |   | 7 |   |   |   |   |
| 6 |   |   | 1 | 9 | 5 |   |   |   |
|   | 9 | 8 |   |   |   |   | 6 |   |
| 8 |   |   |   | 6 |   |   |   | 3 |
| 4 |   |   | 8 |   | 3 |   |   | 1 |
| 7 |   |   |   | 2 |   |   |   | 6 |
|   | 6 |   |   |   |   | 2 | 8 |   |
|   |   |   | 4 | 1 | 9 |   |   | 5 |
|   |   |   |   | 8 |   |   | 7 | 9 |

|  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |

FIGURE 8 – Un Sudoku partiellement rempli (à gauche). À droite, la valeur de la case  $x_{ij}$  doit différer de toutes les autres cases de sa ligne, de sa colonne et de son bloc  $3 \times 3$ .

Le problème se modélise en PPC par l'instance  $P = (X, D, C)$  :

- $X = \{x_1, x_2, \dots, x_{81}\}$  : une variable par case de la grille, numérotées de gauche à droite et de haut en bas. La valeur de  $x_i$  représente le chiffre inscrit dans la  $i$ -ème case.
- $D = \{d_{x_1}, d_{x_2}, \dots, d_{x_{81}}\}$  : pour les cases vides,  $d_{x_i} = \{1, 2, \dots, 9\}$  ; pour les cases pré-remplies de valeur  $v$ ,  $d_{x_i} = \{v\}$ . Par exemple, sur la grille de la figure 8, on aurait  $d_{x_1} = \{2\}$ ,  $d_{x_2} = \{4\}$ ,  $d_{x_3} = \{1\}$ ,  $d_{x_4} = \{1, 2, \dots, 9\}$ , ...
- $C = \{c_{i,j} : x_i, x_j \text{ partagent une ligne, une colonne ou un bloc } 3 \times 3\}$ , où,  $\forall (x_i, x_j)$  dans cet ensemble, la contrainte binaire  $c_{i,j}$  exprime la différence des valeurs :

$$S(c_{i,j}) = \{x_i, x_j\}, \quad R(c_{i,j}) = \{(v_i, v_j) \in d_{x_i} \times d_{x_j} \mid v_i \neq v_j\}.$$

**Remarque 3.** Ces contraintes binaires seront avantageusement regroupées sous une contrainte globale plus compacte à la section 2.2.4, une fois introduite la notion de contrainte globale.

### 2.2.3 Résolution : propagation et recherche arborescente

**Définition 6** (Solution). Une solution d'une instance CSP  $P = (X, D, C)$  est une affectation à chaque variable  $x_i$  d'une valeur de son domaine  $d_{x_i}$  telle que toutes les contraintes de  $C$  soient satisfaites. On parle d'affectation complète cohérente. Un problème est dit cohérent s'il possède au moins une solution, et incohérent sinon.

Décider si une instance CSP admet une solution est un problème **NP-complet** dans le cas général : aucun algorithme polynomial n'est connu pour le résoudre. Les solveurs PPC combinent en pratique deux mécanismes complémentaires que nous décrivons ci-dessous.

**Propagation de contraintes (filtrage).** À chaque étape de la résolution, on retire des domaines les valeurs qui ne peuvent appartenir à aucune solution. Le critère le plus courant est la *cohérence d'arc* : pour toute contrainte  $c$  et toute variable  $x_i \in S(c)$ , on retire de  $d_{x_i}$  toute valeur  $v$  qui n'a

aucun *support* dans les domaines des autres variables de  $c$  (c'est-à-dire telle qu'aucune affectation des autres variables ne satisfasse  $c$  avec  $v$ ). Sur le Sudoku, si une case d'une ligne contient 7, la propagation retire 7 du domaine de toutes les autres cases de la même ligne, de la même colonne et du même bloc.

**Recherche arborescente.** On affecte les variables une à une. À chaque nœud, le solveur choisit une variable et lui assigne une valeur de son domaine courant, puis propage. Si un domaine devient vide, le solveur *revient en arrière* (*backtrack*) sur le dernier choix et essaie une autre valeur. La recherche aboutit soit à une affectation complète cohérente (solution), soit à l'épuisement de toutes les branches (instance incohérente).

L'intérêt majeur du paradigme est qu'il n'est pas nécessaire d'écrire un algorithme spécifique à chaque problème : il suffit de formuler le modèle, puis d'invoquer un solveur traité comme une *boîte noire*. Dans ce travail, nous écrivons les modèles avec la bibliothèque Python PyCSP3 [4] et nous les résolvons avec le solveur CHOCO [5], qui sait énumérer l'ensemble des solutions d'une instance.

Cette modularité confère aussi une **flexibilité** au modèle : ajouter, modifier ou retirer une variable ou une contrainte revient à ajouter, modifier ou retirer une déclaration dans le modèle, sans toucher au mécanisme de résolution. Une approche algorithmique *ad hoc*, construite pour un problème précis, n'offre pas cette souplesse : changer une règle métier oblige généralement à revoir une partie substantielle du code de résolution lui-même. C'est cette propriété que nous exploitons systématiquement dans ce travail, en particulier à la section 6, où de nombreuses variantes de contraintes sont testées sans jamais modifier le solveur.

#### 2.2.4 Contraintes en extension et contraintes globales

La possibilité de spécifier des contraintes de façon modulaire fait la force de la PPC. On distingue deux grandes familles particulièrement utiles dans la suite.

Une **contrainte en extension** (ou *de table*) liste explicitement les combinaisons de valeurs autorisées (ou interdites) pour sa portée : c'est exactement la relation  $R(c)$  donnée plus haut. C'est la forme naturelle pour encoder un catalogue de configurations admissibles, et c'est elle que nous utiliserons pour la *table de voisinage* chimique (section 4).

Une **contrainte globale** capture un motif récurrent sur un nombre arbitraire de variables, avec un *propagateur* spécialisé plus efficace que la décomposition en contraintes binaires. L'exemple typique est  $\text{allDifferent}(x_{i_1}, \dots, x_{i_q})$ , qui généralise les contraintes binaires de différence  $c_{i,j}$  de notre exemple du Sudoku (section 2.2.2) : sa portée est  $S(c) = \{x_{i_1}, \dots, x_{i_q}\}$  et sa relation

$$R(c) = \{ (v_{i_1}, \dots, v_{i_q}) \in d_{x_{i_1}} \times \dots \times d_{x_{i_q}} \mid v_{i_j} \neq v_{i_k} \text{ pour } j \neq k \}.$$

Cette contrainte est équivalente à  $\binom{q}{2}$  contraintes binaires de différence, mais son propagateur dédié élague l'espace de recherche de manière nettement plus efficace. Ce gain n'est pas qu'une question de compacité d'écriture : l'algorithme de filtrage dédié à  $\text{allDifferent}$  (fondé sur un calcul de couplage dans un graphe biparti) atteint la cohérence d'arc complète en une seule passe, ce qu'aucune décomposition en contraintes binaires ne peut garantir, celles-ci ne détectant que des incohérences locales par paires.

**Reformulation du Sudoku avec  $\text{allDifferent}$ .** Les contraintes binaires  $c_{i,j}$  du modèle précédent peuvent être factorisées par lignes, colonnes et blocs. Pour chaque ligne  $L_k$ , on remplace les  $\binom{9}{2} = 36$  contraintes binaires de différence par une seule contrainte globale  $\text{allDifferent}(x_i : x_i \in L_k)$  ; de même pour les colonnes et les blocs  $3 \times 3$ . On obtient ainsi un modèle équivalent avec 27 contraintes globales au lieu de plus de huit cents contraintes binaires, et la propagation est sensiblement plus efficace.

**Illustration de la résolution.** Reprenons la grille de Sudoku partiellement remplie de la figure 8. Au départ, la case  $x_1$  est connue :  $d_{x_1} = \{2\}$ . La propagation des contraintes  $\text{allDifferent}$  de la ligne

$L_1$ , de la colonne  $C_1$  et du bloc  $R_1$  contenant  $x_1$  retire alors 2 de tous les domaines des autres cases concernées. Si après propagation un domaine se réduit à un singleton, l’affectation correspondante est forcée et déclenche à son tour de nouvelles propagations. Lorsque la propagation seule ne suffit plus à compléter la grille, le solveur entre en recherche : il choisit une variable au domaine non encore singleton (par exemple  $x_4$  avec  $d_{x_4} = \{1, 5, 7\}$ ), affecte la première valeur ( $x_4 = 1$ ) et propage à nouveau. Si à un moment un domaine devient vide, la contradiction force un retour arrière et le solveur essaie la valeur suivante ( $x_4 = 5$ ). La recherche aboutit soit à une affectation complète et cohérente — une solution — soit à l’épuisement de toutes les branches, ce qui signifie que l’instance est incohérente.

La souplesse de la PPC, qui consiste à activer, désactiver ou ajouter une contrainte puis réénumérer rapidement les solutions, est un atout décisif pour un travail mené en dialogue continu avec les chimistes.

### 2.2.5 Isomorphisme de graphes

Comme une partie centrale de notre modélisation repose sur les automorphismes d’un graphe (rupture de symétrie en section 4.3.1), nous rappelons ici la notion d’*isomorphisme*, qui apparaît dans tout le mémoire.

**Définition 7** (Isomorphisme de graphes). *Deux graphes non orientés  $G = (V_G, E_G)$  et  $H = (V_H, E_H)$  sont dits **isomorphes** s’il existe une bijection  $f : V_G \rightarrow V_H$  qui préserve les arêtes, c’est-à-dire telle que*

$$\forall u, v \in V_G, \quad \{u, v\} \in E_G \iff \{f(u), f(v)\} \in E_H.$$

*La bijection  $f$  est alors appelée un **isomorphisme** entre  $G$  et  $H$ . Si  $G = H$ , on parle d’**automorphisme** de  $G$  : c’est une permutation des sommets qui préserve les arêtes.*

Intuitivement, deux graphes isomorphes sont « les mêmes » à un renommage des sommets près ; ils représentent la même structure abstraite. Pour notre problème, deux substitutions d’un benzénoïde qui diffèrent uniquement par un automorphisme du graphe dual correspondent à la même molécule, et seront comptées une seule fois. La rupture de symétrie (section 4.3.1) traite explicitement ce point.

## 3 Le problème

Maintenant que le vocabulaire est posé, nous pouvons énoncer précisément le problème et analyser ses deux sources de difficulté.

On part d’un benzénoïde  $B$  à  $n_H(B)$  hexagones, représenté par son graphe dual  $G_D$ . Une **substitution** affecte à chaque hexagone  $v$  une taille de cycle  $x_v \in \{5, 6, 7\}$  : conserver l’hexagone ( $x_v = 6$ ), le contracter en pentagone ( $x_v = 5$ ) ou le dilater en heptagone ( $x_v = 7$ ). La substitution doit satisfaire les deux contraintes suivantes :

- **conservation des interactions entre les cycles** : les arêtes partagées entre cycles voisins sont préservées, donc  $G_D$  reste identique avant et après transformation. C’est un point essentiel de la modélisation : elle garantit que chaque cycle de la solution correspond *exactement* à un hexagone du benzénoïde de départ, ce qui sera exploité pour exprimer simplement la conservation des atomes en section 4.3.1 ;
- **conservation du nombre total d’atomes de carbone** (et donc d’hydrogène) : on veut conserver exactement la même taille de structure moléculaire. Puisque la conservation du graphe dual préserve les arêtes partagées, les carbones communs à plusieurs cycles restent inchangés ; il en va donc de même pour les carbones non partagés, chacun porteur d’un hydrogène, d’où la conservation simultanée des deux comptes d’atomes.

On cherche à **énumérer toutes les substitutions admissibles**, c'est-à-dire toutes celles qui correspondent à une molécule chimiquement et géométriquement réalisable, à *isomorphisme* près : deux substitutions identiques à une symétrie du benzénoïde de départ décrivent la même molécule et ne sont comptées qu'une seule fois (la notion d'isomorphisme est définie en section 2.2.5).




FIGURE 9 – Mise en évidence des carbones et des arêtes partagés

### 3.1 La difficulté combinatoire

Avec trois valeurs possibles par hexagone, un benzénoïde à  $n_H(B)$  hexagones admet a priori  $3^{n_H(B)}$  substitutions. Ce nombre croît exponentiellement, et la grande majorité de ces affectations ne correspondent à *aucune* molécule valide : elles violent la conservation du carbone, ou décrivent des voisinages localement impossibles à reconstruire. Énumérer naïvement puis filtrer est donc hors de portée dès que  $n_H(B)$  dépasse quelques unités. C'est exactement le type de problème fortement combinatoire pour lequel la PPC est conçue : on encode les conditions d'admissibilité comme des contraintes, et le solveur n'explore que les affectations cohérentes.

### 3.2 La difficulté géométrique et topologique

La seconde difficulté est de nature différente, et c'est la plus profonde. Dans un benzénoïde, tous les cycles sont des hexagones réguliers d'angle interne  $120^\circ$ , et le pavage est plan par construction. Dès que l'on introduit des pentagones (angle interne  $108^\circ$ ) et des heptagones (environ  $128,6^\circ$ ), plusieurs grandeurs cessent d'être fixées :

- les **angles** aux sommets ne se complètent plus à  $360^\circ$ , ce qui crée une courbure locale ;
- les **distances** inter-atomiques et les longueurs de liaison s'ajustent pour relâcher les tensions ;
- la **topologie** de fusion impose que les cycles voisins partagent exactement une arête, ce qui n'est pas toujours réalisable selon la disposition des voisins ;
- la **planéité** qui en résulte n'est pas garantie : la molécule peut se courber ou onduler pour minimiser son énergie.

Le point crucial est que la planéité est une propriété *globale* : elle dépend de l'agencement de tous les défauts à la fois, et ne se déduit pas seulement des voisinages locaux. On peut filtrer localement les configurations manifestement irréalisables, mais on ne peut pas, par des contraintes locales seules, garantir qu'une molécule entière sera plane. Cette limite est *intrinsèque au problème*. Elle motive l'architecture en deux temps de notre travail : un modèle PPC qui énumère les candidats en appliquant les conditions *exprimables* (section 4), suivi d'une validation physique qui tranche la planéité *réelle* de chaque candidat (section 5). Et elle motive l'étude expérimentale (section 6), qui cherche les contraintes améliorant au mieux le rendement de planéité.

## 4 Modélisation

Nous présentons à présent le modèle PPC qui énumère les substitutions admissibles. Il comporte une variable par hexagone et un ensemble de contraintes *structurelles*, toujours actives, que nous décrivons ici. Les contraintes *additionnelles*, qui font l'objet de l'étude expérimentale, sont introduites à la section 6.

### 4.1 Variables et domaines

À chaque hexagone  $v$  du graphe dual on associe une variable  $x_v$  donnant la taille du cycle substitué :

$$x_v \in \{5, 6, 7\}, \quad v \in V_D.$$

Toutes les variables ont initialement le même domaine  $\{5, 6, 7\}$ . Les contraintes C2 et C4 décrites ci-dessous réduiront ce domaine en fonction de la position de  $v$  dans le graphe dual, allant jusqu'à le restreindre à  $\{6\}$  pour certains hexagones, dits *gelés*.

### 4.2 Préalable : motif d'occupation $\sigma(v)$ et blocs libres

Plusieurs des contraintes du modèle reposent sur la même donnée locale : *où sont placés les voisins de  $v$  dans son hexagone, et où sont laissés les côtés libres*. Nous introduisons donc d'abord le vocabulaire et la notation correspondants, que nous réutiliserons sans les redéfinir dans la suite.

Soit  $v \in V_D$  un hexagone du benzénoïde de départ. Ses six côtés sont numérotés cycliquement de 0 à 5. Chaque côté est, ou bien **partagé** avec un voisin (le côté coïncide avec une arête commune entre  $v$  et un autre cycle du benzénoïde, c'est-à-dire une arête de  $G_D$  incidente à  $v$ ), ou bien **libre** (aucun voisin de ce côté).

**Définition 8** (Motif d'occupation  $\sigma(v)$ ). *Le motif d'occupation de  $v$  est le vecteur*

$$\sigma(v) = (\sigma_0, \sigma_1, \dots, \sigma_5) \in \{0, 1\}^6,$$

où  $\sigma_i = 1$  si le  $i$ -ème côté de  $v$  est partagé avec un voisin, et  $\sigma_i = 0$  s'il est libre. Le nombre de côtés partagés vaut  $\sum_i \sigma_i = \deg_{G_D}(v)$ .

Le motif  $\sigma(v)$  est défini à rotation cyclique près : changer le point de départ de la numérotation produit une rotation de  $\sigma(v)$ , mais ne modifie pas l'information géométrique sous-jacente.

**Exemple.** Reprenons le benzénoïde  $B$  de la figure 2, et concentrons-nous sur le sommet  $v_1$ . Dans  $G_D(B)$  (figure 3, à droite),  $v_1$  a quatre voisins :  $v_0$  à gauche,  $v_2$  à droite,  $v_3$  en haut-gauche et  $v_4$  en bas-droite. Les quatre côtés de  $v_1$  correspondant sont donc partagés ( $\sigma_i = 1$ ), et les deux côtés restants (haut-droite et bas-gauche) sont libres ( $\sigma_i = 0$ ). En choisissant comme point de départ le côté haut-droite, on obtient

$$\sigma(v_1) = (0, 1, 1, 0, 1, 1),$$

ce qui est équivalent, à une rotation près, à  $(1, 1, 0, 1, 1, 0)$ . La figure 10 matérialise visuellement cette décomposition.

On nomme ces côtés *libres* précisément parce que, à l'inverse des côtés partagés — qui doivent rester partagés pour que le graphe dual  $G_D$  soit préservé (section 3) —, ils ne sont soumis à aucune contrainte de ce type : c'est sur eux seuls que peuvent porter les transformations en pentagone ou en heptagone. Regrouper les côtés libres en *blocs*, plutôt que de raisonner côté par côté, permet d'énoncer des critères de transformabilité compacts et valables pour tout motif  $\sigma(v)$ , sans avoir à énumérer toutes les combinaisons possibles.






FIGURE 10 – Motif d’occupation  $\sigma(v_1)$  pour le sommet central du benzénoïde de la figure 2.

**Définition 9** (Blocs libres,  $b(v)$ ). *On appelle bloc libre de  $v$  une suite maximale d’indices  $i, i + 1, \dots, j - 1$  (modulo 6) telle que  $\sigma_i = \sigma_{i+1} = \dots = \sigma_{j-1} = 0$ , encadrée par des côtés partagés. On note  $b(v)$  le nombre de blocs libres distincts de  $v$ .*

Pour l’exemple de la figure 10, les côtés libres sont en positions 0 et 3, séparés par des côtés partagés. Chacun constitue son propre bloc, et  $b(v_1) = 2$ .

**Définition 10** (Sommet intérieur libre). *Un sommet intérieur libre de  $v$  est un sommet du cycle dont les deux côtés adjacents sont libres. De manière équivalente,  $v$  possède un sommet intérieur libre si et seulement si  $\sigma(v)$  contient au moins deux zéros consécutifs cycliquement.*

Cette notion va jouer un rôle clef dans la contrainte C2 : contracter un hexagone en pentagone consiste précisément à *supprimer un sommet intérieur libre*. Pour  $v_1$  de la figure 10, chaque côté libre est isolé entre deux côtés partagés, donc aucun sommet du cycle n’a ses deux côtés adjacents libres simultanément :  $v_1$  n’a pas de sommet intérieur libre.

### 4.3 Contraintes

Cette sous-section regroupe les contraintes du modèle, organisées en deux groupes. Le premier (C1–C3) rassemble les contraintes **structurelles**, indispensables à la constructibilité géométrique d’une molécule : sans elles, une solution n’a simplement pas de sens physique. Le second (C4–C6) rassemble des contraintes **chimiques additionnelles**, qui encodent des choix motivés par la chimie plutôt que des nécessités géométriques ; certaines sont optionnelles, et leur effet est étudié expérimentalement à la section 6.

#### 4.3.1 Contraintes structurelles (C1–C3)

**C1 : Conservation du nombre de carbone** Le nombre total d’atomes de carbone doit être préservé par la substitution. Notons  $n_H(B)$  le nombre d’hexagones du benzénoïde  $B$  de départ, et  $n_5, n_6, n_7$  les nombres respectifs de pentagones, hexagones et heptagones dans la solution. Tout cycle de la solution remplace exactement un hexagone du benzénoïde de départ, donc

$$n_5 + n_6 + n_7 = n_H(B).$$

Pour exprimer la conservation du carbone, comptons explicitement les atomes de carbone de chaque côté. Soit  $a = |E_D|$  le nombre d’arêtes du graphe dual  $G_D$  du benzénoïde de départ (chaque arête correspond à deux hexagones partageant une arête carbone–carbone, et donc deux atomes communs). Le nombre total d’atomes de carbone du benzénoïde de départ vaut

$$N(B) = 6n_H(B) - 2a,$$

puisque chaque hexagone contient 6 atomes et que chaque arête commune correspond à 2 atomes comptés en double.

Après substitution, la solution comporte  $n_5$  pentagones,  $n_6$  hexagones et  $n_7$  heptagones, soit  $5n_5 + 6n_6 + 7n_7$  atomes avant correction. La **conservation du graphe dual** (section 3) garantit que **le nombre d'arêtes communes reste  $a$** , donc le nombre total d'atomes de la solution vaut

$$N(\text{solution}) = 5n_5 + 6n_6 + 7n_7 - 2a.$$

Conserver le nombre d'atomes ( $N(\text{solution}) = N(B)$ ) donne donc

$$5n_5 + 6n_6 + 7n_7 - 2a = 6n_H(B) - 2a,$$

et le terme  $-2a$  se simplifie de part et d'autre. On obtient

$$5n_5 + 6n_6 + 7n_7 = 6n_H(B).$$

Cette égalité porte sur les comptes  $n_5, n_6, n_7$ , qui ne sont pas des variables du modèle. Pour l'exprimer comme une contrainte sur les variables  $x_v$ , on remarque que la somme  $\sum_{v \in V_D} x_v$  vaut exactement  $5n_5 + 6n_6 + 7n_7$ , puisque chaque hexagone  $v$  contribue sa taille  $x_v$  à la somme selon le nombre de fois qu'elle apparaît. C'est précisément à cette étape que l'on passe d'une identité mathématique sur des comptes à une contrainte exploitable par le solveur :

$$\boxed{\sum_{v \in V_D} x_v = 5n_5 + 6n_6 + 7n_7 = 6n_H(B),}$$

qui est l'expression effectivement déclarée au solveur : une simple contrainte de somme sur les variables entières.

Combinée à  $n_5 + n_6 + n_7 = n_H(B)$ , cette équation équivaut à  $n_5 = n_7$ , qui s'interprète chimiquement : chaque pentagone retire un atome de carbone et doit être compensé par un heptagone qui en ajoute un.

**C2 : Restriction géométrique du domaine** L'attribution  $x_v \in \{5, 6, 7\}$  doit être compatible avec une *reconstruction géométrique* de  $v$  qui ne brise pas la fusion avec ses voisins (les côtés partagés doivent rester partagés, à la même position). Cette compatibilité dépend uniquement du motif d'occupation  $\sigma(v)$  et peut donc être vérifiée *en amont* de la résolution, sous forme d'une restriction du domaine de  $x_v$ .

**Contraction en pentagone ( $x_v = 5$ ).** Transformer un hexagone en pentagone revient à supprimer l'un de ses sommets. Pour ne pas casser un côté partagé, ce sommet doit avoir ses deux côtés adjacents libres : c'est précisément un *sommet intérieur libre*, au sens de la définition donnée section 4.2. La valeur  $x_v = 5$  est donc **admissible** si et seulement si  $\sigma(v)$  contient au moins deux zéros consécutifs cycliquement.

**Dilatation en heptagone ( $x_v = 7$ ).** Transformer un hexagone en heptagone revient à ajouter un sommet entre deux sommets existants, c'est-à-dire à dédoubler un côté libre. La valeur  $x_v = 7$  est donc admissible si et seulement si  $\sigma(v)$  contient au moins un côté libre, soit  $\sigma_i = 0$  pour au moins un  $i$ .

**Énoncé formel.** Pour chaque sommet  $v \in V_D$ , la contrainte C2 réduit le domaine  $D(x_v)$  à

$$D(x_v) = \{6\} \cup \{5 : \sigma(v) \text{ a } \geq 2 \text{ zéros consécutifs}\} \cup \{7 : \sigma(v) \text{ a } \geq 1 \text{ zéro}\},$$

où la valeur 6 reste toujours admissible (l'hexagone d'origine est, par construction, géométriquement compatible avec lui-même).

**Cas particulier : hexagones de degré 6 gelés.** Un cas se distingue par son importance pratique. Si  $\deg_{G_D}(v) = 6$ , l'hexagone  $v$  est entouré de six voisins et n'a aucun côté libre. Son motif vaut  $\sigma(v) = (1, 1, 1, 1, 1, 1)$ , qui ne contient aucun zéro : ni 5 ni 7 ne sont admissibles, donc directement

$$D(x_v) = \{6\} \iff x_v = 6.$$

Le sommet  $v$  est dit *gelé* : il n'apparaît plus que comme constante dans le modèle. Ce gel est une conséquence topologique stricte de C2, sans alternative possible.

C2 s'implémente comme un prétraitement : pour chaque  $v$ , on calcule  $\sigma(v)$  depuis  $G_D$  et on initialise  $D(x_v)$  en conséquence **avant** de passer le modèle au solveur. La présence ou l'absence d'une valeur dans  $D(x_v)$  joue alors exactement le rôle d'une contrainte unaire sur  $x_v$ .

**Exemple.** Reprenons le sommet  $v_1$  de la figure 10, dont le motif est  $\sigma(v_1) = (0, 1, 1, 0, 1, 1)$ . Les zéros sont en positions 0 et 3, séparés par des côtés partagés : il n'y a aucune paire de zéros consécutifs cycliquement. La contrainte C2 retire donc 5 du domaine de  $x_{v_1}$ , mais conserve 7 (le motif contient bien un zéro). On obtient

$$D(x_{v_1}) = \{6, 7\}.$$

Sur cet exemple,  $v_1$  ne pourra pas être contracté en pentagone, mais pourra encore être dilaté en heptagone (en insérant un sommet sur le côté libre  $\sigma_0$  ou  $\sigma_3$ ).

**C3 : Rupture de symétrie** Deux substitutions qui ne diffèrent que par une symétrie du benzénoïde décrivent la *même* molécule. Pour ne les compter qu'une fois, on exploite le groupe des automorphismes du graphe dual,  $\text{Aut}(G_D)$  (les permutations des sommets qui préservent les arêtes), dont on calcule un ensemble générateur  $\{\pi_1, \dots, \pi_m\}$ . Pour chaque générateur  $\pi$ , on impose une contrainte *lex-leader*

$$(x_0, x_1, \dots, x_{h-1}) \leq_{\text{lex}} (x_{\pi(0)}, x_{\pi(1)}, \dots, x_{\pi(h-1)}),$$

qui ne retient, dans chaque orbite de solutions équivalentes, que le représentant minimal pour l'ordre lexicographique. Cette technique élimine les doublons et réduit fortement l'espace de recherche. Sa validité repose sur l'unicité du plongement planaire des graphes considérés (théorème de Whitney [8] et 2-connexité des benzénoïdes).

### 4.3.2 Contraintes chimiques additionnelles (C4–C6)

**C4 : Gel des hexagones à blocs libres fragmentés (optionnel)** Si  $b(v) \geq 2$ , les côtés libres de  $v$  sont répartis en plusieurs blocs disjoints sur le cycle. Notons que la simple connaissance du *nombre* d'arêtes périphériques d'un hexagone — au sens de l'étiquetage de Brinkmann repris par Varet [1] pour distinguer les benzénoïdes partageant le même graphe dual intérieur — ne suffit pas à caractériser cette situation : c'est la *disposition* des côtés libres (un bloc continu ou plusieurs blocs séparés) qui détermine la faisabilité d'une substitution.

La transformation n'est pas *impossible*, mais elle n'est plus unique : on doit choisir où placer l'arête périphérique supplémentaire introduite par le septième sommet, et chaque choix produit un benzénoïde distinct au sens de Brinkmann. La figure 11 illustre cet enjeu sur un motif tiré de la figure 2.14 de la thèse de Varet [1] : un anthracène dont l'hexagone central est étiqueté 2+2 (deux blocs périphériques de deux arêtes, en haut et en bas) admet deux substitutions distinctes par un heptagone, l'une ajoutant une arête périphérique en bas (étiquetage 2+3), l'autre en haut (3+2).

On impose donc  $x_v = 6$  *par défaut* pour ces hexagones, ce qui revient à interdire l'ambiguïté de transformation introduite par les blocs libres multiples. Cette restriction est désactivable lorsqu'on souhaite explorer des géométries où l'on accepte de modifier l'étiquetage des voisins, par exemple pour étudier l'effet de relâcher cette contrainte dans les expériences de la section 6.

Les hexagones qui ne sont gelés par aucune des deux règles sont dits *libres* et conservent le domaine  $\{5, 6, 7\}$ .




FIGURE 11 – Anthracène et transformation du cycle central en heptagone.

**C5 : Voisinage admissible et table de voisinage** C’est le cœur du filtrage chimique. Pour chaque hexagone libre  $v$ , on impose que la configuration locale formée par  $v$  et ses voisins soit *réalisable*. Cette condition est encodée par une **contrainte en extension** : le tuple ordonné

$$\tau_v = (x_v, x_{u_1}, x_{u_2}, \dots, x_{u_k}),$$

où  $u_1, \dots, u_k$  sont les voisins de  $v$  dans  $G_D$  pris dans l’ordre cyclique, doit appartenir à une **table de voisinage**  $\mathcal{T}$  pré-calculée. Le degré  $k$  de  $v$  dans le graphe dual est compris entre 2 et 6 (un hexagone a au plus six côtés partagés), ce qui donne à  $\tau_v$  une longueur  $|\tau_v| = k + 1 \in \{3, 4, 5, 6, 7\}$  (cette longueur est la cardinalité du tuple, à ne pas confondre avec les tailles de cycles 5, 6, 7). Le cas  $k = 0$  (un hexagone isolé sans voisin) n’est pas considéré, et le cas  $k = 1$  est traité séparément ci-dessous.

Un point essentiel distingue notre table de celle des benzénoïdes purs : elle est *sensible à la disposition* des voisins. Deux configurations ayant les mêmes tailles de voisins mais disposées différemment autour du cycle central ne sont pas équivalentes, car elles ne se reconstruisent pas de la même manière en trois dimensions. La position des voisins est donc encodée explicitement dans les tuples de la table (un 0 marquant un côté libre).

La table est **construite hors-ligne** : on énumère les configurations locales candidates (un cycle central entouré de voisins de tailles données dans une disposition donnée), on reconstruit chacune en 3D, on l’optimise par xTB, et on ne retient que celles qui sont planes (au sens du critère décrit en section 5). Ce catalogue est *paramétrable* : il pourra être régénéré ou affiné lorsque de nouvelles études chimiques préciseront les critères d’admissibilité. La version utilisée dans ce travail comporte **721** entrées au total, réparties selon la taille du cycle central :

|                  | $\mathcal{T}(5)$ | $\mathcal{T}(6)$ | $\mathcal{T}(7)$ |
|------------------|------------------|------------------|------------------|
| Nombre d’entrées | 63               | 291              | 367              |

**Remarque 4.** *Un hexagone de degré 1 (un seul voisin) n’a pas besoin de contrainte de table : un cycle accolé à un unique voisin par une arête est toujours réalisable, quelle que soit sa taille.*

**C6 : Adjacence 5–7 (motif azulène)** Cette contrainte est une piste d’amélioration explorée à la section 6. La motivation n’est pas, ici, géométrique mais chimique : en discussion avec les chimistes, le motif azulène (pentagone et heptagone accolés, figure 1) est apparu comme une cible particulièrement intéressante à privilégier dans les substitutions, indépendamment de tout argument

de planéité. Du point de vue électronique, ce motif s’interprète comme la transformation de deux hexagones accolés (motif 6–6, comme dans le naphthalène) en un pentagone et un heptagone accolés (motif 5–7) : l’opération *préserve* le compte d’atomes de carbone ( $5 + 7 = 6 + 6 = 12$ , moins 2 pour l’arête partagée, donc 10 dans les deux cas) ainsi que le nombre total d’électrons  $\pi$  (10 électrons dans les deux motifs). C’est précisément parce que ce compte reste à  $10 = 4n + 2$  avec  $n = 2$  que la règle de Hückel reste satisfaite dans l’azulène comme dans le naphthalène : le motif 5–7 est un *substitut isoélectronique* naturel du motif 6–6.

Pour chaque sommet  $v$  du graphe dual, notons

$$\mathcal{N}(v) = \{u \in V_D \mid (u, v) \in E_D\}$$

l’ensemble des voisins de  $v$  dans  $G_D$ . La contrainte C6 traduit alors l’idée chimique dans le modèle PPC sous la forme *tout pentagone a au moins un heptagone parmi ses voisins, et tout heptagone a au moins un pentagone parmi les siens* :

$$\forall v \in V_D, \quad (x_v = 5 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 7) \wedge (x_v = 7 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 5).$$

Cette contrainte est purement *locale*, mais sa motivation est globale : en imposant que tout défaut 5 ou 7 soit immédiatement compensé par un défaut opposé, on espère préserver la planéité d’ensemble. Son efficacité réelle est mesurée expérimentalement.

## 4.4 Résolution

Le modèle est écrit en PyCSP3, puis compilé au format standard XCSP3. Selon les options choisies par l’utilisateur, il inclut les contraintes suivantes :

- **actives par défaut** : C1 (conservation du carbone), C2 (restriction géométrique du domaine, incluant le gel des hexagones de degré 6), C3 (rupture de symétrie) et C5 (voisinage admissible) ;
- **optionnelles** : C4 (gel des hexagones à blocs libres fragmentés, activée par défaut mais désactivable) et C6 (adjacence 5–7, désactivée par défaut, étudiée à la section 6).

Le solveur CHOCO est ensuite invoqué pour **énumérer toutes les solutions** de l’instance ainsi configurée. Chaque solution est un vecteur de tailles  $(x_0, \dots, x_{h-1})$  qui sera, à l’étape suivante, reconstruit en une molécule tridimensionnelle puis validé.

## 5 Réalisation : des solutions du modèle aux molécules validées et analysées

Le modèle de la section 4 produit des *vecteurs de tailles*  $(x_0, \dots, x_{h-1})$  : des objets abstraits. Cette section décrit comment on en fait des molécules réelles, comment on décide de leur planéité, et comment on analyse leurs propriétés électroniques. Elle regroupe l’essentiel du travail d’implémentation.

### 5.1 Reconstruction 3D, validation et test de planéité

Cette sous-section décrit, en trois temps, comment on passe d’un vecteur de tailles abstrait à une molécule physiquement validée : la reconstruction 3D produit une géométrie initiale, la validation xTB la fait converger vers son équilibre énergétique, et un test géométrique sur la géométrie optimisée tranche la planéité.

### 5.1.1 Reconstruction 3D des solutions

Chaque solution du modèle est un vecteur de tailles  $(x_0, \dots, x_{h-1})$  indiquant la taille assignée à chaque hexagone. Pour en faire une molécule tridimensionnelle exploitable, on procède en trois phases : modification topologique du graphe de carbone, placement géométrique des sommets, puis assemblage en molécule (liaisons doubles et hydrogènes).

**Modifications topologiques du graphe de carbone.** En partant du graphe de carbone (défini en section 2.1.2) du benzénoïde d'entrée, lorsque la solution affecte une taille  $x_v \neq 6$  à un hexagone  $v$ , il faut transformer ce cycle en un pentagone ou un heptagone *sans* perturber les arêtes partagées avec ses voisins. La mécanique de cette transformation — suppression d'un sommet libre pour contracter en pentagone, insertion d'un sommet sur un côté libre pour dilater en heptagone — est exactement celle décrite pour la contrainte C2 (section 4.3.1). Une fois le cycle modifié, sa nouvelle séquence ordonnée de sommets remplace l'ancienne dans la structure de données du graphe de carbone, afin que les cycles voisins continuent à le référencer correctement via leurs sommets partagés.

**Placement géométrique.** Une fois la topologie fixée (chaque cycle connaît sa liste ordonnée de sommets), il reste à attribuer à chaque sommet une position dans le plan. L'idée est de poser chaque cycle comme un *polygone régulier* de longueur de côté  $\ell = 1,4 \text{ \AA}$  (longueur typique d'une liaison carbone-carbone), en respectant les contraintes de partage d'arête entre cycles adjacents.

**Rayon des cycles.** Le rayon  $r_n$  du cercle circonscrit à un polygone régulier de  $n$  côtés de longueur  $\ell$  vaut

$$r_n = \frac{\ell}{2 \sin(\pi/n)}.$$

Pour  $\ell = 1,4 \text{ \AA}$  (longueur typique d'une liaison carbone-carbone dans un benzénoïde), on obtient  $r_5 \approx 1,19 \text{ \AA}$ ,  $r_6 \approx 1,40 \text{ \AA}$ ,  $r_7 \approx 1,61 \text{ \AA}$ .

**Parcours en largeur du graphe dual.** Le placement s'effectue par un parcours en largeur (*BFS*) du graphe dual  $G_D$  à partir d'un cycle **ancre** — choisi de plus haut degré, ce qui maximise les contraintes immédiates de partage et stabilise la géométrie. Le cycle ancre est dessiné centré à l'origine, dans une orientation canonique. Chaque cycle suivant est placé *relativement à un parent déjà placé*, via l'arête  $e = \{a, b\}$  qu'ils partagent.

**Positionnement d'un cycle enfant.** Soit  $c$  un cycle à placer, parent  $p$ , arête partagée  $\{a, b\}$  déjà positionnée aux coordonnées  $\mathbf{x}_a, \mathbf{x}_b$ . Le placement s'effectue alors en quatre étapes décrites par l'algorithme 1.

---

**Algorithme 1** Positionnement d'un cycle enfant relativement à son parent.

---

**Entrée :** cycle  $c$  de taille  $n_c$ , parent  $p$  déjà placé, arête  $\{a, b\}$  partagée

**Sortie :** positions des sommets de  $c$  dans le plan

```

m ← (x_a + x_b) / 2                                     ; milieu de l'arête partagée
a_{n_c} ← r_{n_c} · cos(π / n_c)                         ; apothème du polygone régulier
n ← vecteur unitaire ⊥ {a, b}, opposé au parent p
centre_c ← m + a_{n_c} · n
// répartir les n_c-2 sommets restants sur le cercle
pour i de 1 à n_c - 2 :
    θ_i ← angle du i-ème sommet (depuis a vers b, hors parent)
    x_i ← centre_c + r_{n_c} · (cos θ_i, sin θ_i)

```

---

Le choix de l'orientation de la normale par rapport au parent (étape 3 de l'algorithme) garantit que la structure ne se replie pas sur elle-même : chaque cycle enfant est posé du *bon côté* de son arête

de fusion. Lorsqu'un cycle a plusieurs parents déjà placés (cas de cycles internes au benzénoïde), seul le premier rencontré dans le BFS est utilisé pour le placer, et les positions imposées par les autres parents sont vérifiées *a posteriori* pour cohérence ; la topologie en amont garantit qu'elles coïncident dans la limite des polygones réguliers.

**Algorithme global.** L'algorithme complet de placement, qui orchestre le parcours en largeur du graphe dual et appelle l'algorithme 1 sur chaque cycle non encore placé, est donné par l'algorithme 2.

---

**Algorithme 2** Placement géométrique global par parcours en largeur du graphe dual.

---

```

placer le cycle ancre à l'origine, orienté canoniquement
file ← [ancre]
tant que file non vide :
    c ← file.popleft()
    pour chaque voisin v de c dans GD, non encore placé :
        {a, b} ← arête partagée entre c et v
        positionner v par l'algorithme 1 (parent = c)
        file.append(v)

```

---

**Assemblage moléculaire.** Une fois la géométrie 2D obtenue, le squelette carbone est transformé en molécule exploitable par trois opérations. Un couplage de cardinalité maximale sur le graphe de carbone détermine les liaisons doubles (et les éventuels sites radicalaires), puis les hydrogènes sont ajoutés sur les carbones de bord. La molécule complète est enfin exportée au format XYZ pour les étapes aval de validation par xTB. La géométrie produite est plane par construction ; c'est l'optimisation quantique qui tranchera sa planéité réelle. Les détails opérationnels de ces trois étapes sont donnés en annexe A.6.

### 5.1.2 Validation par xTB : protocole d'optimisation déterministe

L'optimisation xTB procède par descente de gradient. Si la géométrie initiale est parfaitement plane, l'optimiseur reste piégé dans un **minimum plat parasite**. Pour briser cette symétrie de façon reproductible, nous appliquons une **perturbation analytique déterministe** aux coordonnées  $z$  avant toute optimisation : la perturbation est une fonction pure des indices atomiques, sans tirage aléatoire, ce qui rend l'ensemble du pipeline *byte-déterministe*. La formule, la commande `xtb -opt tight` et tous les détails techniques sont donnés en annexe A.3.

### 5.1.3 Test de planéité

Une fois la géométrie optimisée par xTB, il reste à décider si la molécule est plane. Le critère retenu repose sur les **angles dièdres** : c'est la grandeur la plus directement sensible aux déformations *localisées entre liaisons voisines*, qui affectent en premier lieu le système  $\pi$ , contrairement à une courbure d'ensemble qui peut masquer des défauts ponctuels ou en exagérer l'ampleur.

**Métrique angles dièdres :** Nous calculons, pour chaque suite de quatre atomes de carbone  $A-B-C-D$  tous connectés par des liaisons covalentes consécutives (trois liaisons en chaîne), l'angle dièdre signé  $\varphi(A, B, C, D) \in (-180^\circ, 180^\circ]$ . Pour une molécule strictement plane, chaque dièdre vaut  $0^\circ$  ou  $\pm 180^\circ$  : l'écart au plan est donc  $\delta(\varphi) = \min(|\varphi|, 180^\circ - |\varphi|) \in [0, 90^\circ]$ . La métrique retenue est le maximum :

$$\text{max\_dihedral\_deg} = \max_{A-B-C-D} \delta(\varphi(A, B, C, D)).$$

**Critère de décision :** Sur recommandation des chimistes, la classification adopte *trois niveaux*.

## 5.2 Analyse électronique des structures

Une fois les structures planes obtenues, nous avons développé un outil pour en étudier les propriétés électroniques. Ces analyses sont *statiques* : elles opèrent directement sur le graphe de carbone (sans nouveau calcul quantique) et sont donc quasi instantanées.

**Modèle PPC  $\mathcal{M}_K$  pour les structures de Kekulé.** On associe une variable booléenne  $k_e \in \{0, 1\}$  à chaque liaison  $e \in E$  du graphe de carbone ( $k_e = 1$  signifie liaison double) — une notation distincte des variables  $x_v$  du modèle de substitution (section 4), pour éviter toute ambiguïté entre les deux modèles. La contrainte unique est :

$$\sum_{e \in \delta(v)} k_e = 1, \quad \forall v \in V. \quad (\text{C-Kek})$$

L'énumération de toutes les solutions de  $\mathcal{M}_K$  produit l'intégralité des structures de Kekulé. Pour les molécules sans couplage parfait (graphe carbone à nombre impair de sommets ou topologie radicalaire — cas fréquent avec des cycles à 5 ou 7), on relaxe l'égalité en inégalité et l'on maximise  $\sum k_e$  ; les atomes non couverts à l'optimum sont les *sites radicalaires*.




FIGURE 12 – Visualiseur des structures de Kekulé.

**Modèle PPC  $\mathcal{M}_C$  pour les couvertures de Clar.** On étend  $\mathcal{M}_K$  avec une variable booléenne  $y_h \in \{0, 1\}$  par hexagone ( $y_h = 1$  signifie que  $h$  porte un sextet de Clar). La contrainte unifiée par atome est :

$$\sum_{e \in \delta(v)} k_e + \sum_{h \in \mathcal{H} : v \in V(h)} y_h = 1, \quad \forall v \in V, \quad (\text{C-Clar})$$

et l'on maximise  $Z = \sum_{h \in \mathcal{H}} y_h$ . Cette contrainte capture simultanément la vertex-disjonction des sextets (deux sextets partageant un atome violeraient l'égalité à 1) et le couplage parfait du résidu (tout atome hors sextet doit être couvert par exactement une double liaison). En posant  $y_h = 0$  pour tout  $h$ , on retrouve  $\mathcal{M}_K$  comme cas particulier. Pour les structures radicalaires, on relaxe (C-Clar) en inégalité et l'on utilise un objectif lexicographique : minimiser d'abord le nombre de radicaux, puis maximiser  $Z$ .

**Extension du RBO aux cycles 5 et 7.** La définition de Pauling–Randić [13], reprise par Varet, ne concerne que les hexagones. Notre contribution est de conserver la formule  $\text{CBO}(C) = \sum_{e \in C} \text{bo}(e)$






FIGURE 13 – Visualiseur en mode Clar.

sommée sur tout cycle quelle que soit sa taille, en affichant le ratio  $CBO/cbo_{\max}$  pour rester fidèle au contexte. Le cas radicalaire (aucune Kekulé stricte) n'est pas défini au sens de Pauling–Randić.



FIGURE 14 – Visualiseur en mode RBO.

**Remarque 5** (Alignement avec la littérature). Ce modèle coïncide avec celui de *pah-tools* et de *BenzAI* [1] pour les benzénoïdes. Notre apport est l'extension aux cycles impairs (5 et 7) via la relaxation radicalaire de (C-Clar) et le CBO normalisé : les outils existants imposent  $\mathcal{H} = \text{hexagones}$  uniquement et ne définissent pas le cas sans couplage parfait.

### 5.3 Le designer : interface et pipeline intégré

L'ensemble des étapes décrites jusqu'ici — modèle PPC, reconstruction 3D, validation xTB, test de planéité, analyse électronique — est intégré dans une application web unique, le *designer*, qui sert à la fois d'interface d'utilisation et d'infrastructure de campagne expérimentale. L'utilisateur y saisit

un benzénoïde de départ — en le dessinant sur un canevas hexagonal ou en l’important depuis la base BenzDB —, configure les contraintes actives (un pré-réglage en un clic parmi les configurations de la section 6, ou un réglage fin contrainte par contrainte) ainsi que la profondeur de validation xTB souhaitée, puis lance la génération. Le pipeline orchestre alors automatiquement, sans intervention supplémentaire, la compilation du modèle en XCSP3, sa résolution par CHOCO, la reconstruction 3D de chaque solution, la validation xTB et le test de planéité, et le calcul des descripteurs électroniques (Kekulé, Clar, RBO/CBO). Les résultats sont persistés dans une base SQLite et explorables depuis une liste paginée, triable et filtrable, avec accès direct à un visualiseur 3D intégré pour inspecter chaque solution en relief. Le détail de chaque écran, avec les captures correspondantes, est donné en annexe A.5.




FIGURE 15 – Pipeline intégré du designer, de la saisie au résultat exploré.

## 6 Étude expérimentale

Comme établi en section 3, la planéité est une propriété globale qu’aucun jeu de contraintes locales ne capture exactement. La question pratique devient alors : *quelles contraintes additionnelles augmentent le plus la proportion de molécules planes parmi celles que le modèle génère ?* Nous y répondons par une étude comparative de quatre configurations **Cf<sub>1</sub>**, **Cf<sub>2</sub>**, **Cf<sub>3</sub>** et **C<sub>topo</sub>**, des plus simples aux plus contraintes, qui isolent successivement chaque levier identifié.

### 6.1 Protocole et banc d’essai

Le banc d’essai utilise les squelettes benzénoïdes canoniques **plans** de la base *BenzDB*, de  $h_3$  à  $h_9$  hexagones (tableau 1). La métrique principale est la **distribution des verdicts dièdres** définie section 5.1.3 : pour chaque configuration, on reporte la proportion de solutions **très planes** (**TP**, dièdre maximal  $< 10^\circ$ ) et **planes acceptables** (**A**, dièdre maximal  $< 25^\circ$ , *cumulatif* : la colonne A inclut toutes les solutions TP). Le nombre absolu  $N$  de solutions générées est également reporté, car il est souvent plus parlant pour l’aval, qui s’intéresse au nombre de candidats exploitables. Le complément à 100 % de la colonne A donne la proportion de solutions NON PLANES (dièdre  $\geq 25^\circ$ ). La distinction **TP** *vs.* **A** suit la recommandation des chimistes : un dièdre maximal entre 10 et  $25^\circ$  correspond à une molécule *légèrement* déformée mais chimiquement raisonnable, à distinguer d’une planéité quasi parfaite. Les campagnes sont reproductibles (section 5.1.2), agrégées en base SQLite, et chaque configuration de contraintes est comparée terme à terme aux autres sur le même corpus.

| $h$                  | $h_3$ | $h_4$ | $h_5$ | $h_6$ | $h_7$ | $h_8$ | $h_9$ |
|----------------------|-------|-------|-------|-------|-------|-------|-------|
| nombre de squelettes | 3     | 6     | 16    | 44    | 126   | 376   | 2 418 |

TABLE 1 – Nombre de squelettes benzénoïdes **plans** du corpus par taille  $h$ , issus de BenzDB.

### 6.2 Environnement logiciel et reproductibilité

La reproductibilité des expériences est une garantie centrale du pipeline : un même fichier d’entrée et une même configuration de contraintes doivent produire le *même* résultat, indépendamment de la machine ou de la date d’exécution.

**Stack logicielle.** Le pipeline est écrit en **Python 3.14.4**, aligné entre le poste de développement (Windows 11) et l’environnement **conda** du cluster. Les bibliothèques utilisées et leurs versions (extraits de `requirements.txt`) sont récapitulées dans le tableau 2.

| Bibliothèque | Version | Rôle                                            |
|--------------|---------|-------------------------------------------------|
| Python       | 3.14.4  | langage hôte du pipeline                        |
| PyCSP3       | 2.5.1   | modélisation des contraintes (génération XCSP3) |
| Choco        | —       | solveur PPC Java invoqué par PyCSP3             |
| NetworkX     | 3.6.1   | graphes (dual, carbone, couplage de Blossom)    |
| NumPy        | 2.4.6   | algèbre linéaire (ACP, reconstruction 3D)       |
| Flask        | 3.1.3   | backend web du designer                         |
| Werkzeug     | 3.1.8   | dépendance Flask (WSGI)                         |
| Jinja2       | 3.1.6   | dépendance Flask (templates)                    |
| 3Dmol.js     | —       | bibliothèque JS du visualiseur 3D (via CDN)     |

TABLE 2 – Stack logicielle du pipeline et du designer.

**Cluster de calcul.** Les campagnes de grande taille tournent sur le cluster **COALA** du LIS (Aix-Marseille Université), composé de **16 nœuds** (lames `lis-cluster-coala-49` à `-64`), chacun équipé de **2 processeurs Intel Xeon Gold 5218R** (20 cœurs physiques) et **187 GiB de RAM**. Au total, jusqu’à **320 instances xTB en parallèle**. Les artefacts (solutions, géométries XYZ, verdicts) sont persistés dans une base **SQLite** (mode `WAL`). Les détails du protocole (variables d’environnement, `PYTHONHASHSEED`, orchestration cluster) sont en annexe A.3.

### 6.3 Comparaison du solveur ACE vs Choco

Bien que le solveur ACE ait été initialement choisi comme moteur par défaut dans notre pipeline — et ce choix était déjà acté au moment de la rédaction du résumé —, une comparaison scientifique systématique avec CHOCO a été menée pour quantifier leurs performances respectives. L’enjeu était de déterminer dans quelle mesure le choix du solveur influence la rapidité d’exécution et l’exhaustivité de l’énumération, sur un corpus de 11 956 instances couvrant les tailles de graphes de  $h = 3$  à  $h = 9$  et les configurations CF1, CF2, CF3 et CTOPO. L’intégralité des problèmes a été résolue sans échec ni dépassement de temps (timeout fixé à 300 s). Les résultats, détaillés dans les figures 16 et 17, montrent une avance nette de CHOCO sur tous les cas testés. **C’est sur la base de ces résultats que nous avons migré vers Choco pour l’ensemble des campagnes de génération.**




FIGURE 16 – Distribution des temps d’exécution : ACE vs Choco par le corpus  $h_3 - h_9$




FIGURE 17 – Temps moyen d’exécution par configuration (barres d’erreur =  $\pm 1$  écart-type)

**Interprétation.** Quelle que soit la taille du graphe ou la configuration testée, CHOCO est systématiquement environ 1,85 à 1,90 fois plus rapide que ACE. Si l’on se fie uniquement à la performance brute, CHOCO serait donc plus adapté pour de futures campagnes de génération à grande échelle. C’est sur la base de cette comparaison que nous avons décidé d’adopter CHOCO comme solveur par défaut pour la suite du projet.

#### 6.4 $Cf_1$ : Baseline (contraintes structurelles)

La première configuration mesure la référence : avec les seules contraintes structurelles (section 4) et table de voisinage (C5) quelle proportion des solutions est réellement plane après validation xTB ?

Le tableau 3 récapitule les résultats sur le corpus  $h_3$ – $h_9$ .

| $h$   | $N$     | $N_A$   | %A      |
|-------|---------|---------|---------|
| $h_3$ | 7       | 7       | 100,0 % |
| $h_4$ | 44      | 42      | 95,5 %  |
| $h_5$ | 278     | 252     | 90,6 %  |
| $h_6$ | 2 146   | 1 834   | 85,5 %  |
| $h_7$ | 15 004  | 11 381  | 75,8 %  |
| $h_8$ | 112 800 | 78 793  | 69,9 %  |
| $h_9$ | 646 319 | 351 343 | 54,4 %  |

TABLE 3 – Résultats de la configuration  $Cf_1$  (baseline).  $N_A$  : nombre cumulé de solutions planes ou acceptables (dièdre  $< 25^\circ$ ), incluant les solutions très planes. %A : proportion correspondante.

#### 6.5 $Cf_2$ : Pb1 + adjacence 5–7 (motif azulène)

$Cf_2$  ajoute à  $Cf_1$  deux contraintes complémentaires, identifiées comme les plus efficaces parmi les variantes locales explorées :

- **Pb1** ( $K_{pb}=1$ ) :  $\sum_{v \in \partial G_D} \mathbf{1}[x_v = 5] \leq 1$ , c’est-à-dire *au plus un pentagone au bord* du squelette. Cette contrainte traduit l’observation empirique que les pentagones de bord, qui introduisent

une courbure locale non compensée par un voisin opposé, sont particulièrement déstabilisants ; la limiter améliore fortement le taux de planéité.

- **adj\_57** (contrainte C6, section 4.3.1).

Le tableau 4 récapitule les résultats sur le corpus.

| $h$   | $N$    | $N_A$  | %A      |
|-------|--------|--------|---------|
| $h_3$ | 5      | 5      | 100,0 % |
| $h_4$ | 16     | 16     | 100,0 % |
| $h_5$ | 62     | 55     | 88,7 %  |
| $h_6$ | 254    | 233    | 91,7 %  |
| $h_7$ | 900    | 802    | 89,1 %  |
| $h_8$ | 3 292  | 2 925  | 88,8 %  |
| $h_9$ | 21 127 | 15 623 | 73,9 %  |

TABLE 4 – Résultats de la configuration  $Cf_2$  (Pb1 + adj\_57).

## 6.6 $Cf_3$ : Interdire les paires 7–7 adjacentes

$Cf_3$  durcit  $Cf_2$  en interdisant la concentration locale de courbure négative. Concrètement, on impose une **contrainte de Gauss–Bonnet locale** de paramètre  $\tau_{gb} = 0$  et rayon 2 dans le graphe dual :

$$\forall v \in V_D, \quad ||\{u : x_u = 5, d_{G_D}(u, v) \leq 2\}| - |\{u : x_u = 7, d_{G_D}(u, v) \leq 2\}|| \leq 0.$$

En pratique, cela revient à interdire que deux heptagones soient à distance  $\leq 2$  dans le dual sans être compensés par autant de pentagones dans le même voisinage, ce qui exclut notamment les paires 7–7 adjacentes.

Le tableau 5 récapitule les résultats sur le corpus.

| $h$   | $N$   | $N_A$ | %A      |
|-------|-------|-------|---------|
| $h_3$ | 5     | 5     | 100,0 % |
| $h_4$ | 12    | 12    | 100,0 % |
| $h_5$ | 28    | 24    | 85,7 %  |
| $h_6$ | 75    | 71    | 94,7 %  |
| $h_7$ | 178   | 171   | 96,1 %  |
| $h_8$ | 512   | 500   | 97,7 %  |
| $h_9$ | 2 845 | 2 292 | 80,5 %  |

TABLE 5 – Résultats de la configuration  $Cf_3$  (Gauss–Bonnet local, rayon 2).

## 6.7 $C_{\text{topo}}$ : Topologie complète

Pour traiter  $h_9$ , nous avons cherché des contraintes *non redondantes* avec Pb1 et qui capturent un mécanisme d’échec différent. Une analyse *a posteriori* des solutions  $Cf_1$  non planes a fait émerger deux **descripteurs topologiques** complémentaires, qui forment ensemble la configuration  $C_{\text{topo}}$ . On appelle ici *descripteur topologique* toute quantité calculée sur le graphe dual d’une solution qui résume une propriété structurelle et dont on observe la corrélation avec la planéité.

**Descripteur 1 : motifs de rayon 2 dans le graphe dual.** Pour chaque cycle  $v$  d’une solution, on définit son *motif de rayon 2* comme le couple  $(x_v, \mathcal{M}(x_u : u \in \mathcal{N}_{G_D}(v)))$ , où  $\mathcal{M}(\cdot)$  désigne un **multiset** (ou *multi-ensemble*), c’est-à-dire un ensemble autorisant les répétitions :  $\mathcal{M}(6, 7, 7) \neq \mathcal{M}(6, 7)$ , les deux voisins de taille 7 étant comptés séparément. Par exemple, le motif  $7|[6, 7, 7]$  désigne un heptagone entouré d’un hexagone et de deux heptagones. L’analyse statistique sur le

corpus  $h_7, h_8, h_9$  a identifié une *blacklist* d’une dizaine de motifs fortement corrélés à la non-planéité, indépendamment de la taille du benzénoïde : par exemple  $7 \mid [6, 7, 7]$  ne produit que 9,2 % de solutions planes sur  $h_8$ , contre une moyenne de  $\sim 60$  %. La contrainte  $C_{\text{topo}}$  interdit explicitement tous ces motifs ; elle est implémentée par une famille de contraintes négatives sur les tuples  $(x_v, x_{u_1}, \dots, x_{u_k})$ , intégrées dans le modèle PPC.

**Descripteur 2 : topologie du squelette.** Le second descripteur est calculé *avant* l’assignement des tailles : le nombre  $n_{\text{péri}}$  d’atomes péri-condensés du squelette, c’est-à-dire partagés par au moins trois cycles. Empiriquement, les squelettes  $n_{\text{péri}} \geq 4$  (péri-condensés, type coronène) résistent beaucoup mieux à la déformation que les squelettes étalés, où les défauts peuvent se replier sans coût énergétique majeur. La contrainte impose donc  $n_{\text{péri}} \geq 4$ , ce qui est un *pré-filtre sur le squelette d’entrée* : si le benzénoïde fourni ne le satisfait pas,  $C_{\text{topo}}$  ne génère aucune solution.

**Résultats.** Le tableau 6 récapitule les résultats sur le corpus.

| $h$   | $N$    | $N_A$  | %A      |
|-------|--------|--------|---------|
| $h_6$ | 90     | 90     | 100,0 % |
| $h_7$ | 1 035  | 998    | 96,4 %  |
| $h_8$ | 9 340  | 8 512  | 91,1 %  |
| $h_9$ | 43 057 | 35 440 | 82,3 %  |

TABLE 6 – Résultats de la configuration  $C_{\text{topo}}$  (topologie complète, applicable à partir de  $h_6$ ).

## 6.8 Bilan expérimental

L’étude désigne trois régimes selon la taille du squelette d’entrée.

- **Pour  $h_3$ – $h_5$  :** les volumes restent faibles ( $\leq 280$  solutions par configuration sur tout le corpus), le taux de très planes de  $Cf_1$  seul est déjà élevé (88–100 %), et  $Cf_2$  ou  $Cf_3$  atteignent typiquement 100 % très planes. À cette échelle, le filtrage par contraintes additionnelles est essentiellement superflu, et la configuration  $C_{\text{topo}}$  n’est pas applicable (le pré-filtre  $n_{\text{péri}} \geq 4$  exclut tous les squelettes,  $n_{\text{péri}}$  ne dépassant pas 3 avant  $h_6$ ) ;
- **Pour  $h_6$ – $h_8$  :**  $Cf_3$  reste la plus pure (93–**97,3** % très planes), au prix d’un volume réduit ; à utiliser lorsqu’on cherche très peu de candidats mais très fiables.  $C_{\text{topo}}$  atteint la même couverture cumulée %A en élargissant le volume d’un facteur  $\sim 10$  ;
- **Pour  $h_9$  et au-delà :**  $C_{\text{topo}}$  est nettement supérieure (69,6 % de très planes contre 59,6 % pour  $Cf_3$ , **82,3** % cumulé acceptable contre 80,5 %), et produit dix-huit fois plus de très planes en absolu (29 954 contre 1 696). C’est la configuration par défaut recommandée pour les grandes tailles.

**Lecture chimique de la zone « acceptable ».** La métrique cumulée A (dièdre  $< 25^\circ$ ) montre qu’une grande partie des solutions de  $Cf_1$  non strictement planes restent néanmoins modérément déformées. Sur  $h_9$ , la proportion passe ainsi de 37,4 % pour le seuil strict ( $< 10^\circ$ ) à 54,4 %. Sur les configurations contraintes, l’écart est plus faible car les solutions sont déjà majoritairement très planes. Cela suggère, comme l’ont indiqué les chimistes, que les molécules issues du modèle se déforment généralement de façon modérée plutôt que prononcée.

L’effet de  $C_{\text{topo}}$  confirme une difficulté identifiée à la section 3 : la planéité est une propriété globale, difficile à capturer par de simples contraintes locales sur les cycles 5/6/7. Les meilleurs résultats sont obtenus grâce à une analyse du corpus généré et à des informations portant sur le squelette lui-même. Cette démarche, consistant à générer, analyser puis enrichir le modèle, ouvre naturellement la voie aux perspectives présentées dans la section 7.

## 7 Conclusion et perspectives

### 7.1 Conclusion

Ce stage s’inscrit dans la continuité des travaux de Varet [1] sur la génération exhaustive de structures moléculaires par programmation par contraintes. Nous avons proposé un modèle permettant de générer, à partir d’un benzénoïde donné, toutes les substitutions admissibles où chaque hexagone peut être conservé ou remplacé par un cycle à 5 ou 7 atomes.

L’un des apports principaux du modèle est l’utilisation d’une table de voisinage décrivant les configurations locales considérées comme réalisables. Cette représentation offre une grande souplesse : les connaissances chimiques sont concentrées dans un ensemble de motifs admissibles qu’il est possible de faire évoluer sans modifier le reste du modèle. De nouvelles règles peuvent ainsi être intégrées simplement à mesure que la compréhension chimique de ces structures progresse.

Les solutions produites sont ensuite reconstruites en trois dimensions, validées géométriquement et analysées du point de vue de leurs propriétés électroniques. L’ensemble de cette chaîne de traitement a été intégré dans une application interactive permettant à la fois la génération, la visualisation et l’exploration des molécules obtenues. Les outils d’analyse électronique initialement développés pour les benzénoïdes ont également été étendus aux structures comportant des cycles à 5 et 7 atomes.

L’étude expérimentale montre que certaines contraintes améliorent significativement la proportion de molécules planes obtenues. Elle met surtout en évidence une limite fondamentale du problème : la planéité est une propriété globale qui ne peut être entièrement capturée par des contraintes locales. Cette observation explique pourquoi les approches fondées uniquement sur des règles de voisinage perdent en efficacité lorsque la taille des molécules augmente. Les meilleurs résultats sont obtenus en combinant la génération par contraintes avec une analyse plus globale des structures produites.

Ces travaux constituent ainsi une première étape vers la génération assistée de HAP non-benzénoïdes et fournissent un cadre extensible pour explorer de nouvelles familles de molécules présentant des propriétés électroniques potentiellement intéressantes.

### 7.2 Perspectives

La démarche suivie pendant ce stage présente une forme caractéristique : on génère un corpus de candidats par un modèle PPC, on les valide par xTB, on observe les résultats, on interprète les régularités (les pentagones de bord nuisent à la planéité, les paires 5–7 se compensent), on les transforme en hypothèses, on les exprime sous forme de nouvelles contraintes, puis on ré-énumère pour mesurer leur effet. Au sens méthodologique, c’est une boucle d’*apprentissage* aujourd’hui tenue par l’humain ; demain, elle pourrait être tenue partiellement par une machine. C’est précisément l’enjeu de la **combinaison IA symbolique (PPC) + IA d’apprentissage**, qui fait l’objet d’une recherche active actuellement [17, 18]. La PPC apporte la garantie d’exhaustivité et l’explicabilité (chaque solution satisfait des règles écrites explicitement) ; l’apprentissage apporte la capacité à inférer des motifs dans des espaces de grande dimension où l’humain ne saurait les formuler à la main. Pour notre problème, cela ouvre plusieurs voies : apprendre des contraintes à partir du corpus déjà généré, guider la recherche du solveur par une heuristique entraînée, ou encore prédire la planéité par un réseau de neurones sur graphe pour éviter les appels xTB les moins informatifs. Cette direction, qui maintient le moteur symbolique au cœur mais l’enrichit d’heuristiques apprises, semble particulièrement adaptée à un problème comme le nôtre, où la connaissance chimique est encore en construction et progresse au rythme des expériences elles-mêmes.

## A Annexe

### A.1 Définitions formelles de cohérence

Les définitions suivantes sont adaptées de Mackworth [11] et reprises dans la thèse de Varet [1] (Déf. 1.4.1).

**Définition 11** (Arc-cohérence). *Soit  $P = (X, D, C)$  un CSP. Une valeur  $v \in D_x$  est arc-cohérente par rapport à une contrainte  $c \in C$  de portée  $S(c) \ni x$  si, pour chaque autre variable  $y \in S(c)$ , il existe une valeur  $w \in D_y$  telle que le tuple partiellement défini par  $t[\{x\}] = v$ ,  $t[\{y\}] = w$  est compatible avec  $R(c)$ .*

*Un CSP est dit arc-cohérent si chaque valeur de chaque domaine est arc-cohérente par rapport à toutes les contraintes qui la concernent.*

**Définition 12** (Propagation de contraintes). *La propagation de contraintes (ou filtrage) est le processus itératif consistant à supprimer des domaines toute valeur non arc-cohérente. Le processus se répète jusqu'à l'obtention d'un point fixe : un état où aucune suppression supplémentaire n'est possible. Chaque suppression peut déclencher de nouvelles suppressions en cascade (effet "boule de neige").*

**Remarque 6.** *L'arc-cohérence ne garantit pas à elle seule la satisfiabilité du CSP : un problème peut être arc-cohérent et ne posséder aucune solution (les domaines restent non vides, mais aucune combinaison complète n'est consistante). Elle réduit cependant l'espace de recherche et est systématiquement appliquée avant et pendant le backtracking.*

### A.2 Règle de Hückel

La règle suivante est établie par Hückel en 1931 [10] dans le cadre de la théorie des orbitales moléculaires au niveau *tight-binding*.

**Définition 13** (Règle de Hückel, [10]). *Un cycle conjugué plan est aromatique si et seulement s'il possède  $4n + 2$  électrons  $\pi$  pour un entier  $n \geq 0$ .*

Les premiers cas sont :  $n = 0$  (2 électrons, cyclopropényle cation),  $n = 1$  (6 électrons, benzène),  $n = 2$  (10 électrons, azulène et naphthalène). Les cycles à  $4n$  électrons (cyclobutadiène : 4, cyclooctatetraène : 8) sont dits *antiaromatiques* et sont déstabilisés.

**Remarque 7.** *Dans notre contexte, seuls les hexagones satisfont la règle avec  $n = 1$  (6 atomes de carbone  $\Rightarrow$  6 électrons  $\pi$  délocalisés). Les pentagones et heptagones n'ont pas le bon décompte et ne peuvent donc pas porter de sextet de Clar. C'est pourquoi la variable  $y_h$  du modèle  $\mathcal{M}_C$  (section 5.2) n'est définie que sur les hexagones  $h \in \mathcal{H}$ .*

### A.3 Protocole de validation xTB (détails)

**Historique : abandon de la dynamique moléculaire.** Une première version du pipeline utilisait une *dynamique moléculaire* courte (`xtb -md` à 298 K pendant 1 ps) pour briser la symétrie planaire parasite avant l'optimisation. Cette approche s'est révélée **non reproductible** : xTB initialise les vitesses MD à partir de l'horloge système et n'expose aucune graine accessible (confirmé par l'issue GitHub #730 du dépôt `grimme-lab/xtb`, ouverte depuis 2022 et sans réponse). Sur des structures tendues ( $h_8$ – $h_9$ ), deux exécutions identiques pouvaient basculer entre les verdicts PLAN et NON-PLAN, ce qui invalidait toute campagne expérimentale.

**Protocole déterministe retenu.** La perturbation  $z'_i = z_i + A \sin(2\pi i/N + \varphi)$  ( $A = 0,05$  Å,  $\varphi = 0,5$  rad) est appliquée aux  $N$  atomes ordonnés canoniquement avant l'appel à `xtb -opt tight` (GFN2-xTB 6.7.1). Les variables d'environnement suivantes sont imposées avant chaque appel :



```
OMP_NUM_THREADS=1    MKL_NUM_THREADS=1
OPENBLAS_NUM_THREADS=1    NUMEXPR_NUM_THREADS=1
PYTHONHASHSEED=0
```

De plus, l'ordre canonique `sorted(...)` est appliqué partout où des collections non ordonnées (ensembles d'atomes, de liaisons) seraient itérées. L'ensemble du pipeline est ainsi *byte-déterministe*.

**Filtre anti-fragmentation.** Un filtre rejette les optimisations où un atome s'éjecte au-delà de 30 Å du barycentre (liaison rompue). La solution reçoit alors le verdict ÉCHEC xTB.

**Persistance.** La géométrie finale est conservée dans `md_final_opt.xyz` sous chaque solution. L'orchestration sur le cluster COALA utilise un dispatcher basé sur un *manifest JSONL* partagé sur NFS et des verrous atomiques (`O_CREAT|O_EXCL`) garantissant qu'un job n'est pris que par un seul worker.

## A.4 Calcul de la métrique dièdre `max_dihedral_deg`

**Énumération des chemins.** Soit  $G_C = (V_C, E_C)$  le graphe de carbone après optimisation xTB (les hydrogènes sont écartés). Pour chaque arête  $\{B, C\} \in E_C$  prise dans l'ordre  $B < C$ , et pour chaque paire de voisins  $A \in \mathcal{N}_{G_C}(B)$ ,  $D \in \mathcal{N}_{G_C}(C)$  vérifiant  $A \neq C$ ,  $D \neq B$  et  $A \neq D$ , le quadruplet  $(A, B, C, D)$  forme une chaîne de trois liaisons consécutives.

**Angle dièdre.** Pour chaque quadruplet, posons  $\mathbf{b}_1 = \mathbf{x}_B - \mathbf{x}_A$ ,  $\mathbf{b}_2 = \mathbf{x}_C - \mathbf{x}_B$ ,  $\mathbf{b}_3 = \mathbf{x}_D - \mathbf{x}_C$ . L'angle dièdre signé entre les plans  $(A, B, C)$  et  $(B, C, D)$  est

$$\varphi(A, B, C, D) = \text{atan2}(\|\mathbf{b}_2\| \cdot (\mathbf{b}_1 \cdot (\mathbf{b}_2 \times \mathbf{b}_3)), (\mathbf{b}_1 \times \mathbf{b}_2) \cdot (\mathbf{b}_2 \times \mathbf{b}_3)) \in (-180^\circ, 180^\circ].$$

**Écart au plan.** Pour une molécule plane, chaque  $\varphi$  vaut exactement  $0^\circ$  (configuration *cis*) ou  $\pm 180^\circ$  (configuration *trans*). L'écart au plan est donc

$$\delta(\varphi) = \min(|\varphi|, 180^\circ - |\varphi|) \in [0, 90^\circ],$$

et la métrique retenue est le maximum sur tous les quadruplets connectés. Une molécule parfaitement plane vérifie `max_dihedral_deg` =  $0^\circ$  ; une molécule fortement courbée s'approche de  $90^\circ$ .

**Coût.** Implémentation vectorielle en NumPy :  $\sim 0,4$  ms par molécule. Le calcul sur l'intégralité de la base finale ( $\sim 805\,000$  géométries optimisées) prend environ 5 minutes en mono-thread, sans nouvelle invocation de xTB.

## A.5 Interface du designer (détails)

Cette annexe détaille, écran par écran, l'interface du *designer* dont le pipeline est résumé en figure 15 (section 5.3).

**Saisie de l'instance.** Un canevas hexagonal en SVG permet à l'utilisateur de *dessiner* un benzénoïde de départ : on clique sur les hexagones du pavage pour les sélectionner, et le graphe dual sous-jacent est construit à la volée. La saisie peut aussi se faire par *importation* : un benzénoïde déjà enregistré dans la base BenzDB (ou venant d'un fichier au format texte adapté) peut être chargé directement, ce qui est utile pour rejouer une campagne sur un corpus déjà fixé.




FIGURE 18 – Designer en mode saisie : canevas hexagonal pour dessiner un benzénoïde ou choisir un benzenoïde importé depuis BenzDB.

**Configuration des contraintes et exécution.** Une fois l’instance posée, l’utilisateur configure le solveur depuis un panneau organisé en deux onglets. L’onglet **Préréglage** propose quatre configurations canoniques, sélectionnables d’un clic, qui correspondent exactement aux configurations étudiées expérimentalement (section 6) :

- **Cf1 — Baseline** : contraintes structurelles uniquement (C1+C2+C3+C5).
- **Cf2 — Pb1 + adj\_57** : Cf1 plus pentagones plafonnés au bord et appariement 5–7 obligatoire (motif azulène).
- **Cf3 — Pb1 + adj\_57 + pas de 7–7 adjacents** : durcissement local de la courbure (Gauss–Bonnet locale à zéro dans un rayon de 2 dans  $G_D$ ).
- **Ctopo — Topologie complète** : Cf3 plus une blacklist de motifs de rayon 2 du graphe dual et un pré-filtre exigeant un squelette compact (au moins 4 atomes péri-condensés). Recommandé pour les grands squelettes ( $h_9$ ).

L’onglet **Avancé** expose individuellement chaque flag (Pb1, adj\_57, tau\_gb, ctopo\_filter, etc.) pour les expérimentations fines.

Un second panneau gère la **validation xTB**. Le mode par défaut est *skip xTB* : le pipeline s’arrête après la reconstruction 3D et produit directement les géométries planes (non optimisées), ce qui est très rapide et suffit pour visualiser les sorties du modèle PPC. Pour valider la planéité physique, l’utilisateur bascule sur *det-opt* (le protocole déterministe décrit section 5.1.2), ou plus rarement sur les modes *md* et *multi-runs* conservés pour comparaison historique. Une option permet aussi de comparer la planéité des solutions à celle du benzénoïde d’entrée pur (tout-hexagones).

Le lancement d’une génération orchestre, derrière l’interface, l’ensemble du pipeline : compilation du modèle en XCSP3, appel à CHOCO, reconstruction 3D des solutions, validation xTB (si demandée), test de planéité par ACP et calcul des métriques électroniques. Les résultats — solutions, géométries XYZ compressées, statistiques par campagne — sont persistés dans une base SQLite, ce qui rend chaque campagne facilement rejouable et comparable. Les exécutions sur le grand corpus ( $h \geq 7$ , jusqu’à plusieurs milliers de squelettes) sont distribuées sur le cluster décrit ci-dessous.

**Exploration des solutions et visualiseur intégré.** Une fois une campagne terminée, le designer présente l’ensemble des solutions produites sous forme d’une **liste paginée** (figure 19). Chaque ligne récapitule les caractéristiques d’une solution : identifiant, composition  $(n_5, n_6, n_7)$ , verdict de planéité, angle maximal hors-plan, et distances quadratique / extrême au plan moyen.

Plusieurs leviers facilitent l’exploration :

- **Tri** sur n’importe quelle colonne (angle croissant ou décroissant, identifiant, etc.) ;

- **Filtrage** par verdict de planéité (PLAN, NON-PLAN, géométrie infaisable, échec xTB), par sous-chaîne de la composition, ou par squelette de départ ;
- navigation directe vers le **visualiseur 3D** d’une solution donnée pour inspecter sa géométrie en relief, lire ses structures de Kekulé, ses couvertures de Clar et ses RBO/CBO (section 5.2).

Le visualiseur, intégré à la même application web, est aussi accessible indépendamment du design pour explorer la base de résultats du run final ( $\sim 1,5$  M de solutions sur  $h_3-h_9$ ). Il sert à la fois d’outil d’exploration pour les chimistes et de banc de débogage pour le développement (vérifier en 3D qu’une géométrie produite par le pipeline ressemble à ce que l’on attend).

**Molécule : 0-7-8-14-15-16 (Ctopo)**

|                  |              |       |                 |           |           |           |     |
|------------------|--------------|-------|-----------------|-----------|-----------|-----------|-----|
| CSP COMBINATOIRE | XTB VALIDÉES | PLANS | DONT TRÈS PLANS | NON PLANS | ANGLE MIN | ANGLE MAX | JOB |
| 18               | 18           | 18    | 18              | 0         | 0.06°     | 1.56°     | ok  |

Filtrer par sol\_idx ou sizes (ex: 6\_6\_6\_6\_6\_5\_7\_5\_7)    Filtre : Plans (TP + ACC, dièdre < 25°)    Tri : Angle croissant    Page size : 50

| SOL_IDX | SIZES       | VERDICT | ANGLE (°) | RMSD | HEIGHT | TENTATIVES MD | VUE 3D |
|---------|-------------|---------|-----------|------|--------|---------------|--------|
| 14      | 6_5_7_7_6_5 | PLAN    | 0.06°     | —    | —      | 1             | 3D     |
| 7       | 5_6_7_6_6_6 | PLAN    | 0.08°     | —    | —      | 1             | 3D     |
| 2       | 5_5_7_7_6_6 | PLAN    | 0.08°     | —    | —      | 1             | 3D     |
| 9       | 5_6_6_6_6_7 | PLAN    | 0.08°     | —    | —      | 1             | 3D     |

FIGURE 19 – Liste des solutions avec tri et filtrage.

## A.6 Détails de l’assemblage moléculaire

Cette annexe détaille les trois opérations successives qui transforment la géométrie 2D des sommets en une molécule complète.

**Liaisons doubles.** À partir du graphe de carbone  $G_C = (V_C, E_C)$ , on cherche un couplage (ensemble d’arêtes deux à deux non adjacentes) de cardinalité maximale. Ce problème est résolu par l’algorithme de Blossom d’Edmonds [7], qui trouve un couplage maximum en temps polynomial  $O(|V|^3)$ . Chaque arête du couplage est marquée comme liaison double dans la molécule. Les sommets de  $V_C$  qui ne sont couverts par aucune arête du couplage correspondent à des électrons  $\pi$  non appariés, c’est-à-dire à des sites radicalaires. Le choix d’un couplage maximum (par opposition à un couplage parfait) est volontaire : certaines molécules non-benzénoïdes à nombre impair d’atomes de carbone n’admettent pas de couplage parfait, et il est chimiquement pertinent de détecter ces radicaux plutôt que de forcer un appariement artificiel.

**Ajout des hydrogènes.** Dans le graphe de carbone, tout atome de carbone de degré 2 est un carbone de bord : il possède deux liaisons avec d’autres carbones et une valence libre restante, qui doit être saturée par un atome d’hydrogène. Pour chaque tel carbone  $c$ , on identifie le cycle auquel il appartient, et on place l’hydrogène à l’extérieur de ce cycle, dans la direction de la bissectrice des deux liaisons C–C existantes, à une distance fixe de 1,088 Å, longueur standard de la liaison C–H. Un carbone de degré 3 (carbone interne) n’a pas de valence libre et ne porte pas d’hydrogène.

**Export.** La géométrie complète, incluant les coordonnées  $(x, y, z)$  de tous les atomes de carbone et d’hydrogène, est écrite dans un fichier au format XYZ. Ce format textuel simple, où chaque ligne donne le symbole de l’élément suivi de ses trois coordonnées, est directement lisible par xTB pour l’optimisation géométrique décrite en section 5.1.2. Aucune information de connectivité n’est nécessaire dans ce fichier, car xTB la reconstruit automatiquement à partir des distances interatomiques. Toutes les géométries ainsi produites sont initialement planes : tous les atomes ont  $z = 0$ . C’est l’optimisation par xTB qui, en brisant cette symétrie, déterminera si la molécule est effectivement plane à l’équilibre énergétique.

## Références et bibliographie

- [1] A. Varet, *Programmation par contraintes et chimie théorique : utilisation du formalisme CSP pour résoudre des problématiques liées aux benzénoïdes*, thèse de doctorat, Aix-Marseille Université, 2022.
- [2] F. Rossi, P. van Beek, T. Walsh (éds.), *Handbook of Constraint Programming*, Elsevier, 2006.
- [3] C. Lecoutre, *Constraint Networks : Techniques and Algorithms*, ISTE/Wiley, 2009.
- [4] C. Lecoutre, N. Szczechanski, *PyCSP3 : modélisation en programmation par contraintes et le solveur ACE* (Abscon Constraint Engine). [pycsp.org](http://pycsp.org).
- [5] C. Prud'homme, J.-G. Fages, X. Lorca, *Choco Solver Documentation*, TASC – INRIA Rennes, LINA CNRS UMR 6241, COSLING S.A.S. [choco-solver.org](http://choco-solver.org).
- [6] A. Varet, N. Prcovic, C. Terrioux *et al.*, *BenzAI : A Program to Design Benzenoids with Defined Properties Using Constraint Programming*, Journal of Chemical Information and Modeling, 2022. DOI : [10.1021/acs.jcim.2c00353](https://doi.org/10.1021/acs.jcim.2c00353).
- [7] J. Edmonds, *Paths, trees, and flowers*, Canadian Journal of Mathematics, 17 :449–467, 1965.
- [8] H. Whitney, *Congruent graphs and the connectivity of graphs*, American Journal of Mathematics, 54(1) :150–168, 1932.
- [9] E. Clar, *The Aromatic Sextet*, John Wiley & Sons, Londres, 1972.
- [10] E. Hückel, *Quantentheoretische Beiträge zum Benzolproblem*, Zeitschrift für Physik, 70 :204–286, 1931 (règle des  $4n + 2$  électrons  $\pi$ ).
- [11] A. K. Mackworth, *Consistency in Networks of Relations*, Artificial Intelligence, 8(1) :99–118, 1977.
- [12] L. Pauling, *The Nature of the Chemical Bond*, Cornell University Press, 3<sup>e</sup> édition, 1960.
- [13] M. Randić, *Aromaticity and conjugation*, Journal of the American Chemical Society, 99(2) :444–450, 1977 (ordres de liaison et circuits conjugués).
- [14] F. J. Rispoli, *Counting Perfect Matchings in Hexagonal Systems Associated with Benzenoids*, Mathematics Magazine, 14 :194–200, 2001.
- [15] P. W. Kasteleyn, *Graph theory and crystal physics*, in *Graph Theory and Theoretical Physics*, Academic Press, p. 43–110, 1967.
- [16] C. Bannwarth, S. Ehlert, S. Grimme, *GFN2-xTB — An Accurate and Broadly Parametrized Self-Consistent Tight-Binding Quantum Chemical Method*, Journal of Chemical Theory and Computation, 15(3) :1652–1671, 2019.
- [17] Q. Cappart, D. Chételat, E. Khalil, A. Lodi, C. Morris, P. Veličković, *Combinatorial Optimization and Reasoning with Graph Neural Networks*, Journal of Machine Learning Research, 24(130) :1–61, 2023.
- [18] Y. Bengio, A. Lodi, A. Prouvost, *Machine learning for combinatorial optimization : a methodological tour d'horizon*, European Journal of Operational Research, 290(2) :405–421, 2021.