

Mémoire de stage de Master 2
Informatique et Mathématiques Discrètes (IMD)
Année universitaire 2025–2026

Génération automatique et exhaustive de structures moléculaires bi-dimensionnelles par programmation par contraintes

Toky Nirina RAMAHERISOA

Encadrants Nicolas PRCOVIC et Cyril TERRIOUX
LIS, équipe COALA, Aix-Marseille Université

Partenaires Yannick CARISSAN et Denis HAGEBAUM-REIGNIER
Institut des Sciences Moléculaires de Marseille (iSm2)

Table des matières

Table des figures

Liste des tableaux

Liste des algorithmes

1 Introduction

1.1 Contexte

Les *hydrocarbures aromatiques polycycliques* (HAP) sont des molécules constituées uniquement de carbone et d'hydrogène, dont les atomes de carbone forment des cycles fusionnés. Ils sont étudiés pour leurs propriétés électroniques et opto-électroniques. Parmi les HAP, les *benzénoïdes* forment la sous-famille composée exclusivement d'hexagones fusionnés par une arête. Cette famille a fait l'objet de nombreux travaux, et notamment de la thèse de A. Varet [?], qui a montré que la *programmation par contraintes* (PPC) est un outil particulièrement adapté à la génération exhaustive de benzénoïdes répondant à des propriétés données.

L'étude des HAP comportant des cycles à *cinq* ou *sept* atomes, dits *non-benzénoïdes*, est plus récente. L'azulène, formé d'un pentagone et d'un heptagone accolés (figure ??), en est l'exemple emblématique. L'introduction de tels cycles modifie en profondeur la chimie de la molécule : elle brise la régularité du pavage hexagonal, induit une courbure locale, et favorise l'apparition de sites radicalaires. Ces structures intéressent donc les chimistes, mais leur génération systématique reste largement inexplorée.




FIGURE 1 – Azulène (C₁₀H₈).

Remarque 1. Pour alléger la lecture, les figures suivantes ne représenteront plus explicitement les atomes d'hydrogène ni les liaisons C–H : ces derniers sont implicites sur tous les carbones de degré 2 du graphe carbone (les carbones de bord).

1.2 Objectif et problématique

L'objectif du stage est le suivant : étant donné un benzénoïde, énumérer de manière exhaustive toutes les substitutions admissibles dans lesquelles chaque hexagone est soit conservé, soit remplacé par un cycle à 5 ou 7 atomes. La difficulté est double, à la fois combinatoire et géométrique. Nous en donnons l'énoncé précis et l'analyse détaillée à la section ??, une fois introduit le vocabulaire nécessaire.

1.3 Positionnement et contributions

Ce stage se place dans la continuité directe de la thèse de Varet [?] : nous reprenons son cadre (modélisation PPC sur le *graphe dual* d'un benzénoïde, notions d'aromaticité) et nous l'étendons au cas, non traité jusqu'ici, des cycles à 5 et 7 atomes. Nos contributions sont les suivantes.

- Un **modèle PPC** qui énumère exhaustivement les substitutions 5/6/7 d'un benzénoïde, fondé sur une *table de voisinage* encodant les configurations locales chimiquement réalisables.

- Un **pipeline de validation physique** qui reconstruit en trois dimensions chaque solution du modèle, l’optimise par une méthode quantique semi-empirique (xTB), puis juge sa planéité.
- Une **étude expérimentale systématique** de contraintes additionnelles visant à augmenter la proportion de molécules planes produites. Ce point mérite une précision : la planéité d’une molécule est une propriété *globale* qui ne se laisse pas exprimer entièrement par des contraintes locales — c’est une difficulté intrinsèque au problème, et non un défaut de modélisation. Notre démarche consiste à identifier expérimentalement les contraintes qui, sans capturer la planéité au sens strict, en améliorent significativement le rendement.
- Une **extension de l’analyse électronique** (structures de Kekulé, couvertures de Clar, *Ring Bond Order*) aux cycles à 5 et 7 atomes, là où les outils existants se limitent aux hexagones.

Le mémoire est organisé comme suit. La section ?? introduit les deux corpus de notions nécessaires — la PPC et la chimie des HAP. La section ?? détaille le problème et ses difficultés. La section ?? présente notre modélisation. La section ?? décrit la réalisation (reconstruction, validation, analyse). La section ?? rapporte l’étude expérimentale, et la section ?? conclut.

2 Préliminaires et état de l’art

Notre travail se situe à l’interface de l’informatique et de la chimie théorique. Les notions nécessaires à la lecture du mémoire sont d’abord celles de la programmation par contraintes, puis le vocabulaire de chimie utilisé dans la suite.

2.1 Programmation par contraintes (PPC)

La *programmation par contraintes* est un paradigme déclaratif de résolution de problèmes combinatoires. Plutôt que de décrire *comment* résoudre un problème, on se contente d’en *décrire les solutions*, puis on confie la recherche à un solveur générique.

2.1.1 Réseau de contraintes

Définition 1 (Réseau de contraintes / CSP). *Un problème de satisfaction de contraintes est un triplet (X, D, C) où $X = \{x_1, \dots, x_n\}$ est un ensemble de variables, $D = \{D_1, \dots, D_n\}$ associe à chaque variable x_i un domaine fini D_i de valeurs possibles, et C est un ensemble de contraintes. Chaque contrainte porte sur un sous-ensemble de variables et restreint les combinaisons de valeurs qu’elles peuvent prendre simultanément. Une solution est une affectation de chaque variable à une valeur de son domaine satisfaisant toutes les contraintes.*

2.1.2 Un exemple : le Sudoku

Pour illustrer concrètement ce formalisme, prenons l’exemple, classique en PPC, du **Sudoku**. On dispose d’une grille 9×9 partiellement remplie de chiffres de 1 à 9 (figure ??, à gauche), et l’on cherche à compléter les cases vides de telle sorte que chaque chiffre apparaisse exactement une fois sur chaque ligne, chaque colonne et chacun des neuf sous-blocs 3×3 .

Ce problème se modélise comme un CSP :

- **Variables** : une variable x_{ij} par case $(i, j \in \{1, \dots, 9\})$, soit 81 variables.
- **Domaines** : $D_{ij} = \{1, \dots, 9\}$ pour les cases vides ; pour les cases pré-remplies, on fige $D_{ij} = \{v\}$ où v est le chiffre donné.
- **Contraintes** : pour chaque ligne i , $\text{allDifferent}(x_{i1}, x_{i2}, \dots, x_{i9})$; de même pour chaque colonne, et pour chacun des neuf blocs 3×3 (27 contraintes globales au total).

Une affectation des 81 variables est solution si et seulement si elle satisfait les 27 contraintes `allDifferent`.




FIGURE 2 – Un Sudoku partiellement rempli (à gauche) et la portée des contraintes `allDifferent` sur la case x_{ij} (à droite) : sa valeur doit différer de toutes les autres cases de sa ligne, de sa colonne et de son bloc 3×3 .

2.1.3 Résolution : propagation et recherche arborescente

La résolution d'un CSP combine deux mécanismes complémentaires.

Propagation de contraintes. À chaque étape, on retire des domaines les valeurs qui ne peuvent appartenir à aucune solution. Le critère le plus courant est la *cohérence d'arc* : pour toute contrainte c et toute variable x_i de sa portée, on retire de D_i toute valeur v qui n'a aucun *support* dans les domaines des autres variables de c (c'est-à-dire telle qu'aucune affectation des autres variables ne satisfasse c avec v). Sur l'exemple du Sudoku, si une case d'une ligne contient 7, la propagation retire 7 du domaine de toutes les autres cases de la même ligne, de la même colonne et du même bloc.

Recherche arborescente. On affecte les variables une à une dans un arbre de décision (figure ??). À chaque nœud, le solveur choisit une variable et lui assigne une valeur de son domaine courant ; il descend dans l'arbre tant que la propagation laisse au moins une valeur possible à chaque variable, et revient en arrière (*backtrack*) lorsqu'un domaine devient vide. L'efficacité du solveur dépend de l'ordre de branchement et de la finesse de la propagation.




FIGURE 3 – Recherche arborescente pour le Sudoku : à chaque nœud, le solveur essaie successivement les valeurs du domaine courant ; la propagation élague les branches contradictoires.

L'intérêt majeur du paradigme est qu'il n'est pas nécessaire d'écrire un algorithme spécifique à chaque problème : il suffit de formuler le modèle, puis d'invoquer un solveur traité comme une *boîte noire*. Dans ce travail, nous écrivons les modèles avec la bibliothèque Python PyCSP3 et nous les résolvons avec le solveur ACE (*Abscon Constraint Engine*) [?], qui sait énumérer l'ensemble des solutions d'une instance.

2.1.4 Contraintes en extension et contraintes globales

Deux familles de contraintes nous seront particulièrement utiles dans la suite. Une **contrainte en extension** (ou *de table*) liste explicitement les combinaisons de valeurs autorisées pour un

groupe de variables : c’est la forme naturelle pour encoder un catalogue de configurations admissibles, et c’est elle que nous utiliserons pour la *table de voisinage* chimique (section ??). Une **contrainte globale** capture un motif récurrent sur un nombre arbitraire de variables, avec une propagation spécialisée plus efficace que la décomposition en contraintes binaires : par exemple *Sum* (une somme bornée), que nous utiliserons pour exprimer la conservation du carbone, ou *LexIncreasing* (un ordre lexicographique entre deux vecteurs de variables), que nous emploierons pour la rupture de symétrie.

La souplesse de la PPC, qui consiste à activer, désactiver ou ajouter une contrainte puis réénumérer rapidement les solutions, est un atout décisif pour un travail mené en dialogue continu avec les chimistes.

2.1.5 Isomorphisme de graphes

Comme une partie centrale de notre modélisation repose sur les automorphismes d’un graphe (rupture de symétrie en section ??), nous rappelons ici la notion d’*isomorphisme*, qui apparaît dans tout le mémoire.

Définition 2 (Isomorphisme de graphes). *Deux graphes non orientés $G = (V_G, E_G)$ et $H = (V_H, E_H)$ sont dits **isomorphes** s’il existe une bijection $f : V_G \rightarrow V_H$ qui préserve les arêtes, c’est-à-dire telle que*

$$\forall u, v \in V_G, \quad \{u, v\} \in E_G \iff \{f(u), f(v)\} \in E_H.$$

*La bijection f est alors appelée un **isomorphisme** entre G et H . Si $G = H$, on parle d’**automorphisme** de G : c’est une permutation des sommets qui préserve les arêtes.*

Intuitivement, deux graphes isomorphes sont « les mêmes » à un renommage des sommets près ; ils représentent la même structure abstraite. Pour notre problème, deux substitutions d’un benzénoïde qui diffèrent uniquement par un automorphisme du graphe dual correspondent à la même molécule, et seront comptées une seule fois. La rupture de symétrie (section ??) traite explicitement ce point.

2.2 Notions de chimie

Les termes de chimie employés dans la suite peuvent être lus aussi bien comme des définitions sur des graphes que comme le vocabulaire chimique usuel.

2.2.1 Définitions préliminaires

Avant d’introduire les notions spécifiques aux HAP, nous rappelons brièvement le vocabulaire chimique de base utilisé dans le mémoire. Le lecteur familier peut sauter cette sous-section.

Atome et molécule : un atome est l’unité élémentaire de la matière chimique ; dans ce travail, seuls deux types interviennent : le carbone (C) et l’hydrogène (H). Une molécule est un assemblage stable d’atomes reliés par des liaisons covalentes.

Liaison covalente, simple et double : une liaison covalente résulte du partage d’une ou plusieurs paires d’électrons entre deux atomes. On parle de liaison *simple* lorsqu’une seule paire est partagée, de liaison *double* lorsque deux paires le sont. Dans un HAP, toutes les liaisons carbone-carbone et carbone-hydrogène sont covalentes.

Valence : la valence d’un atome est le nombre de liaisons qu’il peut former. Le carbone est tétravalent (quatre liaisons), l’hydrogène monovalent (une liaison). Dans un HAP, chaque carbone établit trois liaisons avec ses voisins du squelette et, lorsqu’il se trouve au bord, une quatrième avec un atome d’hydrogène ; les carbones internes n’ont pas d’hydrogène.

Électrons σ et π : les électrons d'une liaison covalente se répartissent en deux types selon la géométrie du recouvrement orbitalaire. Les électrons σ forment le squelette rigide de la molécule (un σ par liaison simple, et un σ dans chaque liaison double). Les électrons π , présents uniquement dans les liaisons doubles, occupent des orbitales perpendiculaires au plan local et sont *plus faiblement localisés*. Ce sont eux qui portent les propriétés aromatiques et opto-électroniques des HAP.

Hybridation sp^2 et sp^3 : l'*hybridation* décrit la géométrie locale des liaisons d'un atome de carbone. En hybridation sp^3 , le carbone forme quatre liaisons *simples* dirigées vers les sommets d'un tétraèdre, avec des angles de $109,5^\circ$: c'est le cas du méthane CH_4 ou du diamant, deux structures *tridimensionnelles*. En hybridation sp^2 , le carbone forme trois liaisons dont l'une est double, toutes situées dans un même plan avec des angles de 120° : c'est le cas de tous les carbones des HAP, ce qui rend ces molécules naturellement *planes* (au moins localement).

Conjugaison : dans une molécule où chaque carbone est en hybridation sp^2 , les orbitales π de tous les carbones d'un cycle se recouvrent continûment et créent un système d'électrons π *conjugué*. Cette conjugaison est la base de la délocalisation décrite à la section ?? ci-après.

2.2.2 HAP, benzénoïdes et graphe dual

Un **benzénoïde** est un assemblage d'hexagones réguliers du pavage hexagonal, fusionnés par des arêtes. On peut le voir de deux façons. Le *graphe carbone* a pour sommets les atomes de carbone et pour arêtes les liaisons carbone-carbone. Le *graphe dual* G_D , central dans tout ce travail, résume la combinatoire des hexagones.

Définition 3 (Graphe dual). *Soit B un benzénoïde à h hexagones. Son graphe dual $G_D = (V_D, E_D)$ a pour sommets $V_D = \{0, \dots, h-1\}$ (un sommet par hexagone), et $(u, v) \in E_D$ si et seulement si les hexagones u et v partagent une arête carbone-carbone. Cette construction correspond au graphe dual intérieur de la littérature, c'est-à-dire le graphe dual classique privé de la face externe.*

On appelle **bord** de G_D l'ensemble des hexagones de degré strictement inférieur à 6, c'est-à-dire ceux qui ne sont pas entièrement entourés de voisins. La figure ?? illustre cette construction sur un benzénoïde linéaire à trois hexagones.




FIGURE 4 – Un benzénoïde linéaire à trois hexagones (gauche) et son graphe dual G_D (droite).

2.2.3 Aromaticité et délocalisation

L'**aromaticité** traduit la stabilité particulière de certains cycles conjugués. La *règle de Hückel* en donne le critère classique : un cycle est dit aromatique s'il est plan, conjugué (chaque atome du cycle porte un électron π), et contient $4n + 2$ électrons π , où n est un entier positif ou nul. Le benzène ($n = 1$, soit 6 électrons π) en est l'exemple fondamental. Dans un tel cycle, les électrons π ne sont pas localisés sur une liaison précise : ils sont *délocalisés* et circulent autour du cycle. Plus une molécule admet de représentations équivalentes de ses liaisons doubles, plus la délocalisation est étendue, et plus la molécule est stable.

2.2.4 Structures de Kekulé

Une **structure de Kekulé** est un étiquetage des liaisons carbone-carbone en simples et doubles tel que chaque carbone porte exactement une double liaison. En termes de graphes, c'est un *couplage parfait* du graphe carbone. Une molécule HAP possède en général plusieurs structures de Kekulé, mais il est aussi possible qu'elle n'en possède aucune lorsque son graphe carbone n'admet pas de couplage parfait.




FIGURE 5 – Les trois structures de Kekulé du naphthalène.

2.2.5 Sextets et couvertures de Clar

Un **sextet de Clar** (ou rond de Clar) est un hexagone dont les six électrons π forment un cycle aromatique autonome. Concrètement, on peut le visualiser comme trois liaisons doubles alternées sur le cycle, et on le représente conventionnellement par un cercle inscrit dans l'hexagone (voir figure ??). Une **couverture de Clar** place des sextets sur un ensemble d'hexagones deux à deux disjoints, et le **nombre de Clar** est le nombre maximal de sextets que l'on peut placer. La règle de Hückel ($4n + 2$ électrons π , soit 6 pour $n = 1$) impose qu'un sextet occupe exactement six atomes : seuls les *hexagones* peuvent porter un sextet, jamais un pentagone ni un heptagone.




FIGURE 6 – Représentation d'un sextet de Clar.

La figure ?? illustre les couvertures de Clar sur le naphthalène.




FIGURE 7 – Les deux couvertures de Clar du naphthalène.

2.2.6 Ring Bond Order (RBO)

Le *ring bond order* (RBO) est une mesure combinatoire de la délocalisation aromatique locale d'un hexagone au sein d'un benzénoïde. Il prolonge le concept de *bond order* introduit par Pauling [?] à partir de la théorie de la résonance, formalisé ensuite comme indicateur cyclique notamment par Randić [?]. Nous reprenons ici les notations de Varet [?].

Soit $B = (V, E)$ le graphe carbone d'un benzénoïde : V désigne l'ensemble des atomes de carbone et E celui des liaisons covalentes entre atomes voisins. On note $\mathcal{K}(B)$ l'ensemble de ses structures de Kekulé, c'est-à-dire des couplages parfaits du graphe. Lorsque $\mathcal{K}(B) \neq \emptyset$, on dit que B est *Kekuléen*.

Définition 4 (Bond order, [?]). Soient $B = (V, E)$ un benzénoïde Kekuléen et $e \in E$ une de ses liaisons. Le bond order de e est le rapport entre le nombre de structures de Kekulé dans lesquelles e apparaît comme liaison double et le nombre total de structures de Kekulé de B :

$$\text{bo}(e) = \frac{|\{K \in \mathcal{K}(B) : e \in K\}|}{|\mathcal{K}(B)|}.$$

C'est une mesure de la délocalisation locale : $\text{bo}(e) = 1$ signifie que e est double dans toutes les Kekulé (liaison localisée), $\text{bo}(e) = 0$ qu'elle est toujours simple, et toute valeur intermédiaire traduit une délocalisation partielle.

Définition 5 (Ring bond order, [?]). Soient B un benzénoïde Kekuléen et h un de ses hexagones. Le ring bond order de h est la somme des bond order associés aux six liaisons définissant h :

$$\text{RBO}(h) = \sum_{e \in E(h)} \text{bo}(e),$$

où $E(h) \subset E$ désigne l'ensemble des six arêtes du cycle h .

Remarque 2. Pour tout hexagone h d'un benzénoïde Kekuléen, on a $0 \leq \text{RBO}(h) \leq 3$. La borne supérieure provient du fait que, dans toute structure de Kekulé $K \in \mathcal{K}(B)$, au plus trois arêtes de h peuvent être doubles dans K (un couplage parfait restreint aux six sommets de h comporte au plus trois arêtes). En sommant cette inégalité sur les structures et en divisant par $|\mathcal{K}(B)|$, on obtient $\text{RBO}(h) \leq 3$.

À titre d'exemple, le benzène admet exactement deux structures de Kekulé, échangées par rotation des liaisons doubles. Chaque arête y est double dans une seule des deux structures : $\text{bo}(e) = 1/2$ pour les six arêtes, et l'unique hexagone vérifie $\text{RBO}(h) = 6 \times 1/2 = 3$, la valeur maximale. Le naphthalène, qui admet trois structures de Kekulé (figure ??), voit chacun de ses deux hexagones atteindre $\text{RBO}(h) = 8/3 \approx 2,67$: cette valeur strictement inférieure à 3 traduit la délocalisation partielle propre aux benzénoïdes polycycliques.

Extension aux cycles de taille quelconque. Les molécules considérées dans ce travail comportent non seulement des hexagones, mais aussi des cycles à cinq et sept atomes. Pour traiter ces cas, nous étendons la définition précédente. Soit C un cycle de taille n d'un graphe moléculaire Kekuléen, et $E(C)$ l'ensemble de ses n arêtes. On définit le *cycle bond order*

$$\text{CBO}(C) = \sum_{e \in E(C)} \text{bo}(e).$$

Le même argument que ci-dessus donne l'encadrement

$$0 \leq \text{CBO}(C) \leq \lfloor n/2 \rfloor,$$

puisque un cycle de longueur n ne peut porter, dans une structure de Kekulé donnée, plus de $\lfloor n/2 \rfloor$ arêtes doubles. Pour comparer la délocalisation entre cycles de tailles différentes, nous reportons systématiquement le ratio normalisé $\text{CBO}(C)/\lfloor n/2 \rfloor \in [0, 1]$, qui vaut 1 pour un cycle « parfaitement aromatique » au sens combinatoire. Dans le cas radicalaire où $\mathcal{K}(B) = \emptyset$, les quantités $\text{bo}(e)$, $\text{RBO}(h)$ et $\text{CBO}(C)$ ne sont pas définies au sens classique.

2.2.7 Sites radicalaires

Lorsqu'une molécule n'admet aucun couplage parfait (par exemple à cause d'un nombre impair d'atomes ou d'une topologie particulière), certains carbones restent non couverts : ils portent un

électron π non apparié, appelé aussi *électron radicalaire* ou *électron célibataire*. La parité impaire des cycles à 5 et 7 atomes favorise précisément l'apparition de tels sites, ce qui rend les structures non-benzénoïdes intéressantes pour la chimie radicalaire.

L'exemple le plus simple est celui d'un pentagone accolé à un hexagone (figure ??) : le squelette compte $5 + 6 - 2 = 9$ atomes de carbone, un nombre impair. Aucun couplage parfait ne peut donc exister, et au moins un carbone reste non couvert dans toute structure de Kekulé : un site radicalaire est *forcé* par la topologie.




FIGURE 8 – Un pentagone accolé à un hexagone : 9 carbones (impair), donc tout couplage laisse au moins un atome non couvert. Le carbone marqué d'un point porte un électron π non apparié : c'est un site radicalaire imposé par la topologie du squelette.

2.2.8 Planéité et courbure

À toute molécule on associe une fonction *énergie potentielle* qui dépend de la position de ses atomes ; cette énergie est minimale lorsque les longueurs et les angles de liaison correspondent aux préférences de chaque atome et que les répulsions stériques sont relâchées. Une configuration des atomes est dite à l'**équilibre énergétique** lorsqu'elle réalise un minimum local de cette énergie ; c'est dans cette configuration que la molécule existe effectivement. On dit alors qu'une molécule est **plane** si tous ses atomes se placent, à l'équilibre énergétique, dans un même plan.

Pour un pavage d'hexagones réguliers, la somme des angles autour de chaque sommet vaut 360° et la structure est plane. Un pentagone (angle interne 108°) introduit localement un *défaut d'angle* positif et la matière tend à se refermer, comme dans un fullerène ; un heptagone ($\approx 128,6^\circ$) introduit un défaut négatif et la matière tend à onduler.

2.2.9 Validation quantique semi-empirique (xTB)

Pour juger si une molécule est réellement plane, on cherche sa géométrie d'équilibre : la disposition des atomes qui minimise l'énergie. Nous utilisons une méthode *semi-empirique*, GFN2-xTB [?], qui approxime l'énergie à un coût permettant de traiter de grandes séries de molécules et fournit une géométrie optimisée exploitable à grande échelle. C'est le sens de la « validation quantique semi-empirique » du titre.

3 Le problème

Maintenant que le vocabulaire est posé, nous pouvons énoncer précisément le problème et analyser ses deux sources de difficulté.

On part d'un benzénoïde B à h hexagones, représenté par son graphe dual G_D . Une **substitution** affecte à chaque hexagone v une taille de cycle $x_v \in \{5, 6, 7\}$: conserver l'hexagone ($x_v = 6$), le contracter en pentagone ($x_v = 5$) ou le dilater en heptagone ($x_v = 7$). La substitution doit respecter la *topologie* de B (les arêtes partagées entre cycles voisins sont préservées) et conserver le nombre total d'atomes de carbone. On cherche à **énumérer toutes les substitutions admissibles**, c'est-à-dire toutes celles qui correspondent à une molécule chimiquement et géométriquement réalisable, à *isomorphisme* près : deux substitutions identiques à une symétrie

du benzénoïde de départ décrivent la même molécule et ne sont comptées qu’une seule fois (la notion d’isomorphisme est définie en section ??).

3.1 La difficulté combinatoire

Avec trois valeurs possibles par hexagone, un benzénoïde à h hexagones admet a priori 3^h substitutions. Ce nombre croît exponentiellement, et la grande majorité de ces affectations ne correspondent à *aucune* molécule valide : elles violent la conservation du carbone, ou décrivent des voisinages localement impossibles à reconstruire. Énumérer naïvement puis filtrer est donc hors de portée dès que h dépasse quelques unités. C’est exactement le type de problème fortement combinatoire pour lequel la PPC est conçue : on encode les conditions d’admissibilité comme des contraintes, et le solveur n’explore que les affectations cohérentes.

3.2 La difficulté géométrique et topologique

La seconde difficulté est de nature différente, et c’est la plus profonde. Dans un benzénoïde, tous les cycles sont des hexagones réguliers d’angle interne 120° , et le pavage est plan par construction. Dès que l’on introduit des pentagones (angle interne 108°) et des heptagones (environ $128,6^\circ$), plusieurs grandeurs cessent d’être fixées :

- les **angles** aux sommets ne se complètent plus à 360° , ce qui crée une courbure locale ;
- les **distances** inter-atomiques et les longueurs de liaison s’ajustent pour relâcher les tensions ;
- la **topologie** de fusion impose que les cycles voisins partagent exactement une arête, ce qui n’est pas toujours réalisable selon la disposition des voisins ;
- la **planéité** qui en résulte n’est pas garantie : la molécule peut se courber ou onduler pour minimiser son énergie.

Le point crucial est que la planéité est une propriété *globale* : elle dépend de l’agencement de tous les défauts à la fois, et ne se déduit pas seulement des voisinages locaux. On peut filtrer localement les configurations manifestement irréalisables, mais on ne peut pas, par des contraintes locales seules, garantir qu’une molécule entière sera plane. Cette limite est *intrinsèque au problème*. Elle motive l’architecture en deux temps de notre travail : un modèle PPC qui énumère les candidats en appliquant les conditions *exprimables* (section ??), suivi d’une validation physique qui tranche la planéité *réelle* de chaque candidat (section ??). Et elle motive l’étude expérimentale (section ??), qui cherche les contraintes améliorant au mieux le rendement de planéité.

4 Modélisation

Nous présentons à présent le modèle PPC qui énumère les substitutions admissibles. Il comporte une variable par hexagone et un ensemble de contraintes *structurelles*, toujours actives, que nous décrivons ici. Les contraintes *additionnelles*, qui font l’objet de l’étude expérimentale, sont introduites à la section ??.

4.1 Variables et domaines

À chaque hexagone v du graphe dual on associe une variable x_v donnant la taille du cycle substitué :

$$x_v \in \{5, 6, 7\}, \quad v \in V_D.$$

Toutes les variables ont initialement le même domaine $\{5, 6, 7\}$. Le prétraitement décrit en section ?? (contrainte C2) réduira ce domaine à $\{6\}$ pour certains hexagones, dits *gelés*, en fonction de leur position dans le graphe dual.

4.2 Contraintes

Cette sous-section regroupe les contraintes du modèle. C1, C2.1, C3 et C4 sont actives par défaut. C2.2 et C5 sont optionnelles : leur effet est étudié expérimentalement à la section ??.

4.2.1 C1 — Conservation du carbone

Le nombre total d'atomes de carbone doit être préservé par la substitution. Notons h le nombre d'hexagones du benzénoïde de départ, et n_5, n_6, n_7 les nombres respectifs de pentagones, hexagones et heptagones dans la solution. Tout cycle de la solution remplace exactement un hexagone du benzénoïde de départ, donc

$$n_5 + n_6 + n_7 = h.$$

Pour exprimer la conservation des atomes, raisonnons *relativement à un hexagone*. Substituer un hexagone par un pentagone retire un atome de carbone, le substituer par un heptagone en ajoute un, et le conserver ne change rien. Le bilan total des carbones, par rapport à la molécule de départ, est donc $n_7 - n_5$, et la conservation impose

$$\boxed{n_5 = n_7.}$$

Remarque sur le nombre absolu de carbones. Un benzénoïde à h hexagones ne contient pas $6h$ atomes de carbone, car les hexagones adjacents partagent leurs sommets : le naphthalène ($h = 2$) a 10 carbones, l'anthracène ($h = 3$) en a 14, etc. La formule $\sum_v x_v = 6h$ ci-dessous n'est donc pas un comptage d'atomes ; c'est une réécriture algébrique de la condition $n_5 = n_7$.

Pour traduire $n_5 = n_7$ sur les variables x_v du modèle, on observe que

$$\sum_{v \in V_D} x_v = 5n_5 + 6n_6 + 7n_7 = 6(n_5 + n_6 + n_7) + (n_7 - n_5) = 6h + (n_7 - n_5).$$

Imposer $n_5 = n_7$ équivaut donc à imposer

$$\sum_{v \in V_D} x_v = 6h,$$

qui est l'expression effectivement déclarée au solveur (une simple contrainte de somme sur les variables entières).

4.2.2 C2 — Hexagones gelés (réduction de domaine)

Avant même la résolution proprement dite, un *prétraitement* réduit le domaine de certaines variables à $\{6\}$ en exploitant la structure locale du graphe dual. Pour chaque hexagone v , on définit son **motif d'occupation** $\sigma(v) = (\sigma_0, \dots, \sigma_5) \in \{0, 1\}^6$, où $\sigma_i = 1$ si le i -ème côté de v est partagé avec un voisin, et 0 s'il est libre. On note $b(v)$ le nombre de *blocs* de côtés libres consécutifs (sur le cycle des six côtés). La contrainte C2 se décompose en deux conditions de gel, l'une stricte et toujours active, l'autre optionnelle.

C2.1 — hexagones de degré 6. Si $\deg_{G_D}(v) = 6$, l'hexagone v est entouré de six voisins et n'a aucun côté libre. Il ne peut donc ni se contracter (aucun sommet à supprimer sans casser un côté partagé), ni se dilater (aucun bloc libre où insérer un sommet). On impose $x_v = 6$. Ce gel est une conséquence topologique stricte, sans alternative.

C2.2 — blocs libres fragmentés. Si $b(v) \geq 2$, les côtés libres de v sont répartis en plusieurs blocs disjoints sur le cycle. Notons que la simple connaissance du *nombre* d'arêtes périphériques d'un hexagone — au sens de l'étiquetage de Brinkmann repris par Varet [?] pour distinguer

les benzénoïdes partageant le même graphe dual intérieur — ne suffit pas à caractériser cette situation : c’est la *disposition* des côtés libres (un bloc continu ou plusieurs blocs séparés) qui détermine la faisabilité d’une substitution.

La transformation n’est pas *impossible*, mais elle n’est plus unique : on doit choisir où placer l’arête périphérique supplémentaire introduite par le septième sommet, et chaque choix produit un benzénoïde distinct au sens de Brinkmann. La figure ?? illustre cet enjeu sur un motif tiré de la figure 2.14 de la thèse de Varet [?] : un anthracène dont l’hexagone central est étiqueté 2+2 (deux blocs périphériques de deux arêtes, en haut et en bas) admet deux substitutions distinctes par un heptagone, l’une ajoutant une arête périphérique en bas (étiquetage 2+3), l’autre en haut (3+2).




FIGURE 9 – Anthracène et transformation du cycle central en heptagone.

On impose donc $x_v = 6$ *par défaut* pour ces hexagones, ce qui revient à interdire l’ambiguïté de transformation introduite par les blocs libres multiples. Cette restriction est désactivable lorsqu’on souhaite explorer des géométries où l’on accepte de modifier l’étiquetage des voisins, par exemple pour étudier l’effet de relâcher cette contrainte dans les expériences de la section ??.

Les hexagones qui ne sont gelés par aucune des deux règles sont dits *libres* et conservent le domaine $\{5, 6, 7\}$.

4.2.3 C3 — Voisinage admissible et table de voisinage

C’est le cœur du filtrage chimique. Pour chaque hexagone libre v , on impose que la configuration locale formée par v et ses voisins soit *réalisable*. Cette condition est encodée par une **contrainte en extension** : le tuple ordonné

$$\tau_v = (x_v, x_{u_1}, x_{u_2}, \dots, x_{u_k}),$$

où $u_1, \dots, u_k$ sont les voisins de v dans G_D pris dans l’ordre cyclique, doit appartenir à une **table de voisinage** $\mathcal{T}$ pré-calculée.

Un point essentiel distingue notre table de celle des benzénoïdes purs : elle est *sensible à la disposition* des voisins. Deux configurations ayant les mêmes tailles de voisins mais disposées différemment autour du cycle central ne sont pas équivalentes, car elles ne se reconstruisent pas

de la même manière en trois dimensions. La position des voisins est donc encodée explicitement dans les tuples de la table (un 0 marquant un côté libre).

La table est **construite hors-ligne** : on énumère les configurations locales candidates (un cycle central entouré de voisins de tailles données dans une disposition donnée), on reconstruit chacune en 3D, on l’optimise par xTB, et on ne retient que celles qui sont planes (au sens du critère décrit en section ??). Ce catalogue est *paramétrable* : il pourra être régénéré ou affiné lorsque de nouvelles études chimiques préciseront les critères d’admissibilité. La version utilisée dans ce travail comporte **721** entrées, réparties selon la taille du cycle central :

$$|\mathcal{T}(5)| = 63, \quad |\mathcal{T}(6)| = 291, \quad |\mathcal{T}(7)| = 367.$$

Remarque 3. *Un hexagone de degré 1 (un seul voisin) n’a pas besoin de contrainte de table : un cycle accolé à un unique voisin par une arête est toujours réalisable, quelle que soit sa taille.*

4.2.4 C4 — Rupture de symétrie

Deux substitutions qui ne diffèrent que par une symétrie du benzénoïde décrivent la *même* molécule. Pour ne les compter qu’une fois, on exploite le groupe des automorphismes du graphe dual, $\text{Aut}(G_D)$ (les permutations des sommets qui préservent les arêtes), dont on calcule un ensemble générateur $\{\pi_1, \dots, \pi_m\}$. Pour chaque générateur π , on impose une contrainte *lex-leader*

$$(x_0, x_1, \dots, x_{h-1}) \leq_{\text{lex}} (x_{\pi(0)}, x_{\pi(1)}, \dots, x_{\pi(h-1)}),$$

qui ne retient, dans chaque orbite de solutions équivalentes, que le représentant minimal pour l’ordre lexicographique. Cette technique élimine les doublons et réduit fortement l’espace de recherche. Sa validité repose sur l’unicité du plongement planaire des graphes considérés (théorème de Whitney [?] et 2-connexité des benzénoïdes).

4.2.5 C5 — Adjacence 5–7 (motif azulène)

Cette contrainte est une piste d’amélioration explorée à la section ?? ; elle n’est pas active par défaut. L’idée chimique sous-jacente est la suivante : remplacer un motif 6–6 (deux hexagones accolés, comme dans le naphthalène) par un motif 5–7 (un pentagone et un heptagone accolés, comme dans l’azulène, voir figure ??) *préserve* le compte d’atomes de carbone ($5 + 7 = 6 + 6 = 12$, moins 2 pour l’arête partagée, donc 10 dans les deux cas) et conserve le nombre total d’électrons π (10 électrons, soit $4n + 2$ avec $n = 2$, dans les deux motifs : la règle de Hückel reste satisfaite). Le motif 5–7 apparaît donc comme un *substitut isoélectronique* naturel du motif 6–6, et il est connu en chimie pour préserver la planéité localement, là où un pentagone ou un heptagone isolé introduit une courbure.




FIGURE 10 – Motif 5–7 fusionné (azulène).

La contrainte C5 traduit cette idée dans le modèle PPC sous la forme *tout pentagone a au moins un heptagone parmi ses voisins, et tout heptagone a au moins un pentagone parmi les siens* :

$$\forall v \in V_D, \quad (x_v = 5 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 7) \wedge (x_v = 7 \Rightarrow \exists u \in \mathcal{N}(v), x_u = 5).$$

Cette contrainte est purement *locale*, mais sa motivation est globale : en imposant que tout défaut 5 ou 7 soit immédiatement compensé par un défaut opposé, on espère préserver la planéité d'ensemble. Son efficacité réelle est mesurée expérimentalement.

4.3 Résolution

Le modèle est écrit en PYCSP3, puis compilé au format standard XCSP3. Selon les options choisies par l'utilisateur, il inclut les contraintes suivantes :

- **actives par défaut** : C1 (conservation du carbone), C2.1 (gel des hexagones de degré 6), C3 (voisinage admissible) et C4 (rupture de symétrie) ;
- **optionnelles** : C2.2 (gel des hexagones à blocs libres fragmentés, activée par défaut mais désactivable) et C5 (adjacence 5–7, désactivée par défaut, étudiée à la section ??).

Le solveur ACE est ensuite invoqué pour **énumérer toutes les solutions** de l'instance ainsi configurée. Chaque solution est un vecteur de tailles $(x_0, \dots, x_{h-1})$ qui sera, à l'étape suivante, reconstruit en une molécule tridimensionnelle puis validé.

5 Réalisation : des solutions du modèle aux molécules validées et analysées

Le modèle de la section ?? produit des *vecteurs de tailles* $(x_0, \dots, x_{h-1})$: des objets abstraits. Cette section décrit comment on en fait des molécules réelles, comment on tranche leur planéité, et comment on analyse leurs propriétés électroniques. Elle regroupe l'essentiel du travail d'implémentation.

5.1 Reconstruction 3D, validation et test de planéité

Cette sous-section décrit, en trois temps, comment on passe d'un vecteur de tailles abstrait à une molécule physiquement validée : la reconstruction 3D produit une géométrie initiale, la validation xTB la fait converger vers son équilibre énergétique, et un test géométrique sur la géométrie optimisée tranche la planéité.

5.1.1 Reconstruction 3D des solutions

Chaque solution du modèle est un vecteur de tailles $(x_0, \dots, x_{h-1})$ indiquant la taille assignée à chaque hexagone. Pour en faire une molécule tridimensionnelle exploitable, on procède en trois phases : modification topologique du graphe carbone, placement géométrique des sommets, puis assemblage en molécule (liaisons doubles et hydrogènes).

Modifications topologiques du graphe carbone. Le graphe carbone initial est celui du benzénoïde de départ : chaque hexagone est un cycle à six sommets, et deux hexagones adjacents partagent une arête (donc deux sommets). Lorsque la solution affecte une taille $x_v \neq 6$ à un hexagone v , il faut transformer ce cycle en un pentagone ou un heptagone *sans* perturber les arêtes partagées avec ses voisins.

Repérage des côtés libres. Rappelons que le motif d'occupation $\sigma(v) \in \{0, 1\}^6$ indique pour chacun des six côtés du cycle s'il est partagé avec un voisin ($\sigma_i = 1$) ou *libre* ($\sigma_i = 0$). Les modifications topologiques opèrent exclusivement sur les sommets adjacents à des côtés libres ; les sommets attenants à au moins un côté partagé sont *gelés*, sans quoi la modification briserait la fusion avec un voisin.

Contraction en pentagone ($x_v = 5$). On supprime un sommet du cycle parmi les sommets libres, en privilégiant celui qui se trouve au milieu d'un bloc de côtés libres consécutifs ; ses deux voisins dans le cycle sont alors reliés directement, réduisant le cycle de six à cinq sommets. Le choix du sommet à supprimer est unique lorsque l'hexagone possède un seul bloc libre (cas garanti par la condition $b(v) \leq 1$ pour les hexagones non gelés, section ??).

Dilatation en heptagone ($x_v = 7$). On insère un nouveau sommet entre deux sommets libres consécutifs (au milieu du bloc libre), ce qui ajoute une arête au cycle et le porte à sept sommets.

Effet sur les voisins. Une fois le cycle modifié, sa nouvelle séquence ordonnée de sommets est conservée dans la structure de données du graphe carbone afin que les cycles voisins continuent à le référencer correctement via leurs sommets partagés.

Placement géométrique. Une fois la topologie fixée (chaque cycle connaît sa liste ordonnée de sommets), il reste à attribuer à chaque sommet une position dans le plan. L'idée est de poser chaque cycle comme un *polygone régulier* de longueur de côté $\ell = 1,4 \text{ \AA}$ (longueur typique d'une liaison carbone-carbone), en respectant les contraintes de partage d'arête entre cycles adjacents.

Rayon des cycles. Le rayon r_n du cercle circonscrit à un polygone régulier de n côtés de longueur ℓ vaut

$$r_n = \frac{\ell}{2 \sin(\pi/n)}.$$

Numériquement, $r_5 \approx 1,19$, $r_6 \approx 1,40$, $r_7 \approx 1,61$ (en angströms).

Parcours en largeur du graphe dual. Le placement s'effectue par un parcours en largeur (*BFS*) du graphe dual G_D à partir d'un cycle **ancre** — choisi de plus haut degré, ce qui maximise les contraintes immédiates de partage et stabilise la géométrie. Le cycle ancre est dessiné centré à l'origine, dans une orientation canonique. Chaque cycle suivant est placé *relativement à un parent déjà placé*, via l'arête $e = \{a, b\}$ qu'ils partagent.

Positionnement d'un cycle enfant. Soit c un cycle à placer, parent p , arête partagée $\{a, b\}$ déjà positionnée aux coordonnées $\mathbf{x}_a, \mathbf{x}_b$. Le placement s'effectue alors en quatre étapes décrites par l'algorithme ??.

Algorithme 1 Positionnement d'un cycle enfant relativement à son parent.

Entrée : cycle c de taille n_c , parent p déjà placé, arête $\{a, b\}$ partagée

Sortie : positions des sommets de c dans le plan

```

m ← (x_a + x_b) / 2 ; milieu de l'arête partagée
a_{n_c} ← r_{n_c} · cos(π / n_c) ; apothème du polygone régulier
n ← vecteur unitaire ⊥ {a, b}, opposé au parent p
centre_c ← m + a_{n_c} · n
// répartir les n_c-2 sommets restants sur le cercle
pour i de 1 à n_c - 2 :
    θ_i ← angle du i-ème sommet (depuis a vers b, hors parent)
    x_i ← centre_c + r_{n_c} · (cos θ_i, sin θ_i)

```

Le choix de l'orientation de la normale par rapport au parent (étape 3 de l'algorithme) garantit que la structure ne se replie pas sur elle-même : chaque cycle enfant est posé du *bon côté* de son arête de fusion. Lorsqu'un cycle a plusieurs parents déjà placés (cas de cycles internes au benzénoïde), seul le premier rencontré dans le BFS est utilisé pour le placer, et les positions

imposées par les autres parents sont vérifiées *a posteriori* pour cohérence ; la topologie en amont garantit qu’elles coïncident dans la limite des polygones réguliers.

Algorithme global. L’algorithme complet de placement, qui orchestre le parcours en largeur du graphe dual et appelle l’algorithme ?? sur chaque cycle non encore placé, est donné par l’algorithme ??.

Algorithme 2 Placement géométrique global par parcours en largeur du graphe dual.

placer le cycle ancre à l’origine, orienté canoniquement

file $\leftarrow$ [ancre]

tant que file non vide :

 c $\leftarrow$ file.popleft()

 pour chaque voisin v de c dans GD, non encore placé :

 {a, b} $\leftarrow$ arête partagée entre c et v

 positionner v par l’algorithme ?? (parent = c)

 file.append(v)

Assemblage moléculaire. Une fois tous les sommets placés en 2D (avec $z = 0$), il reste à transformer la géométrie en une véritable molécule. On effectue trois opérations successives.

Liaisons doubles. On calcule un *couplage de cardinalité maximale* sur le graphe carbone par l’algorithme de Blossom [?], et chaque arête du couplage est marquée comme liaison double. Les carbones non couverts par le couplage sont les sites radicalaires.

Ajout des hydrogènes. Tout carbone du bord, c’est-à-dire de degré 2 dans le graphe carbone, possède une valence libre : on lui attache un atome d’hydrogène, placé radialement vers l’extérieur du cycle auquel il appartient, à une distance de 1,088 Å (longueur typique de la liaison C–H).

Export. La géométrie complète (carbones et hydrogènes, avec coordonnées) est exportée au format XYZ, lisible par xTB.

La géométrie ainsi produite est *plane par construction* : tous les atomes sont dans le plan $z = 0$. C’est l’étape de validation xTB (section suivante) qui révélera si la molécule est réellement plane à l’équilibre, ou si l’optimisation la fait quitter le plan.

5.1.2 Validation par xTB : protocole d’optimisation déterministe

L’optimisation xTB procède par descente de gradient. Or si la géométrie initiale est *parfaitement* plane, les forces perpendiculaires au plan sont nulles par symétrie : l’optimiseur reste alors piégé dans un **minimum plat parasite** et conclut à tort que la molécule est plane. Nous l’avons constaté en comparant deux géométries initiales planes du même benzénoïde, qui convergeaient l’une vers une forme plane, l’autre vers une forme courbée à 58,6°.

Une première version du pipeline contournait ce piège par une *dynamique moléculaire* courte (xtb -md à 298 K pendant 1 ps) qui « secoue » la molécule pour briser la symétrie planaire parasite, suivie d’une optimisation. Cette approche, recommandée initialement par les chimistes, s’est révélée **non reproductible** : xTB initialise les vitesses MD à partir de l’horloge système et n’expose aucune graine accessible (confirmé par lecture du code source de xTB et par l’issue GitHub #730 du dépôt grimme-lab/xtb ouverte depuis 2022 et restée sans réponse). Sur des structures tendues (h_8 – h_9 avec amas 5/7 denses), deux exécutions identiques basculaient parfois entre les verdicts PLAN et NON-PLAN, ce qui rendait toute campagne expérimentale invalable.

Le protocole finalement retenu remplace la MD stochastique par une **perturbation analytique déterministe** appliquée à la composante z des coordonnées avant l’optimisation. Soit

$\mathbf{x}_1, \dots, \mathbf{x}_N$ les positions des N atomes, ordonnés canoniquement. On définit

$$z'_i = z_i + A \sin\left(\frac{2\pi i}{N} + \varphi\right), \quad A = 0,05 \text{ \AA}, \quad \varphi = 0,5 \text{ rad},$$

les valeurs de A et φ étant fixées une fois pour toutes. Cette perturbation, totalement indépendante d'un tirage aléatoire, brise la symétrie $z = 0$ de manière reproductible bit-à-bit et suffit à sortir l'optimiseur du minimum plat parasite. La géométrie perturbée est ensuite passée à xTB en optimisation locale standard :

```
xtb perturbed.xyz -opt tight
```

avec xTB 6.7.1 en niveau de théorie **GFN2-xTB** [?]. Les variables d'environnement `OMP_NUM_THREADS=1`, `MKL_NUM_THREADS=1`, `OPENBLAS_NUM_THREADS=1` et `NUMEXPR_NUM_THREADS=1` sont imposées avant l'appel, ce qui force un seul fil d'exécution et élimine la dernière source de non-déterminisme (l'ordre d'agrégation des contributions en BLAS multi-thread). L'ensemble du pipeline (reconstruction $\rightarrow$ perturbation $\rightarrow$ optimisation) est ainsi *byte-déterministe* : même fichier d'entrée et même configuration produisent la même géométrie finale, au bit près. Le résultat est conservé dans `md_final_opt.xyz` sous chaque solution. Cette approche, équivalent numérique de la procédure suggérée par le chimiste (*déplacer un atome et vérifier s'il revient à sa place*), restitue la même information physique que la MD courte tout en restant reproductible.

Un filtre anti-fragmentation rejette les optimisations où un atome s'éjecte de la molécule pendant la convergence (cas pathologique observé sur quelques structures très tendues, où l'optimisation brise une liaison et fait fuir un fragment au-delà de 30 Å du barycentre). Lorsque le filtre déclenche, la solution reçoit le verdict ÉCHEC xTB.

5.1.3 Test de planéité par analyse en composantes principales

Une fois la géométrie optimisée par xTB, on doit décider si la molécule est plane. La géométrie est donnée par un nuage de N points dans $\mathbb{R}^3$ (les positions des N carbones), et la question revient à mesurer dans quelle mesure ce nuage est contenu dans un même plan.

Calcul du plan moyen par ACP. On utilise une **analyse en composantes principales** (ACP). Soit $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathbb{R}^3$ les coordonnées des carbones. On centre le nuage en soustrayant le barycentre $\bar{\mathbf{x}} = \frac{1}{N} \sum_i \mathbf{x}_i$, puis on forme la matrice de covariance 3×3

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

La diagonalisation de Σ fournit trois vecteurs propres orthonormés $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ associés aux valeurs propres $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$. Les deux premiers vecteurs engendrent le *plan moyen* du nuage (celui qui minimise la somme des carrés des distances des atomes au plan) et $\mathbf{v}_3$ est sa **normale**. La plus petite valeur propre λ_3 mesure l'épaisseur quadratique moyenne du nuage par rapport à ce plan ; elle est nulle si et seulement si tous les atomes sont parfaitement coplanaires.

Métriques globales. À partir de cette décomposition, on calcule plusieurs grandeurs globales :

- le *rmsd plan* : la racine de la moyenne des carrés des distances des atomes au plan moyen, $\sqrt{\frac{1}{N} \sum_i (\mathbf{n}^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2}$, qui mesure l'épaisseur typique du nuage ;
- la *hauteur* : l'amplitude (max – min) des projections des atomes sur la normale, qui mesure l'épaisseur *extrême* du nuage ;
- l'angle entre $\mathbf{v}_3$ et l'axe Z global, qui n'a qu'une valeur diagnostique (vérifier que la molécule ne s'est pas *simplement* inclinée sans se déformer).

La métrique décisive : `max_angle_deg`. Aucune de ces métriques globales ne suffit. Une molécule peut être très peu épaisse globalement mais comporter un *bombement local* significatif sur quelques cycles seulement ; à l'inverse, une légère inclinaison d'ensemble gonfle artificiellement le rmsd. La métrique réellement décisive, validée par le chimiste, mesure l'angle de chaque cycle par rapport au plan moyen.

Pour chaque cycle C de la molécule (pentagone, hexagone ou heptagone), on applique la même ACP à ses seuls sommets : on obtient une normale locale $\mathbf{n}_C$. L'angle entre cette normale locale et la normale globale $\mathbf{v}_3$ mesure le « gauchissement » du cycle. La métrique `max_angle_deg` est la valeur maximale de cet angle sur l'ensemble des cycles :

$$\text{max_angle_deg} = \max_{C \in \text{cycles}} \arccos(|\mathbf{n}_C \cdot \mathbf{v}_3|),$$

exprimée en degrés (la valeur absolue $|\cdot|$ règle l'ambiguïté de signe de la normale). Le maximum garantit qu'aucun cycle n'est trop incliné par rapport à l'ensemble.

Critère de décision. Le critère retenu, fixé par le chimiste après examen de cas-tests, est

$$\text{molécule plane} \iff \text{max_angle_deg} \leq 10^\circ.$$

Le seuil de 10° tolère les déformations légères dues aux contraintes stériques inévitables (les hydrogènes peuvent dévier le plan localement) sans accepter de molécules visiblement courbées. En combinant le statut du protocole MD (terminé ou échoué, voir section précédente) et ce test, chaque solution reçoit un verdict final : PLAN, NON-PLAN, ou ÉCHEC MD.

5.2 Analyse électronique des structures

Une fois les structures planes obtenues, nous avons développé un outil pour en étudier les propriétés électroniques. Ces analyses sont *statiques* : elles opèrent directement sur le graphe carbone (sans nouveau calcul quantique) et sont donc quasi instantanées.

Kekulé et radicaux. On calcule un couplage de cardinalité maximale (Blossom) ; les Kekulé sont énumérés par retour arrière (avec un plafond). Les carbones non couverts sont les sites radicalaires.

[Capture du visualiseur en mode Kekulé — à insérer]

FIGURE 11 – Visualiseur des structures de Kekulé.

Couvertures de Clar. On énumère les sous-ensembles d'hexagones deux à deux disjoints (au plus $2^{n_{\text{hex}}}$, trivial pour $n_{\text{hex}} \leq 9$) et l'on couple le résidu ; seuls les hexagones portent un sextet (règle de Hückel).

Extension du RBO aux cycles 5 et 7. La définition de Pauling–Randić [?], reprise par Varet, ne concerne que les hexagones. Notre contribution est de conserver la formule $\text{CBO}(C) =$




FIGURE 12 – Visualiseur en mode Clar.

$\sum_{e \in C} \text{bo}(e)$ sommée sur tout cycle quelle que soit sa taille, en affichant le ratio $\text{CBO}/\text{cbo}_{\max}$ pour rester fidèle au contexte. Le cas radicalaire (aucune Kekulé stricte) n'est pas défini au sens de Pauling–Randić.




FIGURE 13 – Visualiseur en mode RBO.

Remarque 4 (Pourquoi l'énumération directe plutôt qu'une méthode polynomiale). *Le comptage rapide des Kekulé des benzénoïdes (méthode de Rispoli [?]) repose sur le caractère biparti du graphe carbone. Les cycles impairs (5 ou 7) brisent cette bipartition ; la généralisation passe par le théorème de Kasteleyn [?] (orientation et Pfaffien), d'un coût d'implémentation jugé hors du périmètre du stage. Nous nous en tenons à l'énumération directe, suffisante car les cycles 5/7 contraignent fortement les couplages.*

À ce stade, cet outillage est *opérationnel* mais l'exploration reste préliminaire : nous avons par exemple cherché un lien entre planéité et nombre de radicaux sans dégager de corrélation exploitable. Nous le présentons comme un moyen d'analyse des structures produites et une piste à approfondir.

5.3 Le designer : interface et pipeline intégré

L'ensemble des étapes décrites jusqu'ici — modèle PPC, reconstruction 3D, validation xTB, test de planéité, analyse électronique — est intégré dans une application web unique, le *designer*, qui sert à la fois d'interface d'utilisation et d'infrastructure de campagne expérimentale. Cette sous-section en donne un aperçu fonctionnel et détaille l'environnement technique (versions, machines, garanties de reproductibilité).

5.3.1 Saisie de l'instance

Un canevas hexagonal en SVG permet à l'utilisateur de *dessiner* un benzénoïde de départ : on clique sur les hexagones du pavage pour les sélectionner, et le graphe dual sous-jacent est construit à la volée. La saisie peut aussi se faire par *importation* : un benzénoïde déjà enregistré dans la base BenzaiDB (ou venant d'un fichier au format texte adapté) peut être chargé directement, ce qui est utile pour rejouer une campagne sur un corpus déjà fixé.




FIGURE 14 – Designer en mode saisie : canevas hexagonal pour dessiner un benzénoïde ou choisir un squelette importé depuis BenzaiDB.

5.3.2 Configuration des contraintes et exécution

Une fois l'instance posée, l'utilisateur configure le solveur depuis un panneau organisé en deux onglets. L'onglet **Préréglage** propose quatre configurations canoniques, sélectionnables d'un clic, qui correspondent exactement aux configurations étudiées expérimentalement (section ??) :

- **C1 — Baseline** : contraintes structurelles uniquement (C1+C2.1+C3+C4).
- **C2 — Pb1 + adj_57** : C1 plus pentagones plafonnés au bord et appariement Stone–Wales obligatoire.
- **C3 — Pb1 + adj_57 + pas de 7–7 adjacents** : durcissement local de la courbure (Gauss–Bonnet locale à zéro dans un rayon de 2 dans G_D).
- **Ctopo — Topologie complète** : C3 plus une blacklist de motifs de rayon 2 du graphe dual et un pré-filtre exigeant un squelette compact (au moins 4 atomes péri-condensés). Recommandé pour les grands squelettes (h_9).

L'onglet **Avancé** expose individuellement chaque flag (Pb1, adj_57, tau_gb, ctopo_filter, etc.) pour les expérimentations fines.

Un second panneau gère la **validation xTB**. Le mode par défaut est *skip xTB* : le pipeline s'arrête après la reconstruction 3D et produit directement les géométries planes (non optimisées), ce qui est très rapide et suffit pour visualiser les sorties du CSP. Pour valider la planéité physique, l'utilisateur bascule sur *det-opt* (le protocole déterministe décrit section ??), ou plus rarement sur les modes *md* et *multi-runs* conservés pour comparaison historique. Une option permet aussi de comparer la planéité des solutions à celle du benzénoïde d'entrée pur (tout-hexagones).

Le lancement d'une génération orchestre, derrière l'interface, l'ensemble du pipeline : compilation du modèle en XCSP3, appel à ACE, reconstruction 3D des solutions, validation xTB (si demandée), test de planéité par ACP et calcul des métriques électroniques. Les résultats — solutions, géométries XYZ compressées, statistiques par campagne — sont persistés dans une base SQLite, ce qui rend chaque campagne facilement rejouable et comparable. Les exécutions sur le grand corpus ($h \geq 7$, jusqu'à plusieurs milliers de squelettes) sont distribuées sur le cluster décrit ci-dessous.

5.3.3 Exploration des solutions et visualiseur intégré

Une fois une campagne terminée, le designer présente l'ensemble des solutions produites sous forme d'une **liste paginée** (figure ??). Chaque ligne récapitule les caractéristiques d'une solution : identifiant, composition (n_5, n_6, n_7) , verdict de planéité, angle maximal hors-plan, et distances quadratique / extrême au plan moyen.

Plusieurs leviers facilitent l'exploration :

- **Tri** sur n'importe quelle colonne (angle croissant ou décroissant, identifiant, etc.) ;
- **Filtrage** par verdict de planéité (PLAN, NON-PLAN, géométrie infaisable, échec xTB), par sous-chaîne de la composition, ou par squelette de départ ;
- navigation directe vers le **visualiseur 3D** d'une solution donnée pour inspecter sa géométrie en relief, lire ses structures de Kekulé, ses couvertures de Clar et ses RBO/CBO (section ??).

Le visualiseur, intégré à la même application web, est aussi accessible indépendamment du designer pour explorer la base de résultats du run final ($\sim 1,5$ M de solutions sur h_3-h_9). Il sert à la fois d'outil d'exploration pour les chimistes et de banc de débogage pour le développement (vérifier en 3D qu'une géométrie produite par le pipeline ressemble à ce que l'on attend).




FIGURE 15 – Liste des solutions avec tri et filtrage.

5.4 Reproductibilité

La reproductibilité des expériences est une garantie centrale du pipeline : un même fichier d'entrée et une même configuration de contraintes doivent produire le *même* résultat, jusqu'au bit près, indépendamment de la machine ou de la date d'exécution. Cette sous-section précise l'environnement et les mécanismes qui le garantissent.

Stack logicielle. Le pipeline est écrit en **Python 3.14.4**, aligné entre le poste de développement (Windows 11) et l'environnement **conda** du cluster. Les bibliothèques utilisées et leurs versions (extraits de **requirements.txt**) sont récapitulées dans le tableau ??.

Validation quantique. La validation utilise le binaire **xTB 6.7.1** avec la méthode **GFN2-xTB**, appelé en sous-processus depuis Python via le protocole *det-opt* décrit section ?? . Le déterminisme byte-pour-byte est garanti par (i) la perturbation z analytique $z'_i = z_i + A \sin(2\pi i/N + \varphi)$ (sans RNG), (ii) le forçage de **OMP_NUM_THREADS=1**, **MKL_NUM_THREADS=1**, **OPENBLAS_NUM_THREADS=1**, **NUMEXPR_NUM_THREADS=1** avant chaque appel à xTB, (iii) **PYTHONHASHSEED=0** dans tous les scripts du pipeline, et (iv) l'ordre canonique **sorted(...)** appliqué partout où des collections non ordonnées (ensembles d'atomes, de liaisons) seraient itérées.

Bibliothèque	Version	Rôle
Python	3.14.4	langage hôte du pipeline
PyCSP3	2.5.1	modélisation des contraintes (génération XCSP3)
ACE	—	solveur CSP Java invoqué par PyCSP3
NetworkX	3.6.1	graphes (dual, carbone, couplage de Blossom)
NumPy	2.4.6	algèbre linéaire (ACP, reconstruction 3D)
Flask	3.1.3	backend web du designer
Werkzeug	3.1.8	dépendance Flask (WSGI)
Jinja2	3.1.6	dépendance Flask (templates)
3Dmol.js	—	bibliothèque JS du visualiseur 3D (via CDN)

TABLE 1 – Stack logicielle du pipeline et du designer.

Cluster de calcul. Les campagnes de grande taille tournent sur le cluster **COALA** de l’équipe COALA du LIS (Aix-Marseille Université), composé de **16 nœuds** (lames **lis-cluster-coala-49** à **-64**), chacun équipé de **2 processeurs Intel Xeon Gold 5218R** (20 cœurs physiques, 40 threads SMT) et de **187 GiB de RAM**. L’accès au cluster se fait via le *jump host* **saphir2**. Au total, jusqu’à **320 instances xTB en parallèle** peuvent tourner simultanément. L’orchestration est interne au projet (pas de SLURM ni PBS) : un dispatcher central distribue les jobs à des workers via un *manifest JSONL* partagé sur NFS et des verrous atomiques (`O_CREAT|O_EXCL`) qui garantissent qu’un job n’est pris que par un seul worker. Les fichiers temporaires (XYZ d’entrée, sorties xTB) sont stockés en local sur le scratch NVMe de chaque nœud, puis les résultats finaux sont rapatriés vers la base SQLite centrale.

Persistance et traçabilité. Tous les artefacts (instance d’entrée, configuration des contraintes, solutions, géométries XYZ, verdicts xTB, métriques électroniques) sont persistés dans une base **SQLite** (mode `WAL`) dont le schéma principal comporte quatre tables (`configs`, `molecules`, `solutions`, `xyz_files`). Chaque campagne enregistre, en plus des résultats, sa configuration complète et les versions logicielles utilisées, ce qui permet de retracer *a posteriori* l’exécution exacte qui a produit un résultat donné.

6 Étude expérimentale : quelles contraintes améliorent la planéité ?

Comme établi en section ??, la planéité est une propriété globale qu’aucun jeu de contraintes locales ne capture exactement. La question pratique devient alors : *quelles contraintes additionnelles augmentent le plus la proportion de molécules planes parmi celles que le modèle génère ?* Nous y répondons par une étude comparative de quatre configurations **C₁**, **C₂**, **C₃** et **C_{topo}**, des plus simples aux plus contraintes, qui isolent successivement chaque levier identifié.

6.1 Protocole et banc d’essai

Le banc d’essai utilise les squelettes benzénoïdes canoniques de la base *BenzaiDB*, de h_3 à h_9 hexagones (tableau ??). La métrique principale est le **taux de planéité** : la proportion de solutions jugées planes par le pipeline xTB+ACP, complétée par le *nombre absolu* de molécules planes produites (souvent plus parlant pour l’aval, qui s’intéresse au nombre de candidats exploitables). Les campagnes sont reproductibles (validation *det-opt*, section ??), agrégées en base SQLite, et chaque configuration de contraintes est comparée terme à terme aux autres sur le même corpus.

h	h_3	h_4	h_5	h_6	h_7	h_8	h_9
nombre de squelettes	3	6	16	44	126	376	2 418

TABLE 2 – Nombre de squelettes benzénoïdes du corpus par taille h . Les tailles h_3 – h_5 proviennent d’une énumération directe (peu de squelettes possibles à cette échelle) ; les tailles h_6 – h_9 sont issues de la base BenzaiDB.

6.2 C_1 — Baseline (contraintes structurelles seules)

La première configuration mesure la référence : avec les seules contraintes structurelles (section ??) — conservation du carbone $C1$, gel des hexagones de degré 6 ($C2.1$), table de voisinage ($C3$) et rupture de symétrie ($C4$) —, quelle proportion des solutions est réellement plane après validation xTB ?

Le constat est sans appel (tableau ??, colonnes $C1$) : le taux de planéité est correct sur les petits squelettes (78,5 % sur h_6) mais s’effondre avec la taille, jusqu’à **38,2 %** sur h_9 . Le volume absolu de solutions, lui, explose : 646 319 solutions sur h_9 , dont seulement 246 855 planes. C’est le point de départ qui justifie toute la suite : sur h_9 , six solutions sur dix seront éliminées par la validation xTB ; il faut donc des contraintes additionnelles pour mieux cibler.

6.3 C_2 — Pb1 + adjacence 5–7 (motif Stone–Wales)

C_2 ajoute à C_1 deux contraintes complémentaires, identifiées comme les plus efficaces parmi les variantes locales explorées :

- **Pb1** ($K_{pb=1}$) : $\sum_{v \in \partial G_D} \mathbf{1}[x_v = 5] \leq 1$, c’est-à-dire *au plus un pentagone au bord* du squelette. Cette contrainte traduit l’observation empirique que les pentagones de bord, qui introduisent une courbure locale non compensée par un voisin opposé, sont particulièrement déstabilisants ; la limiter améliore fortement le taux de planéité.
- **adj_57** (contrainte $C5$, section ??) : appariement Stone–Wales obligatoire (tout pentagone a un heptagone voisin, et réciproquement). Localement, la paire 5–7 compense exactement la courbure de Gauss–Bonnet ($+\pi/3 - \pi/3 = 0$).

Une troisième contrainte testée parallèlement, $|n_5 - n_7| \leq K_{\text{sym}}$ (notée C-SYM), s’est révélée *sans effet mesurable* : l’équilibre $n_5 = n_7$ est déjà imposé par $C1$, et le filtrage par la table produit naturellement des compositions équilibrées.

Le tableau ?? (colonnes C_2) montre que C_2 améliore nettement C_1 : +10 à +25 points de planéité selon la taille. Le volume de solutions chute en revanche fortement (21 127 solutions sur h_9 contre 646 319 pour C_1), ce qui est un compromis attendu : on sélectionne plus durement, on filtre donc beaucoup en amont.

6.4 C_3 — Interdire les paires 7–7 adjacentes

C_3 durcit C_2 en interdisant la concentration locale de courbure négative. Concrètement, on impose une **contrainte de Gauss–Bonnet locale** de paramètre $\tau_{gb} = 0$ et rayon 2 dans le graphe dual :

$$\forall v \in V_D, \quad ||\{u : x_u = 5, d_{G_D}(u, v) \leq 2\}| - |\{u : x_u = 7, d_{G_D}(u, v) \leq 2\}|| \leq 0.$$

En pratique, cela revient à interdire que deux heptagones soient à distance ≤ 2 dans le dual sans être compensés par autant de pentagones dans le même voisinage, ce qui exclut notamment les paires 7–7 adjacentes.

C’est la configuration **la plus pure** sur les tailles intermédiaires : 95,5 % de planéité sur h_7 , **97,3 %** sur h_8 . Mais elle s’effondre sur h_9 (60,1 %) et son volume devient marginal (2 845 solutions

sur h_9 , dont 1711 planes). C’est le signal que les contraintes purement locales ne suffisent plus aux grands squelettes : les défauts de courbure s’accumulent au-delà de ce qu’un rayon de 2 peut contrôler.

6.5 C_{topo} — Topologie complète

Pour traiter h_9 , nous avons cherché des contraintes *non redondantes* avec Pb1 et qui capturent un mécanisme d’échec différent. Une analyse *a posteriori* des solutions C_1 non planes a fait émerger deux descripteurs topologiques complémentaires, qui forment ensemble la configuration C_{topo} .

Descripteur 1 — motifs de rayon 2 dans le graphe dual. Pour chaque cycle v d’une solution, on définit son *motif de rayon 2* comme le couple $(x_v, \text{multiset}(x_u : u \in \mathcal{N}_{G_D}(v)))$. Par exemple, le motif $7|[6, 7, 7]$ désigne un heptagone entouré d’un hexagone et de deux heptagones. L’analyse statistique sur le corpus h_7, h_8, h_9 a identifié une *blacklist* d’une dizaine de motifs fortement corrélés à la non-planéité, indépendamment de la taille du benzénoïde : par exemple $7|[6, 7, 7]$ ne produit que 9,2% de solutions planes sur h_8 , contre une moyenne de $\sim 60\%$. La contrainte C_{topo} interdit explicitement tous ces motifs ; elle est implémentée par une famille de contraintes négatives sur les tuples $(x_v, x_{u_1}, \dots, x_{u_k})$, intégrées dans le modèle PPC.

Descripteur 2 — topologie du squelette. Le second descripteur est calculé *avant* l’assignement des tailles : le nombre $n_{\text{péri}}$ d’atomes péri-condensés du squelette, c’est-à-dire partagés par au moins trois cycles. Empiriquement, les squelettes $n_{\text{péri}} \geq 4$ (péri-condensés, type coronène) résistent beaucoup mieux à la déformation que les squelettes étalés, où les défauts peuvent se replier sans coût énergétique majeur. La contrainte impose donc $n_{\text{péri}} \geq 4$, ce qui est un *pré-filtre sur le squelette d’entrée* : si le benzénoïde fourni ne le satisfait pas, C_{topo} ne génère aucune solution.

Résultats. Le tableau ?? (colonnes C_{topo}) montre que C_{topo} bat C_3 sur h_9 à la fois en pureté (71,4% contre 60,1%) et en volume (43 057 solutions contre 2 845, soit *quinze fois plus* de candidats explorés, dont 30 742 planes contre 1 711, c’est-à-dire *dix-huit fois plus* de plans). Sur les tailles h_6 – h_8 , C_3 reste plus pure (les chiffres sont plus serrés sur des petits volumes), mais C_{topo} génère un volume bien plus utile pour l’aval.

h	C_1		C_2		C_3		C_{topo}	
	N	%plan	N	%plan	N	%plan	N	%plan
h_3	7	100,0	5	100,0	5	100,0	n.a.	
h_4	44	95,5	16	100,0	12	100,0	n.a.	
h_5	278	88,1	62	88,7	28	85,7	n.a.	
h_6	2 146	78,5	254	88,2	75	93,3	90	100,0
h_7	15 004	65,9	900	83,3	178	95,5	1 035	95,6
h_8	112 800	57,4	3 292	82,0	512	97,3	9 340	86,6
h_9	646 319	38,2	21 127	49,7	2 845	60,1	43 057	71,4

TABLE 3 – Comparaison des quatre configurations C_1, C_2, C_3 et C_{topo} : nombre total de solutions générées (N) et taux de planéité (% plan, validation *det-opt*). Pour chaque taille, la meilleure valeur est en gras. La mention « n.a. » pour C_{topo} sur h_3 – h_5 traduit que ces squelettes sont trop petits pour vérifier le pré-filtre $n_{\text{péri}} \geq 4$ ($n_{\text{péri}}$ vaut au plus 1, 2 et 3 pour h_3, h_4 et h_5 respectivement) ; C_{topo} n’est donc applicable qu’à partir de h_6 .

6.6 Bilan expérimental

L’étude désigne trois régimes selon la taille du squelette d’entrée :

- **Pour h_3 – h_5** : les volumes restent faibles (≤ 280 solutions par configuration sur tout le corpus), le taux de planéité de C_1 seul est déjà élevé (88–100 %), et C_2 ou C_3 atteignent typiquement 100 % de pureté. À cette échelle, le filtrage par contraintes additionnelles est essentiellement superflu, et la configuration C_{topo} n’est pas applicable (le pré-filtre $n_{\text{péri}} \geq 4$ exclut tous les squelettes, $n_{\text{péri}}$ ne dépassant pas 3 avant h_6) ;
- **Pour h_6 – h_8** : C_3 reste la plus pure (93–97 % de planéité), au prix d’un volume réduit ; à utiliser lorsqu’on cherche très peu de candidats mais très fiables ;
- **Pour h_9 et au-delà** : C_{topo} est nettement supérieure (71,4 % contre 60,1 % pour C_3), et produit dix-huit fois plus de candidats plans en absolu. C’est la configuration par défaut recommandée pour les grandes tailles.

L’effet C_{topo} illustre une difficulté méthodologique identifiée à la section ?? : la planéité est une propriété *globale*, et les leviers les plus efficaces ne s’expriment pas comme contraintes locales « naturelles » sur les tailles 5/6/7. Ils nécessitent d’une part une exploration statistique du corpus C_1 pour identifier des motifs déstabilisants (descripteur 1, *a posteriori*), et d’autre part une caractérisation du squelette *avant assignment* (descripteur 2, indépendant de la solution). Cette démarche — générer un corpus, analyser ses échecs, en extraire des contraintes, ré-énumérer — préfigure une boucle d’apprentissage que nous discutons en perspective (section ??).

7 Conclusion et perspectives

7.1 Conclusion

Ce stage a étendu aux non-benzénoïdes le cadre de génération exhaustive par programmation par contraintes proposé par Varet [?]. Nous avons proposé un modèle PPC qui assigne à chaque hexagone d’un benzénoïde d’entrée une taille dans $\{5, 6, 7\}$, articulé autour d’une *table de voisinage* extensionnelle de 721 entrées sensible à la disposition des voisins, et d’une rupture de symétrie par lex-leader sur le groupe d’automorphismes du graphe dual. Chaque solution du modèle est reconstruite en géométrie 3D, puis validée par un pipeline xTB+ACP, dont le protocole d’optimisation déterministe (perturbation analytique en $\sin(2\pi i/N + \varphi)$ suivie de `xtb -opt` en mono-thread) garantit la reproductibilité byte-pour-byte, contrairement à la dynamique moléculaire initialement employée. L’ensemble est intégré dans une application web — le *designer* et son visualiseur 3D — qui étend également aux cycles à 5 et 7 atomes l’analyse électronique (structures de Kekulé, couvertures de Clar, ring bond order), restreinte jusqu’ici aux hexagones.

L’étude expérimentale sur les squelettes h_3 – h_9 de BenzaiDB a comparé quatre configurations, du modèle de base C_1 à la configuration C_{topo} combinant une blacklist de motifs de rayon 2 et un pré-filtre sur le squelette ($n_{\text{péri}} \geq 4$). Les configurations purement locales C_2 et C_3 atteignent une pureté élevée sur les tailles intermédiaires (jusqu’à 97 % sur h_8) mais s’effondrent sur h_9 , où C_{topo} s’impose nettement (71,4 % de planéité, et *dix-huit fois plus* de candidats plans absolus que C_3). Ce résultat confirme expérimentalement ce que nous avons identifié théoriquement : la planéité est une propriété globale qui ne se capture pas, sur les grands squelettes, par des contraintes purement locales sur les tailles 5/6/7. Les leviers les plus efficaces nécessitent soit une analyse statistique *a posteriori* du corpus généré (descripteurs de rayon 2), soit un pré-filtre sur le squelette d’entrée indépendant de l’assignment ($n_{\text{péri}}$) — difficulté qui motive directement les perspectives ci-après.

7.2 Perspectives

La démarche suivie pendant ce stage présente une forme caractéristique : on génère un corpus de candidats par un modèle PPC, on les valide par xTB, on observe les résultats, on interprète les régularités (les pentagones de bord nuisent à la planéité, les paires 5–7 se compensent), on les

transforme en hypothèses, on les exprime sous forme de nouvelles contraintes, puis on ré-énumère pour mesurer leur effet. Au sens méthodologique, c'est une boucle d'*apprentissage* aujourd'hui tenue par l'humain ; demain, elle pourrait être tenue partiellement par une machine. C'est précisément l'enjeu de la **combinaison IA symbolique (PPC) + IA d'apprentissage**, qui fait l'objet d'une recherche active actuellement [?, ?]. La PPC apporte la garantie d'exhaustivité et l'explicabilité (chaque solution satisfait des règles écrites explicitement) ; l'apprentissage apporte la capacité à inférer des motifs dans des espaces de grande dimension où l'humain ne saurait les formuler à la main. Pour notre problème, cela ouvre plusieurs voies : apprendre des contraintes à partir du corpus déjà généré, guider la recherche du solveur par une heuristique entraînée, ou encore prédire la planéité par un réseau de neurones sur graphe pour éviter les appels xTB les moins informatifs. Cette direction, qui maintient le moteur symbolique au cœur mais l'enrichit d'heuristiques apprises, semble particulièrement adaptée à un problème comme le nôtre, où la connaissance chimique est encore en construction et progresse au rythme des expériences elles-mêmes.

Références et bibliographie

- [1] A. Varet, *Programmation par contraintes et chimie théorique : utilisation du formalisme CSP pour résoudre des problématiques liées aux benzénoides*, thèse de doctorat, Aix-Marseille Université, 2022.
- [2] F. Rossi, P. van Beek, T. Walsh (éds.), *Handbook of Constraint Programming*, Elsevier, 2006.
- [3] C. Lecoutre, *Constraint Networks : Techniques and Algorithms*, ISTE/Wiley, 2009.
- [4] C. Lecoutre, N. Szczepanski, *PyCSP3 : modélisation en programmation par contraintes et le solveur ACE (Abscon Constraint Engine)*. pycsp.org.
- [5] A. Varet, N. Prcovic, C. Terrioux et al., *BenzAI : A Program to Design Benzenoids with Defined Properties Using Constraint Programming*, Journal of Chemical Information and Modeling, 2022. DOI : 10.1021/acs.jcim.2c00353.
- [6] J. Edmonds, *Paths, trees, and flowers*, Canadian Journal of Mathematics, 17 :449–467, 1965.
- [7] H. Whitney, *Congruent graphs and the connectivity of graphs*, American Journal of Mathematics, 54(1) :150–168, 1932.
- [8] E. Clar, *The Aromatic Sextet*, John Wiley & Sons, Londres, 1972.
- [9] E. Hückel, *Quantentheoretische Beiträge zum Benzolproblem*, Zeitschrift für Physik, 70 :204–286, 1931 (règle des $4n + 2$ électrons π).
- [10] L. Pauling, *The Nature of the Chemical Bond*, Cornell University Press, 3^e édition, 1960.
- [11] M. Randić, *Aromaticity and conjugation*, Journal of the American Chemical Society, 99(2) :444–450, 1977 (ordres de liaison et circuits conjugués).
- [12] F. J. Rispoli, *Counting Perfect Matchings in Hexagonal Systems Associated with Benzenoids*, Mathematics Magazine, 14 :194–200, 2001.
- [13] P. W. Kasteleyn, *Graph theory and crystal physics*, in *Graph Theory and Theoretical Physics*, Academic Press, p. 43–110, 1967.
- [14] A. J. Stone, D. J. Wales, *Theoretical studies of icosahedral C_{60} and some related species*, Chemical Physics Letters, 128(5–6) :501–503, 1986.
- [15] C. Bannwarth, S. Ehlert, S. Grimme, *GFN2- xTB — An Accurate and Broadly Parametrized Self-Consistent Tight-Binding Quantum Chemical Method*, Journal of Chemical Theory and Computation, 15(3) :1652–1671, 2019.
- [16] Q. Cappart, D. Chételat, E. Khalil, A. Lodi, C. Morris, P. Veličković, *Combinatorial Optimization and Reasoning with Graph Neural Networks*, Journal of Machine Learning Research, 24(130) :1–61, 2023.
- [17] Y. Bengio, A. Lodi, A. Prouvost, *Machine learning for combinatorial optimization : a methodological tour d’horizon*, European Journal of Operational Research, 290(2) :405–421, 2021.